

계량분석

Data Reshape

김현우, PhD¹

¹충북대학교 사회학과 부교수

September 21, 2026



진행 순서

- 1 자료의 구분
- 2 데이터 아카이브
- 3 자료구조 재배열



자료의 구분



자료의 구분

통계자료는 1차 자료와 2차 자료로 구분할 수 있다.

- **편의표본(convenient sample)**에 근거하여 자기가 직접 **1차 자료(primary data)**를 수집한 뒤, 이를 분석하여 논문을 쓰는 경우도 제법 많다.
- 증거자료의 체계적인 수집과 정리, 관리도 하나의 전문적인 경험과학자의 역할이다. 그러나 이에 요구되는 전문적인 능력, 자본, 시간 없이 수집된 1차 자료는 현실적으로 기준 미달인 경우가 많다.
- **내용분석(content analysis)**을 수행하는 경우에는 대부분 직접 1차 자료를 수집해야 한다. 설문조사의 경우에도 2차 자료로는 존재하지 않는 **숨겨진 모집단(hidden population)**을 연구한다면 직접 1차 자료를 수집해야 한다.
- 다만 데이터를 직접 수집하다보면 석박사 과정의 기간이 (아무리 적게 잡아도) 최소한 1년은 늘어난다. 따라서 **2차 자료(secondary data)**가 현실적인 대안이 된다.



자료의 구분

- 최근에는 데이터 사이언스의 영향력이 커지면서 연구자 스스로 온라인에서 1차 자료를 수집하는 경우가 늘어났다.
- (Python이나 R과 같은) 전문적인 코딩 언어를 학습해야 한다. 웹 스크래이핑(web scraping)을 배워야 한다.
- 행정자료(administrative data)를 직접 분석하는 경우가 크게 늘어났다. 가령 소득불평등을 연구한다면 국세청이 직접 생산한 자료를 바로 분석하는 것이 가장 이상적이다(Why?).
- 행정자료는 여러모로 표본(sample)과는 성격이 크게 다르다. 어떤 의미에서 이것은 모집단(population)에 가깝다.



자료의 구분

실험 자료와 비실험 자료의 차이를 명확히 이해해야 한다.

- 실험 자료(experimental data)는 상대적으로 소수의 참가자들(subjects)을 선발(recruitment)한다.
- 비실험 자료(non-experimental data) 또는 관찰 자료(observational data)는 대체로 많은 사람을 조사한다. 최근에는 실험에서도 상대적으로 다수를 선발하는 추세가 있다.
- 실험 자료에서 참가자들은 광고 등의 매체를 통해 초대되는 것이 보통이다.
- 관찰자료에서는 무작위 표집(random sampling)을 강조한다. 여기서는 조사대상을 초대할 때 나타나는 선택편의(selection bias)의 문제를 엄격히 경계한다(Why?).



자료의 구분

- 실험 참가자들은 **무작위(random)**로 처방집단(treatment group)과 통제집단(control group)으로 나뉜다.
- 비실험 자료에서도 물론 처방집단과 통제집단이 나뉘지만, 이때 두 집단의 구분이 무작위라는 보장이 없다(Why?).
- 실험의 경우, 실험집단과 통제집단 사이에서 나타나는 차이는 **처방효과(treatment effect)**로 귀속된다. 비실험 데이터의 경우 그렇다는 보장이 없다(Why?).
- 실험에서 얻은 결과(results)가 실험 참가자 이외의 사람들에게 대해서도 **일반화(generalization)**될 수 있는가 확신할 수 없다.
- 이러한 목적을 위해서는 **메타분석(meta analysis)**이 필요하다(Why?).



자료의 구분

실험 자료와 관찰자료에서 무작위성 또는 임의성은 다른 의미로 통용된다.

- 실험 자료에서 **무작위화(randomization)** 또는 **임의할당(random assignment)**와 관찰자료에서 **임의표본(random sample)**을 확실히 구분해야 한다.
- 실험 자료에서 임의할당은 어떤 실험 참가자가 처방집단과 통제집단 중 어느 쪽에 속할지 “오로지 우연에 의해서” 결정된다는 뜻이다.
- 임의할당 덕분에 실험연구에서 두 집단 사이의 차이를 처방효과라고 볼 수 있게 된다. 즉 **상관관계(correlations)**를 넘어 **인과관계(causal relations)**를 발견할 수 있다.
- 다만 임의표집은 아니므로 모집단 전체로 일반화를 보장할 수 없다.



자료의 구분

- 관찰자료에서 **임의표본(random sample)**이란 모집단의 구성원이 “오로지 우연에 의해서” 선발된 표본임을 뜻한다.
- **단순임의표집(simple random sampling)**에서는 모집단의 구성원이 표본으로 뽑힐 확률이 같다.
- 임의표집 원리 덕택에 표본 안에서의 분석 결과는 모집단 전체로 일반화 될 수 있다.
- 다만 임의할당이 아니므로 분석 결과를 통해 얻은 연관성이 인과관계를 보장하지 못한다.



자료의 구분

(심리학을 제외한) 많은 사회과학 연구에서는 대체로 관찰자료를 사용한다.

- 전통적인 사회과학은 실험이 불가능하거나 매우 어려운 주제인 경우가 많다.
- 너무 여기에 집착해서 실험 자료와 모의실험 자료를 아예 고려하지 않는 것은 위험하다.
- 실험 자료의 분석은 비교적 근래에 사회과학 분야에서 다시 한 번 크게 주목받고 있다.
- 관찰자료도 **자연실험(natural experiments)**의 상황에서는 실험 자료처럼 분석될 수도 있다(Why?).
- 모의실험(simulation)은 **수리사회학(mathematical sociology)**의 영역이고 이 분야는 (사회학 안에서는) 마이너한 분야라서 제대로 배우기 어렵다.



자료의 구분

시간을 어떻게 고려하는가에 따라서 연구설계 유형이 달라진다.

- **횡단면 연구(cross-sectional studies)**는 시간을 무시한다. “같은 시간 동안” 다른 사람들을 조사한다(물론 분석단위에 따라 사람이 아닐수도 있다).
- **시계열 연구(time-series studies)**에서는 “하나의 대상”을 시간의 변화에 따라 조사한다.
- **반복된 횡단면 연구(repeated cross-sectional studies)**에서는 횡단면 연구를 “다른 시점에” 여러 번 수행한다.
- **패널 연구(panel studies)**는 여러 대상들을 시간의 변화에 따라 추적하여 반복 조사한다.



데이터 아카이브



데이터 아카이브

사회과학 연구에서 2차 자료의 확산은 역사적인 현상이다.

- 가정용 컴퓨터가 보급된 1990년대 이후의 시점에서 이른바 **데이터 아카이브(data archive)**가 탄생했다.
- 자신이 수집한 자료를 한 번 쓰고 버리기보다 남들도 연구와 교육을 위해 쓸 수 있도록 배려한다는 취지였다.
- 경험과학의 성격상 자료 수집 자체에 전문화된 사람들이 다양한 주제로 데이터를 수집하여 공개하였다.
- 데이터 아카이브의 출현은 **계량적 사회과학(quantitative social sciences)**의 출현과 발달에 가장 중요한 인프라였다.
- 어떤 기관/조직이 데이터 아카이브를 운영하고 통제하는 것은 말하자면 그 조직이 계량적 사회과학 계에서 기축통화(key currency)를 가졌다는 말과 같다.



데이터 아카이브

다양한 2차 자료 아카이브가 있다.

- 종합적인 주제를 모두 커버하는 데이터 아카이브와 특수한 주제만을 커버하는 데이터 아카이브로 나뉜다.
- 특수주제형 데이터 아카이브는 수가 무척 많고 여기저기 흩어져 있어서 자기 전공 분야만 잘 아는 경우가 많다.
- 한국의 지리정보 데이터의 경우 **통계지리정보서비스**가 좋은 출발점이다.
- 경영/금융 데이터의 경우 **금융감독원 전자공시시스템**이 있다.
- 해외 경제 데이터의 경우 **National Bureau of Economic Research (NBER)**가 유명하다.
- 전세계 종교 데이터의 경우 **The Association of Religion Data Archives (ARDA)**가 유명하다.



데이터 아카이브

- 전세계에서 명실상부 가장 대표적인 종합형 데이터 아카이브는 Inter-university Consortium for Political and Social Research로 이른바 **ICPSR**라고 불리운다.
- 그 밖에도 사회분석 비영리단체인 **Pew Research Center**, 여론조사자료 아카이브 플랫폼인 **Roper Center**, 그리고 기존 연구 데이터를 수록한 **Harvard Dataverse** 등이 알려져 있다.
- 우리나라에서 대표적인 종합형 데이터 아카이브는 현 시점에서 아마도 **한국사회과학자료원**과 **한국사회과학데이터센터**인 것 같다.



우리나라는 상당히 괜찮은 수준으로 공공데이터를 제공하고 있다.

- 공공데이터라면 특히 **공공데이터포털**에서 원하는 자료를 찾아보아야 한다.
- 센서스 등 수많은 조사들의 마이크로데이터(microdata)는 **MDIS**에 공개되어 있으므로 다운로드 받을 수 있다. 일부는 통계데이터센터(SDC)에 직접 방문해서 사용할 수 있다(원자료 반출은 허용되지 않는다).
- 각 지자체나 기관 별로 공공데이터를 따로 관리하기도 한다. 가령 **서울 열린데이터광장**이나 심평원의 **보건의료빅데이터개방시스템** 등이 있다.
- 다운로드가 아니라 **Application Programming Interface (API)**의 형식을 취하는 경우가 늘어났다. 이런 경우에는 자료에 접근하기 위해서라도 코딩(주로 R이나 Python)을 배워야 하고 전처리 숙련도도 필요하다.



자료구조 재배열

- 다만 공공데이터나 공식 통계는 대부분 집계 자료(aggregate data)라는 점에서 유용성이 다소 제한적인 경우가 많다(Why?).
- 어떤 경우에는 집계 자료로도 충분하지만, 대체로 원자료(raw data)가 훨씬 유용하다.
- 원자료는 프라이버시나 저작권 등의 이유로 인해 보통 공공 데이터로서는 공개되지 않지만, 연구 목적에 따라서는 구입 또는 정보공개 청구로 확보할 수 있는 경우가 있다.
- 필요에 따라 SDC 또는 정보공개 청구를 적극 이용해야 할 수도 있다.



데이터 아카이브

- 막상 사회학 연구에서 공공데이터나 정부의 공식 통계는 다소 미묘한 입장에 있다.
- Emile Durkheim의 <자살론>은 **공식 통계(official statistics)**를 활용한 가장 뛰어난 사회학 고전 연구다(동시에 공식 통계에 의존했다는 이유로 비판받기도 했다).
- 사회학 연구에서 공식 통계의 사용에 관한 가장 근본적인 비판 가운데 하나는 **민속방법론(ethnomethodology)**에 의해 제기되었다
- “우리는 사회 현상을 통계적으로 분석하는가? 아니면 공무원의 통계 작성 행위를 분석하는가?”
- 아까 언급한 행정자료 사용도 어떤 의미에서 이 문제 제기에 취약하다.



자료구조 재배열



자료구조 재배열

분석목적에 따라 자료를 뒤틀어 다른 꼴로 바꾸어야 할 때가 있다.

- 분석의 목적에 따라 **긴 꼴(long form)**과 **넓은 꼴(wide form)**로 자료구조를 **재배열(reshaping)**해야 하는 상황이 나온다.
- 아래 예제는 넓은 꼴에서 긴 꼴로 자료를 변환할 때 어떻게 달라지는지 보여준다.
- (Weight과 BP 대신) Key와 Value가 새로 생겼다. 그리고 기존의 구체적인 값들은 Value 안에 들어갔다.

Name	Weight	BP
John	150	120
Smith	170	130



Name	Key	value
John	Weight	150
John	BP	120
Smith	Weight	170
Smith	BP	130



자료구조 재배열

- 아래의 또다른 예제는 긴 쪽에서 넓은 쪽으로 자료를 변환하는 상황을 보여준다.

country	year	metric
x	1960	10
x	1970	13
x	2010	15
y	1960	20
y	1970	23
y	2010	25
z	1960	30
z	1970	33
z	2010	35

country	yr1960	yr1970	yr2010
x	10	13	15
y	20	23	25
z	30	33	35



대체 왜 이런 재배열이 필요할까?

- 그 상황을 직접 부딪쳐보면 그 필요성을 이해할 수 있다.
- 만약 국가별로 `metric`을 종속변수로, `year`를 독립변수로 하는 회귀분석을 수행한다면 자료가 어떤 꼴일 때 더 편리할까?
- 만약 국가별로 특정 해의 `metric` 평균을 구하고 싶다면 자료가 어떤 꼴일 때 더 편리할까?
- 문제는 적절한 배열의 형태를 우선 파악하고, 이를 제대로 수행하기가 생각보다 까다롭다는 점이다.
- (자료 결합과 마찬가지로) 혼동스럽기 때문에 상당한 경험과 연습을 필요로 한다.



자료구조 재배열

World Bank에서 제공하는 공공 데이터로 연습해보자.

- 세계은행에서 국가 단위의 경제 통계를 다운로드 받을 수 있다([링크]).
- World Development Indicators에서 모든 나라의 GDP (constant 2015 US\$)를 모든 기간에 걸쳐 csv 파일 형식으로 다운로드 받아보자.
- GDP는 문자열(string)이므로 이를 수치형 자료로 변환하고 히스토그램을 그려보자. 이 그림은 어떤 시사점을 제공하나?



자료구조 재배열

- 현재 주어진 자료의 꼴은 무엇인가? 넓은 꼴(wide form)인가, 아니면 긴 꼴(long form)인가?
- `reshape` 명령어를 사용하여 다른 형태로 능수능란하게 바꿀 수 있어야 한다.
- 재배열한 자료를 다시 원상복귀해보자.
- 상당히 많은 연습을 거치지 않으면 잘 되지 않는다. 특히 관측치에 걸쳐 변화하는 값과 변화하지 않는 값을 잘 구별해야 한다(Why?).

