

계량분석

Aggregation and Merge

김현우, PhD¹

¹충북대학교 사회학과 부교수

September 21, 2026



진행 순서

- 1 사회조사
- 2 자료의 집계와 결합
- 3 설문지 공부하기
- 4 연습문제



사회조사



사회조사

수많은 사회조사 자료를 찾을 수 있다.

- **사회조사(social survey)**는 해당 지역 또는 국가의 거주민들이 정치·사회·경제·과학기술 등 여러 분야에 걸친 가치(values), 여론(opinions), 태도(attitudes), 행동(behaviors)를 조사한 것이다.
- 일반적으로 하나의 사회조사자료는 특정 연구모집단 내 모든 구성원들에 대해 **대표성(representativeness)**을 확보하고 있다.
- (미국은 GSS, 한국은 KGSS, 중국은 CGSS, 일본은 JGSS, 독일은 GGSS 등) 국가별로 각각 대표적인 사회조사가 있다.
- 유사한 질문을 수 년에 걸쳐 반복적으로 질문하여 사회변동을 파악하기에 유용하다. 다만 같은 사람을 추적하지 않으므로 패널자료는 아니다(미국의 GSS는 패널도 함께 운용하고 있다).
- 특정 토픽을 수 년에 한 번씩 돌리기도 한다(가령 3년 간격으로 보건의료·정치경제·사회복지 로테이션).



사회조사

사회조사 데이터들을 비교하여 국가간 비교를 수행할 수도 있다.

- 예전 **비교사회학(comparative sociology)**이 제법 흥성하던 시기가 있었다.
- 이 목적으로 설계·수집된 대표적인 자료로 Ronald Inglehart가 주도한 World Values Survey (WVS)가 특히 유명하다.
- 유럽 국가들 사이에서 설계·수집된 자료로 European Values Survey (EVS)도 나름 유명하다.
- 몇몇 국가의 연구자들은 자국에서 나름의 GSS를 운영하면서 같은 **모듈(module)**을 같은 해에 함께 질문하여 일부러 비교가능하도록 설계하였다.
- 이 자료를 따로 뽑아 만들어진 자료로는 International Social Survey Programme (ISSP), ESS (European Social Survey), East-Asian Social Survey (EASS) 등이 있다.
- (필요에 따라) 한국인과 미국인의 사회적 가치를 비교하기 위해 KGSS와 GSS를 함께 분석할 수 있다.



비교사회학자들은 폭넓은 자료에 힘입어 여러 주제들을 탐구하고 있다.

- 국민정체성(national identity), 민족주의(nationalism), 그리고 이주민에 대한 태도(attitudes toward migrants)
- 국가기구에 대한 신뢰(confidence), 대중 일반에 대한 신뢰(trust)
- 노동조합 가입률 및 조직관련 행동
- 결혼과 가족, 여성의 사회적 지위, 아동 양육 등에 관련한 태도 및 행태, 가치관
- 더 많은 시민적 자유(civil liberties)와 통치가능성(governability) 사이에서의 믿음
- 정치 및 사회 참여, 신사회운동(new social movements) 가치관
- 교육, 보건, 의료와 관련된 태도 및 행동



세계가치관조사의 최근 자료를 간단히 살펴보자.

- 링크는 <https://www.worldvaluessurvey.org>
- Stata 원자료 파일(Wave 7) 뿐만 아니라 설문지도 함께 다운로드 받자.
- 특히 **탈물질주의적 가치(post-materialist values)**를 살펴보자.
- 다음의 중 가장 중요한 두 가지가 무엇인가를 고르게 하여 분류한다(1=물질주의적; 2=혼합적; 3=탈물질주의적).
 - (1) Maintain order in the country
 - (2) Give people more to say in important government decisions
 - (3) Fight raising prices
 - (4) Protect freedom of speech
- Y002 변수가 어떻게 만들어졌는지 확인해보자.

잉글하트, 로널드. 1983. 『조용한 혁명』. 종로서적.

잉글하트, 로널드 · 크리스찬 웰젤. 2011. 『민주주의는 어떻게 오는가』. 김영사.



자료의 집계와 결합



자료의 집계와 결합

집계는 선거 결과 개표를 연상하면 이해하기 쉽다.


- 수십만 장의 투표용지 뭉치로는 선거 결과를 알 수 없고, 하나하나 개표하여 각 후보에 던져진 표의 수를 세어야(count) 한다.
- 최종 결과표에는 전체 투표수를 분모로, 후보별 득표수를 분자로 한 비율(proportion)이 명시되어야 한다(Why?).
- (선거 결과에서 그러하듯) **집계(aggregation)**는 변수를 하나의 숫자로 요약하는 과정이다.
- 어떤 경우에 집계는 요약통계(=기술통계)를 계산하는 과정에서 자연스럽게 이루어진다.
- 기술통계는 반드시 결과표를 제시하려는 목적으로만 수행되는 반면, 우리는 집계를 별도로 수행하여 인위적으로 **집계자료(aggregate data)**를 생산할 수 있다.



자료의 집계와 결합

두 개 이상의 자료의 연결은 매우 중요한 기법이다.

- **자료 결합(data merging)**는 크게 네 가지 형식 중 하나로 이루어진다:
 - (1) **일대일(one-to-one)**
 - (2) **일대다(one-to-many)**
 - (3) **다대일(many-to-one)**
 - (4) **다대다(many-to-many)**



One-to-Many Merging



자료의 집계와 결합

- 각각 **공통 변수(common identifier)**가 “고유한 하나”인가 아니면 “중복된 여러 개”인가에 따라 다르다.
- 연구 목적에 따라서도 써야 하는 연결 방식이 달라진다.
- Stata에서는 **결합하는 파일(master file)**과 **결합에 쓰일 파일(using file)** 모두에서 공통 변수의 이름이 반드시 같아야 한다.
- 공통 변수가 있는 한 수많은 자료들을 연결할 수 있다. 연결된 자료는 그렇지 않았을 때와는 비교할 수 없을만큼 큰 잠재력을 갖는다(Why?).
- 특히 공공 데이터는 그 자체로는 다소 쓸모가 약하지만, 다른 사회조사 자료나 패널자료와 결합되었을 때 나름의 가치를 보여준다(Why?).



자료의 집계와 결합

아까 준비한 세계가치관조사 자료와 세계은행 공공 데이터를 결합해 보자.

- ISO 3166-1 국가 코드는 WVS 자료와 세계은행 공공 데이터 양쪽 모두에 들어있다. 이 공통 변수를 사용해 자료를 연결할 수 있다.
- 먼저 WVS 데이터에서 가치체계를 세 개의 **가변수(dummy variable)**로 바꾸어보자.
- WVS 원자료의 관찰단위는 개인이었는데 이를 국가 수준으로 집계(aggregate)하자.
- 이제 WVS 데이터와 WB 데이터 모두 측정단위는 국가가 되었다.
- 이제 서로 결합(merge)하고 편의상 결합에 실패한 국가들은 그냥 삭제하자.
- 국가별로 물질주의적 가치 평균, 혼합형 가치 평균, 탈물질주의적 가치 평균이 GDP와 어떤 관련을 갖는지 산점도를 그려보자.



설문지 공부하기



설문지 공부하기

자료 탐색에 시간을 충분히 많이 써야 한다.

- 찾고자 하는 데이터가 정말 존재하는지 그리고 어떻게 구하는지를 아는 것은 그 자체로 어려운 일이다(know-how라기보다 **know-where**에 가깝다).
- 자신의 전공과 무관하더라도 수많은 데이터를 살펴보아야 한다. 이 과정에서 새로운 분야에 대해 관심과 식견을 키우고 학제간 통찰력도 얻는다.
- 여러분이 연구하고자 하는 주제와 직결된 자료가 아니더라도 쓸모 있을 수 있음에 주의하자(Why?).



설문지 공부하기

책 읽기와 마찬가지로 설문지 읽기도 사회학 연구에 큰 도움이 된다.

- 이론과 분석 사이의 간극은 언뜻 매우 넓고 깊은 것 같지만 때때로 아주 우연히 메꾸어진다.
- 얼핏 본 설문조사 질문 하나로부터 지적 충격을 받아 완전히 새로운 이론적 관심으로 발전하는 일은 매우 흔하다.
- 관심있는 자료 사이트에 가서 (적어도) 설문지를 다운로드 받고 어떤 문항들이 있는지 눈여겨 보다보면, 많은 사회학적 상상력과 분석적 통찰력을 얻는다.



설문지 공부하기

특정 자료가 필요하다면 연구 기간을 고려하여 신속하게 행동하자.

- 많은 경우 회원 가입 후 쉽게 자료를 받을 수 있다.
- 자신이 원하는 자료를 얻으려면 이를 보유한 기관에 별도로 신청해야 할 수도 있다. 이 과정은 생각보다 오래 걸릴 수도 있다.
- 경우에 따라 정보공개청구 내지 개별적인 연락까지 필요할 수도 있다. 이 과정도 당연히 시간 소모를 예상해야 한다.
- 유료 자료에는 애초에 손을 대지 말자.



연습문제



연습 1. BODYFAT.SAV 자료의 배열을 파악하고 다른 꼴로 재배열하시오.
재배열된 자료를 다시 원래 형태로 복구하시오.



연습 2. 한국교육종단연구 2005년 교육용 자료(Y2_STD_EDU.SAV)를 사용하여 다음 지시를 수행하시오.

- 1 사회 자기(social self) 변수들을 모두 더하여 사회 자기 총점을 계산하시오.
- 2 사회 자기 총점을 각 학교별(schid)로 집계한 평균값을 구하여 그 결과를 적절히 시각화하시오.
- 3 각 학교별로 집계된 사회 자기 점수의 평균값을 원래 자료(Y2_STD_EDU.SAV)에 적절히 결합하시오. 결합의 과정을 설명하시오.
- 4 결합된 자료에서 학생 개인의 사회 자기 점수와 학교별 평균값의 편차(deviation)를 계산하고, 그 결과를 시각화하시오.



연습 3. ‘성평등한 정치대표성 확보를 위한 정치인식조사, 2020’
kor_data_20200064.dta 자료를 사용하여 다음 과업을 수행하시오.

- 1 성별, 연령대, 거주지역, 거주지역 규모, 최종학력, 월평균 가구소득 등 인구통계학적 변수들의 **기술통계표(descriptive statistics table)**를 만드시오.
- 2 조사참여자 별로 사회적 변화를 위해 참여한 활동의 갯수를 계산하시오. 이때 오프라인 방식(act1)과 온라인 방식(act2)을 나누어 계산하시오.
- 3 두 변수의 빈도분포표와 히스토그램을 살펴보고, 이 새로운 변수들에서 큰 값들 무엇을 의미하는지 논하시오.
- 4 **정치적 효능감(political efficacy)**를 측정하기 위해 A2_1와 A2_2의 평균을 **외적(external)** 효능감으로, A2_3을 **내적(internal)** 효능감으로 사용한다. 필요에 따라 변수들을 **역부호화(reverse coding)**한다.
- 5 성별에 따라 두 정치적 효능감 변수의 차이를 간단히 비교해보자.
- 6 다음 기사([링크])를 읽고 이를 직접 재현해보자(연습문제).

