

계량분석

Comparing Variances

김현우, PhD¹

¹충북대학교 사회학과 부교수

October 5, 2026



진행 순서

- 1 모분산에 대한 가설검정
- 2 두 모분산에 대한 가설검정
- 3 일원분산분석



모분산에 대한 가설검정



모분산에 대한 가설검정

모분산 σ^2 에 관한 가설검정은 여러 상황에서 유용하다.

- 1 가령 소득의 분산은 소득 불균등을 의미한다(사실 사회계층 및 불평등 연구에서는 좀 더 정교한 소득 불균등 지표가 사용되기는 한다).
- 2 한 반에서 학생 성적의 분산은 교육 성과가 고르게 나타나지 않아 교육 양극화가 나타남을 시사한다.
- 3 설문조사의 특정 문항에 대한 응답의 분산은 조사대상자 의견의 불일치 내지 다양성을 의미한다.
- 4 금융상품의 수익률의 분산은 해당 상품의 **스프레드(spread)** 또는 **리스크(risk)**를 의미한다. 똑같은 논리가 도박에 대해서도 적용된다.
- 5 제조된 공산품의 상태지표의 분산은 들쭉날쭉한 품질(quality) 상태를 의미한다.



모분산에 관한 가설검정

일단 하나의 표본분산 s^2 에 대해 이론적으로 상상해보자.

- 우리는 모집단에서 표본을 무한히 계속 뽑고 그것들의 분산 s^2 를 구해 분산의 표집분포를 상상해 볼 수야 있다
- 이때 표본 크기 n 이 작다면 분산의 표집분포는 오른쪽 꼬리가 길어진다(long tail). 그 이유는 생각보다 단순한데, 분산의 계산 과정에서 제곱을 하다보면 큰 값이 우연히 많이 나오기 때문이다(Why?).
- 하지만 아쉽게도 표본분산 s^2 에 관한 직접적인 이론 분포는 없다!



모분산에 관한 가설검정

- 표본평균 $\bar{x}$ 의 경우 소표본일 때 t 분포, 대표본일 때 Z 분포라는 이론적 확률분포를 가졌다.
- 반면 분산 s^2 의 경우 직접적인 이론적 확률분포가 없고, “표본분산 s^2 와 모분산 σ^2 간의 비율을 자유도와 곱한 값”에 관한 이론적 확률분포인 χ^2 분포(chi-square distribution)를 대신 사용한다(교과서 175-177).

$$\chi_{n-1}^2 = \frac{(n-1)s^2}{\sigma^2}$$

- 다시 한 번 강조하자면, 단일표본의 분산 s^2 의 표집분포가 아니라, $\frac{(n-1)s^2}{\sigma^2}$ 의 표집분포를 상상해야 한다!



모분산에 대한 가설검정

χ^2 분포는 오로지 자유도 $n - 1$ 에 의해 모양이 결정된다.

- χ^2 분포는 소표본일 때 비대칭적이고 오른쪽으로 꼬리가 길다.
- Z 값에 제곱을 하다보면 우연히 큰 값이 나타나기 쉽고 표본이 작다보면 그 값이 튀어보이기 때문이다(Why?).

$$\chi_k^2 = Z_1^2 + Z_2^2 + \dots + Z_k^2 = \sum \left(\frac{x - \mu}{\sigma} \right)^2$$


- 모집단에 대해 정규성 가정(normality assumption)이 성립할 것이 요구된다(Why?).
- 그러나 대표본이 될수록 정규분포의 모습에 점점 근사한다(Why?).
- χ^2 값은 결국 분산들의 비율이므로 항상 양수값을 갖는다.

$$\frac{(n - 1)s^2}{\sigma^2} \geq 0$$



모분산에 대한 가설검정

- 표본에서 나온 s^2 와 귀무가설로 설정된 σ^2 이 거의 같다면, s^2/σ^2 은 1에 가까워진다.
- 만약 s^2/σ^2 이 1과 크게 다르다면, χ^2 값은 $(n-1)$ 보다 매우 작거나 매우 커질 것이다(교재 196페이지).
- χ^2 분포는 대칭적이지 않기 때문에 좌측 유의확률과 우측 유의확률이 일치하지 않는다. 그러나 표본이 충분히 크면 양자는 대체로 일치하게 된다(Why?).



모분산에 대한 가설검정

앞서 배운 바와 마찬가지로 유의성 검정을 수행할 수 있다.

- 주어진 데이터(stay)에서 모표준편차를 추정하고자 하는 대상 변수의 요약통계량을 살펴보자.
- “모집단에서 입실 기간(length of stay in days)의 표준편차는 10일보다 작다 ($\sigma \leq 10$)”라는 귀무가설을 세우기로 한다.
- 이에 따라 1,778개의 표본에서 계산된 표준편차 s 와 모집단 점수로 가설 설정된 표준편차 σ_0 의 비율에 1,777의 자유도를 곱한 χ^2_{1777} 분포를 그릴 수 있다.



모분산에 대한 가설검정

- 표본에서 계산된 표준편차가 약 9.45점이므로, χ^2 값은 약 1587.2이다.

$$\chi^2 = \frac{(n-1)s^2}{\sigma^2} = \frac{(1778-1) \cdot 9.45^2}{10^2} = 1587.2$$

- Stata에서는 이론적 확률분포의 **누적분포함수(CDF)**를 직접 계산하여 χ^2 값과 유의확률(p -value)을 구할 수 있다.
- $p < 0.001$ 이므로 99.9% 유의수준에서 귀무가설을 통계적으로 유의하게 기각할 수 있다.
- Stata에서는 `sdtest` 명령어를 사용한다. 다만 이것은 분산을 비교하는게 아니라 표준편차를 비교한다는 점에 주의하자.



두 모분산에 대한 가설검정



두 모분산에 대한 가설검정

분산비교는 F 분포를 이용한다.

- “단일모집단의 분산”에 관한 가설 검정이 χ^2 분포를 이용하는 반면, “두 모집단의 분산의 **비율**”에 관한 가설 검정은 F 분포를 이용한다.
- F 분포의 **확률밀도함수(PDF)**는 다음과 같이 정의된다.


$$F_{(n_1-1, n_2-1)} = \frac{\chi_1^2 / (n_1 - 1)}{\chi_2^2 / (n_2 - 1)}$$

- 조금만 생각해보면 F 분포는 각각의 “단일모집단의 분산”을 설명하는 χ^2 의 비율임을 쉽게 파악할 수 있다.



두 모분산에 대한 가설검정

- F 분포는 두 개의 자유도 ($n_1 - 1$)와 ($n_2 - 1$)에 따라 그 형태가 결정된다(이것도 χ^2 와 흡사하다).
- 두 개의 자유도가 작을 때는 우측 꼬리가 길다. 두 개의 자유도가 점점 커지면 정규분포에 점점 근사한다.
- χ^2 분포와 마찬가지로 대칭적인 형태가 아니다.



두 모분산에 대한 가설검정

- 우리는 두 표본의 분산의 차(difference)를 구하려는 것이 아니라 비(ratio)를 구한다. 따라서 두 χ^2 값이 서로 비슷할수록 F 값은 (0이 아니라) 1에 접근한다.
- F 값은 두 개의 χ^2 분포의 비로 구성되므로 항상 양수(+)이다.
- 일단 χ^2 분포 자체에 익숙해져야 F 분포에 대해서도 쉽게 이해할 수 있다.



두 모분산에 대한 가설검정

Stata에서 두 개의 독립표본에 대한 분산비교를 연습하자.

- `fuel12` 자료에서 `treat`에 따라 `mpg`의 표준편차 비율에 관한 귀무가설들을 검정해보자.
 - (1) “`treat` 상태에 따른 `mpg`의 표준편차 비율은 1이다.”
 - (2) “`treat` 상태에 따른 `mpg`의 표준편차 비율은 1보다 작다.”
 - (3) “`treat` 상태에 따른 `mpg`의 표준편차 비율은 1보다 크다.”
- 쌍체표본(`paired sample`)도 있긴 하지만, 여기서는 더이상 다루지 않고 넘어간다.



일원분산분석



일원분산분석

일원분산분석은 여러 모분산에 대한 가설검정 기법이다.

- 사실 지금까지 설명한 분산의 추정과 비교는 **일원분산분석(one-way analysis of variance)**을 위한 준비에 불과하다.
- 한편 **분산분석(ANOVA)**은 특히 **실험적 연구**의 맥락에서 분석을 위해 자주 사용되는 고도로 발달한 여러 분석기법들의 한 집합이다.
- 일원분산분석에서 일원(one-way)는 독립변수가 하나인 것을 의미한다.
- 일원분산분석은 여러 개의 표본들이 주어졌을 때 이것들이 하나의 모집단에서 추출되었는가를 확인한다.
- 그 밖에도 **다변량분산분석(multivariate ANOVA 또는 MANOVA)**, **공분산분석(analysis of covariance 또는 ANCOVA)**이나 **다변량공분산분석(multivariate analysis of covariance 또는 MANCOVA)** 등 다양하게 있으나 이것들은 이 수업의 수준을 벗어난 것이므로 다루지 않는다.



일원분산분석

일원분산분석의 검정통계량은 F 값이다.

- 일원분산분석은 F 분포를 사용하며, 그 근본 원리는 (앞서 설명한) 두 모집단 분산 비율에 대한 가설검정과 완전히 같다.

$$\begin{aligned} F_{(k-1, n-k)} &= \frac{SS_{between}/(k-1)}{SS_{within}/(n-k)} \\ &= \frac{MS_{between}}{MS_{within}} \\ &= \frac{\sigma_{between}^2}{\sigma_{within}^2} \end{aligned}$$

- 분자는 실험처리에 의한 효과(treatment effect)로 볼 수 있고, 분모는 무작위오차(random error)에 지나지 않는다(Why?).




집단 간 분산이 클수록 그리고 집단 내 분산이 작을수록 F 값은 커진다.

- 수리적으로 따지고 들어갈 필요조차 없다. 사실 F 값이 갖는 의미는 상식적으로 너무나 명확하다!
- 두 표본이 주어졌을 때, 표본 간에는 차이가 크고 표본 내에는 차이가 작다면, 두 모집단은 서로 다른 것이다.
- 두 표본이 주어졌을 때, 표본 간에는 차이가 작고 표본 내에는 차이가 크다면, 두 모집단은 서로 다르다고 할 수 없다.
- 따라서 F 값이 크다는 것은 두 모집단은 서로 다름을 시사한다.



일원분산분석



일원분산분석

- 계산을 진행하면서 **분산분석표(ANOVA table)** 안에 각각의 숫자를 채워넣으면 된다.
아! 물론 계산은 컴퓨터가 한다.

Variance	SS	df	MS	F
Between groups	$SS_{between}$	$(k - 1)$	$MS_{between}$	F
Within groups	SS_{within}	$(n - k)$	MS_{within}	
Total	SS_{total}	$(n - 1)$	MS_{total}	

- 실제 표에서는 F 옆에 유의확률(p -value)이나 임계값(critical value) 등도 추가해서 써넣는 경우도 있다.



일원분산분석의 가설 설정은 다소 주의를 요한다.

- 귀무가설은 “모든 그룹에 걸쳐 평균이 같다”이다. 예를 들면 다음과 같다.
 - (1) 인지된 기후변동의 심각성 점수의 평균에 최종학력별 차이는 없다.
 - (2) 출신지역별로 정치적 보수주의 점수 차이가 없다.
 - (2) 기업내 직급 수준에 따른 인적자원개발 프로그램 만족도 차이는 없다.

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \dots = \mu_k$$

- 그 대립가설은 “적어도 하나의 그룹에서 평균값이 다르다”이다.

$$H_a : (\mu_1 \neq \mu_2) \text{ or } (\mu_1 \neq \mu_3) \text{ or } \dots \text{ or } (\mu_{j-1} \neq \mu_j)$$



일원분산분석

- “모든 그룹에 있어 평균값이 다르다($H_a : \mu_1 \neq \mu_2 \neq \mu_3 \neq \dots \neq \mu_j$)”가 아님에 주의할 것(Why?)!
- 당연히 “최종학력이 높아질수록 인지된 기후변동의 심각성 점수도 함께 높아진다”와 같은 해석은 본래 일원분산분석으로 할 수 없는 과잉해석이 된다.
- 튜키(Tukey), 본페로니(Bonferroni), 셰퍼(Scheffe), 시닥(Sidak) 등 이른바 **다중비교검정(multiple comparison test)**은 임의로 선정된 두 그룹 중 어느 그룹에서 평균값이 더 높은가를 살펴보는 기법이다. 교과서에 따라서는 **사후비교(post hoc comparison)**라고 부르기도 한다. 우리는 다루지 않는다.
- 일원분산분석은 실제 분석상 분산의 비율을 비교하고 있음에도 불구하고, 가설 설정은 평균에 대해 이루어진다는 점도 주의해야 한다.



두 개의 자유도와 계산된 $F_{(k-1, n-k)}$ 값을 가지고 유의성 검정을 수행한다.

- census3 자료에서 지역(region)에 따라 출산율(brate)이 다른지 일원분산분석을 수행해보자.
- (모든 집단에 있어 평균이 같다는) 귀무가설이 정말로 옳다면 F 값은 1에 가까울 것이다(Why?).
- Stata에서는 oneway 명령어를 사용할 수 있고, 좀 더 일반화된 분산분석 명령어인 anova를 사용할 수도 있다.

