

계량분석

One-Way ANOVA in Practice

김현우, PhD¹

¹충북대학교 사회학과 부교수

October 5, 2026



진행 순서

- 1 일원분산분석의 실제 활용
- 2 χ^2 독립성 검정
- 3 연습문제



일원분산분석의 실제 활용



일원분산분석의 실제 활용

경험적 연구에서 일원분산분석은 크게 두 부분에서 주로 활용된다.

- 첫째, 표본에 관한 **기술통계(descriptive statistics)**를 제시할 때 사용된다.
- 둘째, **회귀분석(regression analysis)**에서 **모형 적합도(goodness-of-fit)** 지표 중 하나로 사용된다.
- 기술통계로 제시한다면, 표본 안의 핵심이 되는 범주형 관심변수 내지 종속변수에 따라 다른 여러 변수들이 어떻게 다른지 일원분산분석을 통해 보여줄 수 있다.
- 이때 범주형 변수는 명목형 내지 순서형 척도로 측정된 것이다. 예컨대 최종학력, 출신지역, 지지하는 정당 등을 생각해 볼 수 있다.



일원분산분석의 실제 활용

〈Table 7〉 Analysis of variance on perception toward justice

		Average of effort reward fairness	<i>F</i>	Prob.> <i>F</i>
All		2.981		
Sex	Male	2.975	0.10	0.7469
	Female	2.987		
Co-residency with parents	Not living together	3.008	1.02	0.3136
	Living together	2.969		
Economic Independence	Independent	3.031	7.47	0.0063
	Dependent	2.935		
Marital status	Married	3.120	24.65	0.0000
	Single	2.927		
Employment	Regular worker	3.067	9.36	0.0001
	Self-employed	2.866		
	Unemployed	2.938		

이희정. 2018. “청년층 계층인식 변화가 공정성 인식에 미치는 영향 분석.” 『한국사회학』 52(3): 119-164.



일원분산분석의 실제 활용

〈표 3〉 노인인구의 결혼지위 및 결혼만족도 유형에 따른 우울증세 차이

유형 구분			빈도(%)	CES-D 평균	분산분석
결혼지위 (N=4,040)	전체 (N=4,012)	혼인	2,588(64.5)	17.86	F=33.3 (p<.001)
		별거	22(0.5)	18.86	
		사별/실종/이산가족	1,362(33.9)	19.93	
		이혼	31(0.8)	21.71	
		미혼	9(0.2)	21.11	
	여성 (N=2,333)	혼인	1,084(46.5)	18.60	F=9.29 (p<.001)
		별거	16(0.7)	19.97	
		사별/실종/이산가족	1,211(51.9)	19.97	
		이혼	16(0.7)	22.25	
		미혼	6(0.3)	22.33	
	남성 (N=1,679)	혼인	1,504(89.6)	17.33	F=8.37 (p<.001)
		별거	6(0.4)	16.67	
		사별/실종/이산가족	151(9.0)	19.59	
		이혼	15(0.9)	21.13	
		미혼	3(0.1)	18.67	

이미숙. 2012. “노인인구의 결혼관계와 우울증세: 결혼지위와 결혼만족도를 중심으로.” 『한국사회학』 46(4): 176-204.



일원분산분석의 실제 활용


일원분산분석의 전형적인 표와 시각화 기법이 있다.

- citytemp 데이터에서 난방도일(heatdd)과 냉방도일(cooldd)이 센서스 지역구획(region)에 따라 다른지 여부를 검정해보자.
- 표와 시각화를 통해 그 결과를 적절히 요약해보자.
- 좋은 표를 최대한 흉내내는 연습이 필요하다.
- 시각화 기법으로 무엇이 적절할까? 반드시 시각화해야 하는 것은 아니지만 필요하다고 생각하면 넣을 수 있다.



일원분산분석의 실제 활용

	Heating degree days		Cooling degree days	
	평균	표준편차	평균	표준편차
NE	5803	743	722	238
N Cntrl	6446	1006	822	311
South	2518	1390	2327	888
West	3169	1948	973	880
전체	4426	2200	1240	938
$F(p>F)$	482.482 (<.001)		299.018 (<.001)	



일원분산분석의 실제 활용

- 또다른 연습도 해보자. `nlswork` 데이터에서 산업별(`ind_code`)로 임금(`ln_wage`) 수준이 상이한지 여부를 검정해보자. 표와 시각화를 통해 그 결과를 적절히 요약해보자.
- Stata의 `oneway`에서 앞선 변수가 종속변수이고 뒤에 오는 변수가 독립변수임에 주의하자. 이때 종속변수는 반드시 연속변수이고, 독립변수는 범주형(categorical) 변수임에 주의하자(Why?).



일원분산분석의 실제 활용

일원분산분석은 회귀분석 전체 계수의 유의성 검정에서도 사용된다.

- 이 경우 귀무가설은 “모든 회귀계수들이 0이다”로 만일 이 귀무가설을 기각하지 못한다면 모델에 포함된 어떠한 독립변수 X 로도 종속변수 Y 를 의미있게 설명하지 못함을 의미한다(Why?).
- 당연히 이 경우에는 회귀모형을 처음부터 다시 만들어야 한다.
- 회귀분석의 맥락에서 대립가설은 “적어도 하나 이상의 회귀계수는 0이 아니다” 임에 주의할 것.
- 우리는 나중에 회귀분석을 배우면서 일원분산분석이 회귀분석의 맥락에서도 다시 한번 쓰이게 됨을 확인하게 된다.



일원분산분석의 실제 활용

t 검정과 일원분산분석에는 잘 알려진 연관성이 있다.

- t 검정은 두 모집단의 **평균을 비교**하고, 일원분산분석은 여러 모집단에 걸친 **분산의 비율**을 비교한다.
- 만일 집단이 두 개만 주어졌을 때 일원분산분석을 수행하면 어떤 결과를 가져올까?
- 이 경우 일원분산분석의 귀무가설은 “모든 집단에 걸쳐 평균값이 동일하다”였으므로 이는 다시 “두 집단에 걸쳐 평균값이 동일하다”로 축소된다.
- 즉 t 검정과 같은 것이 된다. 실제로 F 값과 t 값에는 다음과 같은 관계가 있다.

$$\sqrt{F} = |t| \quad (\text{또는 } F = t^2)$$

- auto.dta에서 수입품 여부(foreign)에 따라 가격(price) 차이가 있는지 여부를 t 검정과 일원분산분석으로 함께 검정해보고, 그 차이를 살펴보자.



일원분산분석의 실제 활용

- 그렇다면 반대로 생각해서, 집단이 여러 개 있을 때 구태여 일원분산분석 대신 t 검정을 여러 번 하면 안될까?
- 결론만 말하자면 (1) 굉장히 불편하고 혼란스러울 뿐 아니라, (2) 추정상의 오류를 저지르게 될 위험이 극단적으로 커지므로 권할 수 없다.
- 먼저 t 검정을 아주 여러 번 수행하고 비교해야 하는 부담이 있다.
- 예컨대 겨우 5개의 모집단을 비교하기 위해서 t 검정을 10번이나 수행해야 한다 (Why?).
- 이것은 기하급수적으로 증가하여 6개의 모집단을 비교하기 위해서는 t 검정을 15 번이나 수행해야 한다(Why?).



일원분산분석의 실제 활용

- 게다가 이 10번의 t 검정을 수행하는 과정에서 최소 1번 이상 오류가 나타날 가능성 또한 급격히 증가한다.
- 예컨대 5% 유의확률이라면, 10번의 t 검정을 수행하는 과정에서 1회 이상의 오류 확률은 약 40%나 된다(Why?).
- **이항분포(binomial distribution)**를 통해 이 확률분포를 계산할 수 있다. 즉 발생확률 p 가 0.05인데 10번의 시행 중 사건이 전혀 발생하지 않을 확률분포는 다음과 같다.

$$1 - \binom{n}{k} p^k (1-p)^{n-k} = 1 - \binom{10}{0} \cdot 0.05^0 \cdot (1-0.05)^{10-0}$$

- 이 사실을 간단히 Stata에서 계산해보자.



χ^2 독립성 검정



비모수 통계학 개념을 먼저 이해할 필요가 있다.

- 여기서 **비모수(non-parametric)**이라는 단어는 추정할 모집단(population)의 분포에 대한 가정을 필요로 하지 않음을 의미한다.
- 일반적인 추리통계학(inferential statistics)에서는 모집단(population)의 분포에 대한 가정(e.g., 정규분포 등)을 전제로 한다.
- 하지만 이 가정은 사례 수 N 이 충분히 크면 **중심극한정리(central limit theorem)**에 의해 자동적으로 충족된다.
- 다시 말해 “모집단의 분포에 대한 가정이 필요없으면 사례 수 N 이 작아도 큰 문제를 일으키지 않는다”는 의미가 된다.
- 이로 인해 비모수 통계학은 꽤 많은 상황에서 유용하다.



χ^2 독립성 검정

χ^2 독립성 검정이 비모수 통계학의 대표 주자로 여겨진다.

- χ^2 분포는 모집단의 분산에 대한 추정/가설검정에서도 등장하지만, χ^2 독립성 검정(chi-square test of independence)에서도 자주 쓰인다.
- χ^2 분석을 통해 교차표에서 주어진 두 변수 사이에 통계적으로 유의한(statistically significant) 관계가 있는지 확인할 수 있다.
- 여기서는 이론적으로 기대된 빈도(expected frequency)과 실제 관찰된 빈도(observed frequency) 사이를 비교한다.
- 이 비교의 목적은 교차표의 두 변수, 즉 두 개의 표본(sample)이 같은 모집단에서 나온 것인지를 확인하는 것이다.



χ^2 독립성 검정

기대빈도 E 는 χ^2 분포의 독립성 가정에 따라 계산된다.

- 표준화된 자료가 아니라 원자료로 χ^2 독립성 검정을 시작한다.

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

- 성별과 종교 두 변수가 독립적이라면(=다른 모집단에서 나온 표본이라면) 곱셈법칙이 성립한다.

$$P(A \cap B) = P(A|B) \cdot P(B) = P(A) \cdot P(B)$$

- e.g., $P(\text{여자} \cap \text{종교인}) = P(\text{여자}) \cdot P(\text{종교인}) = (221/521) \cdot (165/521) \approx 0.13434$
- $n = 521$ 이므로 “여자 $\cap$ 종교인” 사건의 기대빈도 E 는 $521 \cdot 0.13434 = 69.99$ 이다.



χ^2 독립성 검정

Stata에서 관찰빈도 O 와 기대빈도 E 를 직접 계산해보자.

- 관찰빈도 O 행렬의 주변확률 정보를 이용해 옆의 기대빈도 E 행렬을 채워넣자.

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

	비종교인	종교인
남자		
여자		69.99

- 정답은 뒷 페이지에 있으니 먼저 풀어보고 확인하자.



χ^2 독립성 검정

- 이제 채워진 관찰빈도 O 와 기대빈도 E 를 꼼꼼히 비교해보자!

	비종교인	종교인	합계
남자	232	68	300
여자	124	97	221
합계	356	165	521

	비종교인	종교인
남자	204.99	95.01
여자	151.01	69.99

- 기대빈도 E 는 두 변수가 독립적이라는 가정에 입각했을 때 이론적으로 기대된 빈도였다.
- 다시 말해, 기대빈도 E 가 관찰빈도 O 와 크게 다르지 않다면 독립성 가정(=두 변수는 서로 독립적이다)는 결론에 도달한다.
- 반면, 기대빈도 E 와 관찰빈도 O 가 크게 다르다면 (애초에 세운) 독립성 가정이 틀렸다는 결론에 도달한다. 즉 두 변수는 연관되어 있었던 것이다!



χ^2 독립성 검정

지금까지 논의를 통해 χ^2 분석의 가설구조를 유추할 수 있다.

- χ^2 독립성 검정의 가설은 다음과 같다.

H_0 : 성별과 종교인 여부는 서로 독립적이다.

H_a : 성별과 종교인 여부는 서로 독립적이지 않다.

- 만일 귀무가설을 기각할 수 있었다고 할지라도 여성이 더 종교적인지 여부 등은 독립성 검정을 통해서 알 수 없다.
- 단지 “성별과 종교성이 서로 독립적”이라는 귀무가설을 통계적으로 유의하게 기각할 수 있을 뿐이다.
- 대립가설 이상의 해석을 χ^2 독립성 검정에 멋대로 덧붙이지 않도록 꼭 주의해야 한다!



χ^2 독립성 검정

이제 (가설검정을 위한) 검정통계량을 계산한다.

- 검정통계량인 χ^2 값은 다음과 같이 계산된다.

$$\chi^2 = \sum_{j=1}^J \sum_{k=1}^K \frac{(O_{jk} - E_{jk})^2}{E_{jk}}$$

- 여기서 J 와 K 는 각각 교차표의 행과 열의 수, O_{jk} 와 E_{jk} 는 각각 j 번째 행, k 번째 열의 관찰빈도 O 와 기대빈도 E 를 의미한다.
- Stata에서 직접 검정통계량 χ^2 값을 계산해 보자.



χ^2 독립성 검정

관찰빈도 O 와 기대빈도 E 가 다름을 확인하는 유의성 검정을 수행한다.

- (유의성 검정에서 사용하는) 이론적 확률분포는 확률변수 χ^2 의 분포이다.

$$\sum_{j=1}^J \sum_{k=1}^K \frac{(O_{jk} - E_{jk})^2}{E_{jk}} \sim \chi^2_{(J-1)(K-1)}$$

- 만일 귀무가설대로 $O = E$ 라면 χ^2 는 0이다. 그러나 표본에서 계산된 χ^2 값이 크다면 (그러진) χ^2 분포 위의 아주 구석진 곳에 놓일 것이다.
- 앞의 예에서는 2×2 교차표였으므로 $J = K = 2$ 다. 자유도는 $(J - 1)(K - 1) = 1$ 이다. 1의 자유도를 가진 χ^2 분포를 그린다.



χ^2 독립성 검정

Stata에서 χ^2 독립성 검정을 수행해보자.

- 옵션을 사용하면 쉽게 O_{jk} , E_{jk} , 그리고 χ^2 를 계산할 수 있다.
- 독립성 검정의 결과를 적절히 해석해보자.
- 교차표를 제시할 때는 표준화했더라도, 독립성 검정은 빈도 자료를 근거로 수행한다는 것에 주의하자.
- 앞서 골랐던 또다른 질적 변수 두 개에 관하여 χ^2 독립성 검정을 수행해보고 교차표 아래에 덧붙여보자.



χ^2 독립성 검정

χ^2 분석은 원자료가 없어도 그냥 수행할 수 있다.

- 눈치를 이미 챘을수도 있지만 생각해 보자. 기대빈도 E 와 χ^2 통계량을 계산하는데 구태여 원자료는 필요가 없다.
- 이미 만들어진 교차표에서 관찰빈도 O 만 확인할 수 있으면 충분하다.
- Stata에서도 `tabi` 명령어로 즉석에서 χ^2 독립성 검정을 수행할 수 있다.
- 물론 빈도를 사용해야 하고 표준화된 값을 근거로 χ^2 독립성 검정을 하지 않아야 한다.



연습문제



연습 1. 서울시민 여성혐오 및 여성정책에 대한 인식조사 자료에서 성별(SQ2) 및 연령대별(SQ3_1)로 총 10개의 범주를 생성하시오(e.g., “여성(30-39)”, “남성(15-19)” 등). 또한 다양한 여성혐오 표현에 대한 관대함(A3)을 모두 합산하여 그 관대함의 정도를 나타내는 합성지수를 계산하시오. 여성혐오 표현에 대한 관대함이 성별-연령대별 범주에 따라 상이한지 살펴보기 위한 유의성 검정을 수행하고, 그 차이를 시각화하고 간단히 해설하시오.

