계량분석
Correlation Analysis

김현우, PhD[1]

[1] 충북대학교 사회학과 부교수

October 12, 2026



진행 순서

1. 상관분석
2. 상관분석의 활용
3. 상관계수의 유의성 검정
4. 산점도



상관분석



상관분석

두 양적변수 사이의 관계를 살펴볼 때는 상관분석을 수행한다.

- **상관분석(correlation analysis)**은 **상관계수(correlation coefficient)**를 구하는 기법이다.
- 상관계수를 이해하려면 먼저 분산(variance)과 공분산(covariance)을 돌이켜 볼 필요가 있다.
- 먼저 분산의 식을 돌이켜보자.

$$Var(X) = \sigma_X^2 = \frac{1}{N}\sum_{i=1}^{N}(X_i - \mu)^2$$
$$= \frac{1}{N}\sum_{i=1}^{N}(X_i - \mu)(X_i - \mu)$$

- 변수가 하나 주어져 있을 때 편차(deviation)를 구해 제곱하여 분산을 구했는데, 아래처럼 살짝 바꾸면 곧바로 공분산이 된다.

$$Cov(X, Y) = \sigma_{XY} = \frac{1}{N}\sum_{i=1}^{N}(X_i - \mu_X)(Y_i - \mu_Y)$$



상관분석

- 공분산과 분산의 아이디어는 거의 똑같다! 다만 X_i 하나의 편차를 제곱하는 대신, X_i와 Y_i의 편차를 서로 곱했을 뿐이다.
- 두 변수의 편차끼리 곱할 때, 모두 양수(+)이거나 음수(-)이면 공분산은 양수(+)가 되고, 어느 한쪽이 양수(+)이고 다른 쪽이 음수(-)이면 공분산은 음수(-)가 된다.
- 엑셀에서 `COVARIANCE.P(·)` 함수로 모집단의 공분산을 구할 수 있다. 표본의 공분산은 `COVARIANCE.S(·)` 함수로 구할 수 있다.
- 공분산은 흥미로운 아이디어를 제시하고 있지만 명확한 단점이 있었다.
- $Cov(X, Y)$는 X **내부(within X)**의 분산과 Y **내부(within Y)**의 분산이 다를 수 있다는 점을 고려하지 않았으므로 그 자체로는 해석이 어려웠다.



상관분석

Karl Pearson은 공분산의 단점을 보완하는 천재적인 접근을 제시했다.

- 그는 두 변수 X와 Y의 각각의 표준편차(분산이 아니고!)를 분모로 각각 나누어줌으로서 X 내부의 분산과 Y 내부의 분산이 다를 수 있는 가능성을 제거하고 표준화를 이루었다.
- 뿐만 아니라, 일부러 분산이 아닌 표준편차로 나누어주었기 때문에 표준화된 값은 절묘하게 -1과 1사이로 두 변수가 얼마나 강한 상관관계를 가지고 있는지 보여준다.
- 이것이 이른바 **피어슨의 적률상관계수(Pearson's product-moment correlation coefficient)**이다. 줄여서 상관계수 ρ다. ρ는 rho라고 읽는다.

$$\rho = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$



상관분석

상관계수의 해석은 매우 간단하지만 혼동하지 않도록 주의해야 한다.

- 상관계수는 반드시 -1과 1사이에 놓인다. $\rho = 0$는 **무상관(no correlation)**, $\rho = 1$은 **완전상관(perfect correlation)**이라고 한다.
- 상관계수가 0보다 크면 두 변수는 **서로 같은 방향(정방향)**으로 움직인다. 즉 "X가 증가하면 Y도 증가한다."
- 상관계수가 0보다 작으면 두 변수는 **서로 다른 방향(역방향)**으로 움직인다. 즉 "X가 증가하면 Y는 감소한다."
- 왜 이렇게 해석되는지 공분산의 분자 $\sum(x - \mu_X)(y - \mu_Y)$를 잘 들여다보자.
- 상관계수가 1에 가까울수록 (그리고 -1에 가까울수록) 두 변수는 더욱 밀접한 상관관계를 갖게 된다.



상관분석

- 해석할 때는 0과 1 사이를 사분위수로 나누고 각각 리커트 4점 척도로 의미를 부여한다. 물론 0과 -1 사이에서도 마찬가지이다.

상관계수	상관관계의 해석
[-1, -0.75]	매우 강한 역방향
[-0.75, -0.5]	다소 강한 역방향
[-0.5, -0.25]	다소 약한 역방향
[-0.25, 0]	매우 약한 역방향
[0, 0.25]	매우 약한 정방향
[0.25, 0.5]	다소 약한 정방향
[0.5, 0.75]	다소 강한 정방향
[0.75, 1]	매우 강한 정방향



상관분석

공분산과 상관계수를 Stata에서 계산해보자.

- 상관계수를 구하기 위해 `correlate` 명령어를 사용할 수 있다.
- 공분산을 구하기 위해서는 같은 명령어 뒤에 `cov`라는 옵션을 붙이면 된다.
- 변수에 적당한 상수를 곱하거나 나눈 뒤, 공분산과 상관계수를 다시 계산하여 비교해보자.
- 위의 상관계수 공식을 사용하여 `correlate` 명령어에 의존하지 말고 직접 상관계수를 계산해보자.



상관분석의 활용



상관분석의 활용

상당히 많은 논문들이 기술통계의 일환으로 상관계수행렬을 제시한다.

- 상관계수행렬은 단순히 한 변수와 다른 변수 사이의 상관관계를 보여주는 것을 넘어 이른바 **다중공선성(multicollinearity)**이 존재하는가를 살펴볼 때도 (잠재적으로) 유용하다. 이에 관해서는 나중에 다루기로 한다.
- 상관계수행렬은 논문 한 페이지를 통째로 잡아먹기 때문에 근래에는 보고하지 않는 경우도 많다.
- 그러나 이 행렬은 이른바 **메타분석(meta analysis)**에서 종종 유용한 정보를 제공하는 경우가 있으므로 사정이 허용된다면 온라인 부록(online appendix)으로라도 보고하는 편이 바람직하다.



상관분석의 활용

〈표 2〉 주요 변인들 간 피어슨 단순 상관계수

	1	2	3	4	5
1. 혼전성수용도	-				
2. 혼외성수용도	.34***	-			
3. 법회·예배참석	-.22***	-.09***	-		
4. 기도빈도	-.18***	-.10***	.63***	-	
5. 기타활동 참석	-.15***	-.07**	.68***	.53***	-
6. 자기평가종교성	-.17***	-.06**	.58***	.52***	.44***
7. 본질적종교성	-.20***	-.09***	.58***	.53***	.44***
8. 비본질적종교성	-.02	-.04	.35***	.33***	.30***
9. 연령	-.41***	-.09***	.14***	.15***	.07**
10. 교육수준	.29***	.09***	-.01	-.02	.04

※ 유의수준: ***p 〈0.001 **p 〈0.01 *p 〈0.05

〈표 2: 계속〉 주요 변인들 간 피어슨 단순 상관계수

	6	7	8	9
6. 자기평가종교성	-			
7. 본질적종교성	.56***	-		
8. 비본질적종교성	.40***	.34***	-	
9. 연령	.14***	.16***	.00	-
10. 교육수준	-.05*	-.08**	.09***	-.62***

※ 유의수준: ***p 〈0.001 **p 〈0.01 *p 〈0.05

한내창. 2010. "종교와 성태도 간 관계." 『한국사회학』 44(5): 114-138.



상관분석의 활용

- 그런데 이렇게 여러 변수들의 상관계수를 보여줄 때, 결측치(missing value)가 포함되어 있을 때 그 처리 방식이 조금 복잡해진다.
- (1) 한 변수에라도 결측치가 있다면 그대로 버리는 방식과 (2) 그 변수와 다른 변수와의 상관계수를 계산할 때만 버리는 방식으로 나뉜다.
- 후자는 **쌍별(pairwise)** 상관분석이라고 부른다(그리고 좀 더 많이 쓰이는 것 같다). Stata에서 `pwcorr`로 수행할 수 있다.
- 상관계수행렬을 만들때는 `correlate`와 `pwcorr`가 각각의 장단점을 갖고 있다.



상관계수의 유의성 검정



상관계수의 유의성 검정

상관계수에 대해서도 다음과 같이 유의성 검정을 할 수 있다.

- 상관계수에 대해서는 무조건 양측검정을 수행한다.

$$H_0 : \rho = 0$$
$$H_a : \rho \neq 0$$

- t 검정을 통해 유의확률(p-value)을 구한다. 단, t 분포의 꼴은 $(n-2)$의 자유도로 결정된다(Why?).

$$t = \frac{\hat{\rho} - \rho}{se_\rho} = \frac{\hat{\rho}}{\sqrt{\frac{1-\hat{\rho}^2}{n-2}}} = \hat{\rho}\sqrt{\frac{n-2}{1-\hat{\rho}^2}}$$

- 즉 (1) 추정된 상관계수 $\hat{\rho}$가 커지고 (2) 사례수 n가 많아질수록 검정통계량 t 값이 커져 귀무가설을 기각하기 쉬워진다.



상관계수의 유의성 검정

소표본만 벗어나도 상관계수의 유의성 검정에 사실 큰 의미가 없다.

- 위 식을 곰곰히 들여다보면 눈치챌 수 있는 부분인데, 예컨대 $n = 50$ 정도로 작은 표본에서 $\hat{\rho} = 0.3$ 정도의 값만 나와주어도 이미 95% 신뢰수준에서 통계적으로 유의하다(Why?).
- 오늘날 경험적 사회과학 연구에서 $n = 50$ 짜리 연구는 거의 없다. 게다가 $\hat{\rho} = 0.3$는 거의 없는 수준의 상관관계에 불과하다.
- Stata에서는 `pwcorr`의 경우 `sig` 옵션을 통해 유의확률을 알 수 있다. 이때 `star(0.05)`와 같은 옵션을 통해 5% 수준에서 유의한가를 알려주는 별을 붙일 수도 있다.



산점도

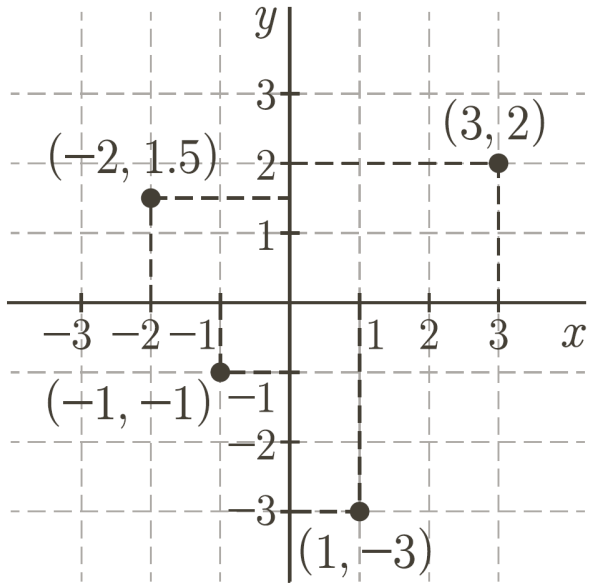


산점도

산점도와 상관계수는 늘 함께 생각하자!

- **산점도(scatterplot)**란 두 양적변수가 주어졌을 때, 이를 **벡터(vector)** (X, Y)로 파악하여 **데카르트 좌표계(Cartesian coordinates)** 위에 뿌린 것이다.

ID	MATH	ENG
1	-2	1.5
2	3	2
3	-1	-1
4	1	-3



산점도

상관분석을 수행할 때는 반드시 함께 산점도를 그려야 한다.

- 상관계수는 두 양적변수 간 **선형적 관계의 강도(strength of the linear relationship)**를 보여준다.
- 그러나 현실자료에서는 두 변수가 (U자형, 역U자형, W자형 등) **비선형적(non-linear)**일 수도 있다. 그 중 **곡선형(curvilinear)**인 경우도 흔하다.
- 이때 기울기(slope)는 상관계수의 본질이 아니다. 오히려 관찰값 사이의 흩어짐(산포경향)이 상관계수의 본질이다(Why?). 사실 기울기는 회귀계수의 본질이다(이에 관해서는 나중에 배우게 된다).
- 산점도는 극단치(outliers)를 발견할 때도 매우 유용하다.
- 산점도에는 늘 **적합선(fitting line)**을 함께 그려넣자.



산점도

- Stata에서는 `graph twoway scatter` 명령어로 수행할 수 있다.
- 마커(marker)를 꼭 동그라미로 해야 하는 것은 아니고, 직접 레이블을 붙일 수도 있다.

