계량분석
Introduction to Multiple Regression

김현우, PhD[1]

[1] 충북대학교 사회학과 부교수

October 19, 2026



진행 순서

1. 다중회귀모형 입문
2. 위계적 회귀분석
3. 부분효과의 의미
4. 누락변수 편의



다중회귀모형 입문



다중회귀모형 입문

실제 업무나 연구에서는 다중회귀모형을 사용한다.

- **단순회귀모형(simple regression model)**에서는 오로지 독립변수 X와 종속변수 Y, 딱 두 개의 변수만 고려하였다.

$$Y = \beta_0 + \beta_1 X + \epsilon$$

- 반면, (종속변수는 여전히 1개지만) 모형 안에 k개의 독립변수가 투입된 경우를 **다중회귀모형(multiple regression model)**이라고 부른다.

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + ... + \beta_k X_k + \epsilon$$

- k개의 독립변수를 모형에 투입했다면 여러 영향력은 각각에 해당되는 변수 안으로 나뉘어 흡수된다.
- 그러므로 다중회귀분석은 (다른 변수의 영향력으로부터 독립된) 특정 변수의 **순효과(net effect)** 또는 **부분효과(partial effect)**를 살펴보는데 유리하다.



다중회귀모형 입문

- 가령 임금(ln_wage)을 종속변수로, 나이(age)와 교육연수(educ)를 독립변수로 하는 회귀모형을 세웠다고 하자.

$$\texttt{ln_wage} = b_0 + b_1 \texttt{age} + b_2 \texttt{educ} + e$$

- 다중회귀분석을 통해 "나이(age)의 효과를 통제했을 때(즉 같은 나이일 때)" 교육연수(educ)가 한 단위 변화하면 임금(ln_wage)이 얼마만큼 변화하는지 살펴볼 수 있다.
- 이렇게 "다른 요소들이 같다고 할 때(all other things being equal)"라는 표현에 대하여 경제학에서는 ceteris paribus 라는 라틴어를 사용하기도 한다."



다중회귀모형 입문

다중회귀분석을 수행할 때는 변수의 사전 체크에 주의를 기울여야 한다.

- 여러 개의 독립변수를 모형에 한꺼번에 투입하다보면 하나하나를 꼼꼼하게 살펴보지 않고 그냥 대충 집어넣는 경우가 많다. 이것은 매우 위험하다!
- 개별 변수의 **척도(scale)**가 어떻게 구성되어 있는지, **분포(distribution)**는 어떠한지, **극단치(outlier)**는 없는지, **결측치(missing values)**가 있는지 등을 반드시 살펴보아야 한다.
- 단순회귀분석에 비해 **표본 크기(sample size)**가 얼마나 달라지는지도 확인해야 한다 (Why?).
- Stata에서 `summarize`, `tabulate`, `codebook`, `inspect`, `histogram`, `graph` 등의 명령어를 활용해 변수를 살펴본다. 또 `edit`로 여러 변수들이 각각 어떤 구조 속에 있는지도 충분히 감을 얻어야 한다.
- 특정한 변수 별로 정렬(sort)하여 데이터를 살펴보는 것도 유용하다. Stata에서 `sort`는 그런 기능을 제공한다.



다중회귀모형 입문

다중회귀모형의 해석에 친숙해져야 한다.

- 다른 변수들의 영향력을 통제하였을 때, 특정 독립변수 X의 값이 한 단위 변화(a unit change)하면 회귀계수 b만큼 종속변수 Y가 변화한다.
- 가령 `age`와 `ttl_exp`이 `ln_wage`에 영향을 미친다는 회귀모형을 세우고 보통최소자승법(OLS)에 따라 b_0, b_1, 와 b_2"를 다음과 같이 추정하였다고 하자.

$$ln_wage_i = 1.55 - 0.0065age_i + 0.050ttl_exp_i$$

- "직무경험의 효과를 통제하였을 때, 연령이 한 살 증가하면 로그 임금은 평균적으로 0.0065만큼 감소한다."
- "연령의 효과를 통제하였을 때, 직무경험이 한 단위 증가하면 로그 임금은 평균적으로 0.050만큼 증가한다."
- "연령과 직무경험이 모두 0일 때의 로그 임금은 평균적으로 1.55이다."



다중회귀모형 입문

다중회귀분석에서는 보통 변수들의 역할을 구분한다.

- 우리는 종종 **관심변수(variables of interest)**와 **통제변수(control variables)**를 구별한다.
- 우리의 연구문제에 따라 "교육수준이 임금에 미치는 영향"에 관심이 있다면 교육수준이 우리의 관심변수가 되고, 나머지 (잠재적으로 임금에 영향을 미칠 수 있는) 다른 모든 독립변수들은 이른바 통제변수로 취급된다.
- 하지만 이것은 어디까지나 주관적으로 부여하는 의미일 뿐이고, 회귀모형 안에서 변수들의 지위는 평등하다(Why?).
- 논문에서는 통제변수가 갖는 실질적 함의에 대해서 보통 너무 깊게 논의하지 않는다.



위계적 회귀분석



위계적 회귀분석

단순한 회귀모형에서 복잡한 회귀모형으로 점진적으로 발전시켜야 한다.

- **위계적 회귀분석(hierarchical regression analysis)**을 통해 회귀계수 및 유의성 여부의 변화를 관찰할 수 있다.
- 단계적으로 독립변수를 모델에 투입하여 점차 회귀계수와 유의성이 변화하는 모습을 관찰할 수 있다. 이때 어떤 변수를 어떤 순서대로 넣는가는 전적으로 연구자의 몫이다.
- 독립변수를 넣는 순서와 어떤 것을 넣는가를 기계적으로 결정하는 방식이 꽤 오래 전부터 지금까지 몇몇 교과서에서 다루어져 왔으나 사회학에서는 덜 중요한 것 같다.
- 단번에 수많은 독립변수를 넣어 근사한 회귀모형을 만들고 싶은 유혹에 빠지기 쉽지만, 하나하나 변수를 넣어가면서 차분히 회귀모형을 설계하는 것이 바람직하다.



위계적 회귀분석

- 특히 독자는 다른 **모형 설정(model specification)**의 가능성에 대해 아는 바가 없기 때문에 연구자는 이에 관한 정보를 충실히 보여주어야 한다(Why?).
- 논문에서 모두 보고하지 않더라도 수많은 대안모형들을 만들어 살펴보고, 변수 투입에 따른 변화를 꼼꼼히 살펴보아야 한다.
- 특히 기존 문헌에서 중요하게 보고되었던 독립변수가 빠지면 심사자에게 지적을 받기 쉽다. 그러므로 "(이를 고려해보았지만) 연구의 발견에는 큰 변화가 없었다" 하는 식으로 보고해야 할 수도 있다.
- 참고로 위계적 회귀분석(hierarchical regression analysis)과 **위계적 선형모형 (hierarchical linear model)**은 서로 다른 것이다. 위계적 선형모형은 이른바 **다층모형(multilevel model)**을 의미하며 지역/조직/시간 속에 내포된 개체 (individuals)를 분석할 때 유용하다.



위계적 회귀분석

〈표 4〉 고3 학업성취도에 대한 회귀분석의 결과 1

	모형 1		모형 2		모형 3	
	계수	표준오차	계수	표준오차	계수	표준오차
비일반고[1]	.062**	.179	.017	.155	.019	.154
중3 학업성취도			.509***	.008		
남성[2]					-.009	.107
자아존중감					.165***	.014
학습시간					.091***	.008
학습태도					.355***	.013
교사-학생 관계					.046*	.019
가구소득					.056**	.114
부모 관리/전문직[3]					.034	.116
부모 대졸 이상[4]					.055**	.123
부모 감독					-.005	.035
부모 애정					.009	.029
4년제 대학교 졸업 부모 기대[5]					.082**	.194
대학원 졸업 부모 기대[5]					.099***	.253
아직 정해지지 않은 부모 기대[5]					.028	.243
상수	8.952***	.065	6.498***	.126	-.819	.985
사례수	1,361		1,361		1,361	
결정계수	.004		.261		.285	

***p〈.01, **p〈.05, *p〈.1.
계수는 표준화 회귀계수. 단, 상수의 계수는 비표준화 회귀계수.
기준집단: 1 = 일반고; 2 = 여성; 3 = 부모 비전문/관리직; 4 = 부모 고졸 이하; 5 = 2-3년제 전문대학 졸업 이하 부모 기대.



위계적 회귀분석

Stata에서 연습해보자.

- 임금(`ln_wage`)을 설명하기 위해 (1) 나이(`age`)을 독립변수로 한 회귀분석을 수행해보자.
- 뒤이어 (2) 나이와 직무경험(`ttl_exp`)을 넣은 회귀분석을 수행해보자.
- 마지막으로 (3) 나이, 직무경험(`ttl_exp`), 노조원 여부(`union`)을 넣은 회귀분석을 수행해보자.
- 표로 만들어 이 모형들을 비교해보자. 계수와 유의성은 어떻게 변화하는가? 왜 그런가?



위계적 회귀분석

- 하나의 변수에라도 결측치가 있다면 그 행(row)을 아예 모두 삭제할 수 있다. 이것을 **목록별 삭제(listwise deletion)**이라고 부른다.
- 결측치가 전반적으로 적다면 목록별 삭제가 큰 문제를 일으키지 않는다.
- 특히 다중회귀모형에서 새로운 변수를 넣기 때문에 그보다 단순한 모형(가령 단순회귀모형이나 투입된 변수가 적은 다중회귀모형)과 관찰값의 수가 달라질 수 있다. 이렇게 되는 경우를 일단 피하도록 하자.
- 보다 복잡한 모형 안에 내포될 수 있을 때 이를 **내포모형(nested model)**이라고 부른다.



위계적 회귀분석

- 두 모형 사이에 사용된 표본이 일치할 때만 내포관계를 따질 수 있다!
- 내포관계일 때만, 아래 모형 (1b)에서 $w_2 = 0$이라는 **제약(constraint)**이 붙는다면, $b_0 = w_0$ 그리고 $b_1 = w_1$이 성립한다.

$$Y = b_0 + b_1 X_1 + e \tag{1a}$$

$$Y = w_0 + w_1 X_1 + w_2 X_2 + e \tag{1b}$$

- 내포관계 없이는 이런 관계가 성립하지 않는다(Why?).



위계적 회귀분석

다중회귀분석 결과를 단순회귀분석처럼 해석해보자.

- 사실 종속변수는 관심변수 뿐 아니라 다른 변수들에 의해서도 함께 영향을 받는다. 그러므로 관심변수의 변화에만 집중하면 곤란하다. 통제변수도 살아움직이며 종속변수에 끊임없이 영향을 미치기 때문이다.
- 따라서 통제변수들의 영향력을 일단 고정(fix)시켜 놓고, 관심변수와 종속변수의 연관성을 살펴보면 편리하다!
- 어떤 변수를 대표하는 값은 아무래도 평균(mean)이다. 즉 통제변수들을 각각의 평균에 고정시켜 놓고, 관심변수가 변화함에 따라 $\widehat{Y}$이 달라지는 모습에 집중하면 단순회귀분석처럼 해석할 수 있게 된다(Why?).



위계적 회귀분석

- 만일 `ttl_exp`이 관심변수라면 다음과 같이 `age`을 표본평균에 고정시킨다.

$$\texttt{age}_i = \overline{\texttt{age}}$$

- 이제 `ttl_exp`의 변화에 따른 `ln_wage`의 차이를 예측할 수 있다.

$$\begin{aligned} E(\texttt{ln_wage}) &= 1.236 - 0.005\overline{\texttt{age}} + 0.050\texttt{ttl_exp} \\ &= 1.236 - 0.005 \cdot 29.05 + 0.050\texttt{ttl_exp} \\ &= 1.091 + 0.050\texttt{ttl_exp} \end{aligned}$$

- 일단 방정식을 단지 두 변수 사이의 관계로 축약했다면 그래프도 그릴 수 있다.
- Stata에서는 `margins`와 `marginsplot`을 사용한다. 이 명령어들의 옵션과 그래프 꾸미는 법을 제법 연습해야 한다.



부분효과의 의미



부분효과의 의미

회귀분석의 중요한 가정 가운데 하나는 완전모형설정이다.

- 종속변수에 영향을 미치는 모든 독립변수가 온전하게 측정되어 회귀모형 안에 투입되어 있다는 가정일 **완전모형설정(perfect model specification)**이라고 부른다.
- 회귀모형이 완전하게 설정되어야만, 어떤 독립변수의 종속변수에 대한 효과는 해당 **편회귀계수(partial regression coefficient)** 안으로 온전히 고립시킬 수 있다 (isolate).



부분효과의 의미

- 단순회귀모형에서 보통최소자승(OLS)에 따라 회귀계수를 구하면 다음과 같다.

$$b = \frac{Cov(X, Y)}{Var(X)}$$

- 한편 다중회귀모형에서는 회귀계수가 다음과 같다.

$$b = \frac{Cov(\tilde{X}, Y)}{Var(\tilde{X})}$$

- 이때 $\tilde{X}$는 다른 변수와 겹치지 않는 X만의 부분효과를 뜻한다(벤 다이어그램으로 상상해보자).
- 가령 연령과 직무경력의 임금에 대한 효과는 일정 부분 겹치지만 각자 나름의 순효과 내지 부분효과가 있기 마련이다!



부분효과의 의미

수학적으로 검토하는 대신, Stata에서 이 원리를 간단히 실습해보자.

- `lifeexp` 자료에서 인구증가율(`popgrowth`)과 1인당 GNP(`gnppc`)의 두 독립변수로 기대수명(`lexp`)을 설명하고자 한다(벤 다이어그램을 그려보자).
- 이때 `gnppc`의 편회귀계수를 계산해보자:

  (1) 분자는 `popgrowth`와 겹치지 않는 `gnppc`의 일부분 $\tilde{X}$와 종속변수 `lexp` 사이의 공분산이다.
  (2) 분모는 `popgrowth`와 겹치지 않는 `gnppc`의 일부분 $\tilde{X}$의 분산이다.
- 이때 `popgrowth`와 겹치지 않는 `gnppc`의 일부분 $\tilde{X}$는 **부속회귀모형(auxiliary regression model)**을 추정하고 그 잔차(residual)를 통해 얻는다(Why?).
- 이렇게 계산된 값은 다중회귀계수에서 계산된 `gnppc`의 실제 편회귀계수와 일치한다.



누락변수 편의



누락변수 편의

앞서 설명과는 달리 완전모형설정이 위배된다면 어떻게 될까?

- 만일 (가정과는 달리) 그 변화를 측정하는 변수가 회귀모형 안에 적절히 고려되지 않았다면, 그 특정 요인의 변화는 (1) 다른 변수를 통해서 혹은 (2) 잔차 e을 통해서 종속변수에 영향을 미치게 된다.
- 결국 빠진 변수로 인해 종속변수에 대한 특정 독립변수의 순효과는 어느 정도 오염되었다고 할 수 있다.
- 그 오염된 정도를 **누락변수 편의(omitted variable bias; OVB)**라고 부른다.



누락변수 편의

Stata에서 누락변수 편의의 크기를 실제로 추정해보자.

- `nlswork` 자료에서 가상의 자료를 만들어 완전모형을 갖춘 회귀분석을 수행해보자. 이때 얻은 회귀계수는 말하자면 "정답"이다(Why?).
- 이제 그 중 하나 이상의 변수를 제외하고 회귀분석을 수행해보자. 회귀계수와 유의확률은 어떻게 달라졌나?



누락변수 편의

완전모형설정은 물론 현실적으로 거의 불가능하다.

- 누락변수 편의(OVB)는 그럴듯한 통제변수 몇 개를 집어넣으면 자동적으로 해소되는 그런 간단한 문제가 아니다.
- 사회 현상의 복잡성을 고려한다면 실증연구에서 완전모형설정은 사실상 불가능하다.
- 게다가 때로는 명백히 종속변수에 영향을 미치리라고 예상되는 요인이 있지만, 그것을 **측정할 수 없는(unobservables)** 경우도 있다(Why?).
- 그러므로 누락변수 편의는 언제나 사회과학 연구의 타당성을 위협한다. 우리는 기존문헌을 꼼꼼하게 살피고 이론적 통찰력에 힘입어 변수를 구성해야 한다.

