계량분석
Multiple Regression in Practice

김현우, PhD[1]

[1] 충북대학교 사회학과 부교수

October 19, 2026



진행 순서

1. 표준화 회귀계수
2. 모형의 적합도
3. 다중회귀분석의 실제 활용
4. 연습문제



표준화 회귀계수



표준화 회귀계수

여러 독립변수 중 어떤 변수가 가장 강력한 영향요인인지 궁금할 수 있다.

- 어떤 독립변수가 종속변수를 가장 잘 설명하나? 회귀계수의 크기만 보고 이것을 판단할 수 없다(Why?).
- 이는 각 독립변수의 표준편차가 다르기 때문이다. 어떤 변수는 겨우 [1,10] 사이에 놓인 반면, 어떤 변수는 [-9999,9999] 사이에서 변화할 수 있다.
- 그러므로 비교를 위해서는 회귀계수 b를 **표준화(standardization)**해야 한다.
- 표준화된 회귀계수를 β로 표현하는데 이를 모회귀계수와 혼동하지 않도록 주의한다.



표준화 회귀계수

- 몇 가지 표준화 방식이 있는데, 가장 널리 사용되는 것은 다음의 **전체 표준화 베타계수 (fully standardized beta coefficients)**이다.

$$\beta_k^* = \frac{s_{X_k}}{s_Y} b_k$$

- **원회귀계수(raw coefficient)**에 독립변수/종속변수의 표준편차 비율 s_X/s_Y 를 곱하여 구하는데, 공식 자체의 의미를 꼼꼼히 살펴보자.
- 추정된 베타계수의 크기를 보고 곧바로 여러 독립변수들 사이에서 상대적 영향력을 비교할 수 있다(Why?).



표준화 회귀계수

- 원회귀계수 b의 경우 "X가 한 단위 변화할 때, Y는 b 만큼 변화한다"로 해석했었다.
- 베타계수 β의 해석은 조금 특별하다: "X가 1 표준편차만큼 변화할 때, Y는 β^* 표준편차만큼 변화한다."
- 원회귀계수는 자료 본래의 단위를 사용하지만, 베타계수에서는 표준편차를 단위로 사용하여 해석한다(Why?).
- Stata에서는 `beta` 옵션으로 이를 구할 수 있다.
- 사회학 분야의 여러 권위있는 저널을 살펴보면, 표준화된 베타계수는 예전에 비해 그다지 인기가 없는 듯 하다.



모형의 적합도



모형의 적합도

이제 자신의 회귀모형을 평가해보자.

- 우리가 모형(model)을 세워 그것을 현실 데이터에 맞추어(fit) 본 이상, 이것이 얼마나 잘 맞는가를 말할 수 있어야 한다. 이것이 모형의 자료 **적합도(goodness-of-fit)**이다.
- 크게 세 가지 적합도 지표(goodness-of-fit indices)를 공부한다:

  (1) **결정계수(coefficient of determination)** 또는 R^2
  (2) **일원분산분석(one-way ANOVA)**
  (3) **제곱근평균제곱오차(root mean square error; RMSE)**.
- 어느 한 가지 지표에만 맹목적으로 의존하지 않고 모든 지표들을 균형있게 살펴보면서, 자신이 세운 모형이 얼마나 자료에 잘 맞는가를 확인해야 한다.
- 여러 적합도 지표에 근거하여, 여러 가지 모형들을 비교 평가할 수도 있다.



모형의 적합도

첫번째로 결정계수를 간단히 살펴보자.

- 주어진 자료에 **전체 변량(total variation)**이 있다면, 이것은 (모형에 의해) **설명된 변량(explained variation)**과 (그렇지 못하고) **남은 변량(residual variation)**의 합이라고 분해될 수 있다.

$$\sigma^2_{total} = \sigma^2_{explained} + \sigma^2_{residual}$$

- 그렇다면 설명된 변량 $\sigma^2_{explained}$와 전체 변량 σ^2_{total}의 비율은 모형의 높은 설명력을 의미한다고 볼 수 있다.

$$R^2 = \frac{\sigma^2_{explained}}{\sigma^2_{total}} = 1 - \frac{\sigma^2_{residual}}{\sigma^2_{total}}$$

- 그러므로 결정계수 R^2는 설명된 변량과 전체 변량의 비율이므로 0과 1 사이에 놓인다. 1에 가까울수록 모형은 높은 적합도를 보인다고 할 수 있다.
- 만약 R^2가 0.45라면 "이 회귀모형은 주어진 자료의 전체 변량의 45%를 설명한다"고 해석할 수 있다.

모형의 적합도

앞서 설명한 세 변량들은 어떻게 정의되는가?

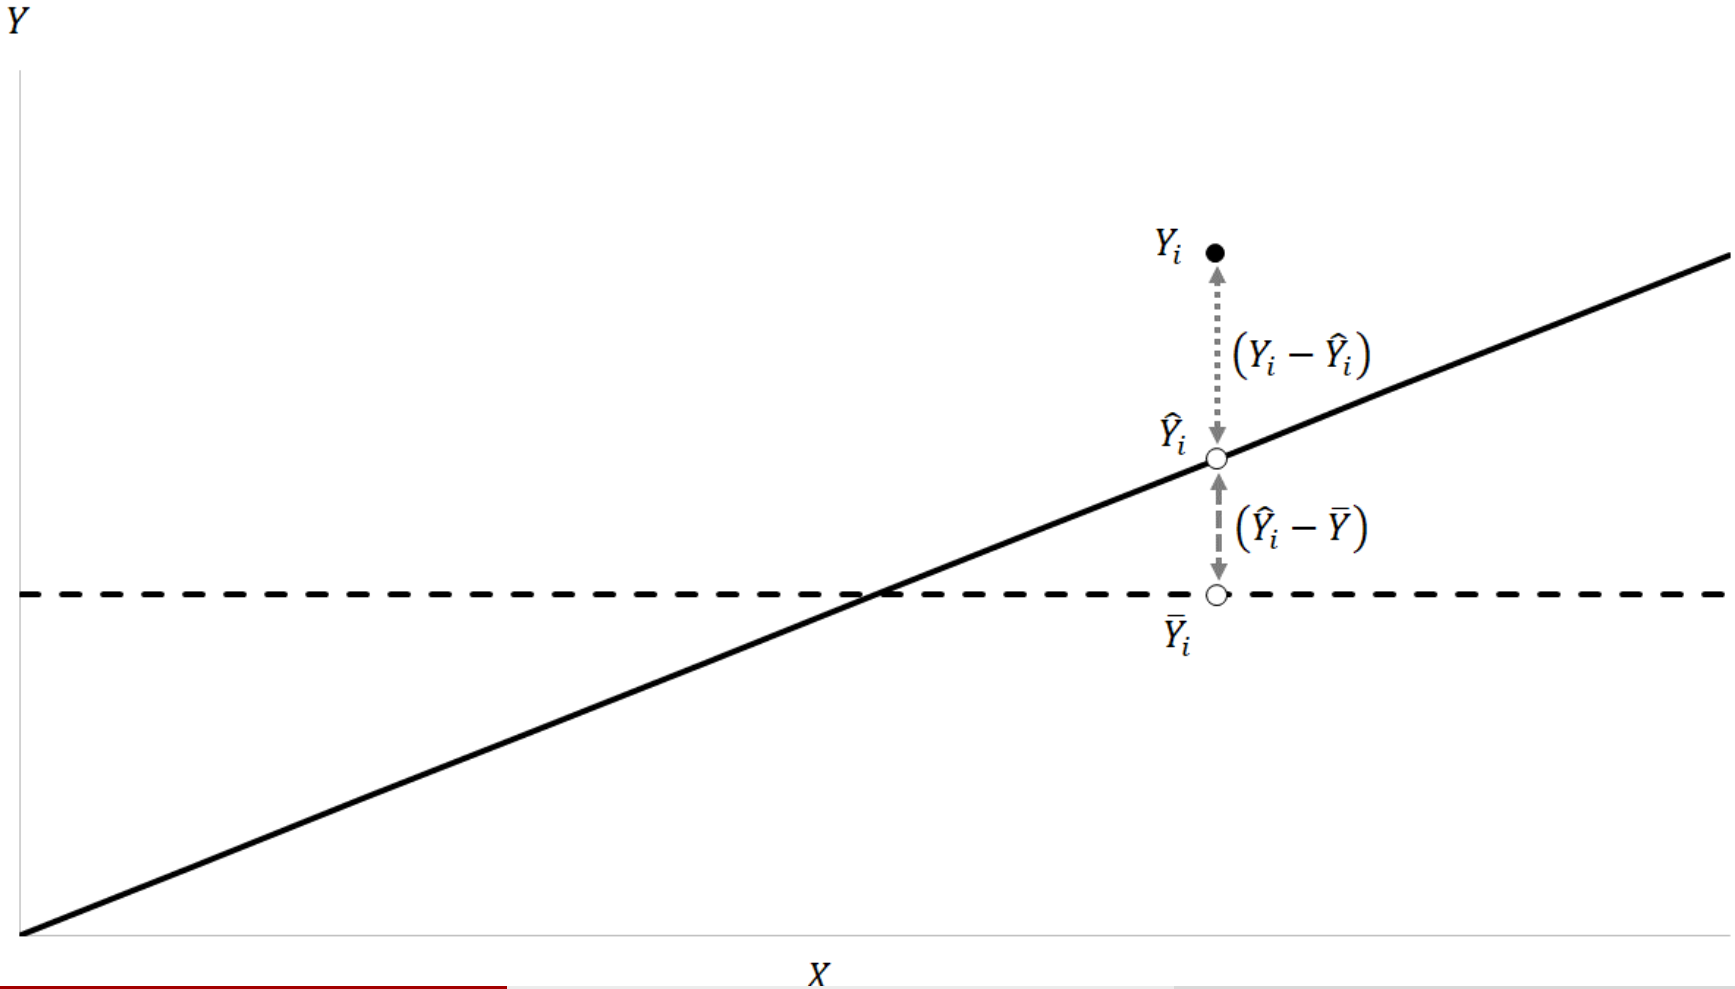
- "독립변수 X가 없을 때 종속변수 Y를 가장 잘 예측하는 요소는 무엇일까?"
- 이 질문은 생각보다 매우 중요하다! 그것은 바로 종속변수의 평균($\bar{Y}$)이다(Why?). 우리는 사실 학부 시절 이른바 **중심성향(central tendency)**에 관해 공부하면서 이것을 은근슬쩍 배웠다.
- 이 원리는 우리에게 중요한 원칙 하나를 제공한다: "어떤 모형을 세우던지 최소한 종속변수의 평균($\bar{Y}$)보다는 나은 설명력을 보여야 한다."
- 종속변수의 평균 $\bar{Y}$은 일종의 기준점이자 최소한의 바닥이다. 한편 종속변수의 실제 값(Y_i)은 일종의 이상점이자 최고의 천장이다.
- (직관적으로 설명한다면) 모형의 예측값 $\hat{Y}_i$은 Y_i와 $\bar{Y}$ 사이 어딘가 놓여야 한다.



모형의 적합도

- (아주 엄밀하지는 않지만) 그림을 통해서 우리는 총변량이 “설명된 변량”과 “잔여 변량”의 합임을 직관적으로 이해할 수 있다.

$$(Y_i - \bar{Y}) = (Y_i - \widehat{Y}_i) + (\widehat{Y}_i - \bar{Y})$$



모형의 적합도

- 우리는 이제 **제곱합(Sum of Squares; SS)** 개념을 가지고 다음의 공식에 도달할 수 있다.

$$SS_{Total} = SS_{Explained} + SS_{Residual}$$

$$\sum (Y_i - \bar{Y})^2 = \sum (Y_i - \hat{Y}_i)^2 + \sum (\hat{Y}_i - \bar{Y})^2$$

- 당연히 R^2에 관해서도 정의할 수 있다.

$$R^2 = \frac{SS_{Explained}}{SS_{Total}} = \frac{\sum (Y_i - \hat{Y}_i)^2}{\sum (Y - \bar{Y})^2}$$

- 아까 그림을 통해 되새겨보면, Y_i에 더 가까운 위치에 $\hat{Y}_i$가 놓일수록 R^2 역시 높으리라고 추측할 수 있다.



모형의 적합도

다중회귀분석에서는 조정결정계수를 사용하기도 한다.

- 우리는 R^2가 모형의 높은 설명력 내지 데이터 적합도를 의미함을 배웠다.

$$R^2 = \frac{SS_{explained}}{SS_{total}}$$

- 다중회귀분석에서는 **보정된 결정계수(adjusted R^2)**를 쓸 수도 있다.

$$\text{adjusted } R^2 = R^2 - \frac{k(1-R^2)}{n-k-1}$$

(k는 독립변수의 수)

- 위 공식을 암기하기보다 내부를 뜯어보면서 이해하자.



모형의 적합도

- 변수를 더 많이 사용할수록 두 결정계수 사이의 차이는 점점 벌어진다는 점이 알려져 있다.
- 그러므로 다중회귀모형 안에 변수를 많이 사용한다면 보정된 결정계수의 사용이 더 바람직할 수도 있다.
- 실험삼아 이론적으로 쓸데없는 변수(예컨대 난수)도 독립변수로 넣어보자.
- `R-squared`는 조금 더 증가하지만 `Adj R-squared`는 호락호락하게 증가하지 않는다 (심지어 감소하기도 한다).



모형의 적합도

결정계수에 대해 추가로 알아둘 만한 것들이 있다.

- 첫째, 결정계수가 작다는 것이 무엇을 뜻하는지 생각해보자. 그것을 크게 만드는 것이 사회과학연구의 목적이 아닐 수도 있다(Why?).
- 둘째, 결정계수의 기호가 R^2 인 것은 우연이 아니다. 모상관계수 ρ의 추정량인 표본상관계수 r은 결정계수 R^2 의 제곱근이기 때문이다(수학적인 증명 대신 Stata 에서 확인해보자).
- 만약 회귀모형에서 아래와 같이 상수 b_0가 포함되어 있지 않다면, 일반적인 결정계수 공식은 더이상 사용할 수 없다(증명 생략).

$$Y_i = b_1 X_i + e_i$$



모형의 적합도

두번째인 일원분산분석 역시 회귀모형의 적합도와 관련된다.

- 다중회분석에서 수행하는 일원분산분석의 가설구조는 다음과 같다.

$$H_0 : \beta_1 = \beta_2 = ... = \beta_k = 0$$
$$H_a : (\beta_1 \neq 0) \text{ or } (\beta_2 \neq 0) \text{ or } ... \text{ or } (\beta_k \neq 0)$$

- "이 모형은 완전히 쓸모없다" 라는 귀무가설을 기각하지 못한다면, 이때 설정한 모형은 완전히 무의미한 것이다(Why?).



모형의 적합도

- 단순회귀분석에서 사용된 일원분산분석의 귀무가설은 $H_0 : \beta_1 = 0$이므로 회귀계수의 t 값의 제곱과 같다(Why?).
- 일원분산분석의 검정통계량 F값은 다음과 같다. 단 k는 독립변수의 수를 의미한다.

$$F_{(k,n-k-1)} = \frac{MS_{model}}{MS_{residual}} = \frac{SS_{between}/k}{SS_{within}/(n-k-1)}$$

- 검정통계량 F 값이 클수록 유의확률이 작아져(Why?) 귀무가설을 기각하기 쉬워진다.



모형의 적합도

세번째로 평균제곱근오차는 보다 직관적이다.

- 사회과학자보다 데이터 사이언티스트가 오히려 평균제곱근오차(RMSE)에 더욱 주목하는 점이 흥미롭다(Why?).
- 수리적인 관점에서 보면 RMSE는 R^2 만큼 흥미롭지는 않다. 다만 해석이 너무나 명쾌하다!
- RMSE는 **MSE (Mean Squared Error)의 제곱근(square root)**이다. MSE는 다음과 같이 정의된다.

$$MSE = \frac{1}{n}\sum(Y_i - \hat{Y}_i)^2 = \frac{1}{n}\sum e_i^2$$

- 즉 오차의 제곱의 합이다. 제곱을 했으니 제곱근을 통해 팽창한 부분을 제거해야 좋다.



모형의 적합도

- RMSE은 모형을 통해 예측한 값들과 실제 데이터의 값들 사이에서 나타나는 평균적인 오차의 합으로 볼 수 있다.
- 만약 종속변수가 (0점에서 100점 사이의) 수학시험 점수이고 RMSE가 7이라면, 모형을 통한 예측과 실제 값 사이에는 평균적으로 7점의 오차가 있다고 해석할 수 있다.
- Stata에서 모형적합도 지수들을 해석하고 재현해보자.



다중회귀분석의 실제 활용



다중회귀분석의 실제 활용

일-생활 균형 인식은 임금노동자의 행복에 어떤 영향을 미치는가?

- 윤수인·이홍직(2020)의 모든 통계표를 순서대로 살펴보자. 어떤 식으로 진행되고 있는가?
- 주요 종속변수 및 독립변수는 어떤 항목들로 측정되고 있는가? 기술통계표는 어떻게 제시되고 있는가?
- 상관관계분석의 결과는 어떻게 요약되었는가?
- t 검정 또는 ANOVA 결과는 어떻게 제시되었는가?
- 마지막으로 〈표 8〉의 다중회귀분석 결과표에서 일-생활 균형 인식의 회귀계수를 해석해보자.

윤수인·이홍직. 2020. "임금노동자의 행복에 영향을 미치는 요인에 관한 연구: 인구 사회학적 요인, 좋은 일자리 요인, 일-생활 균형 요인을 중심으로." 『한국사회복지학』 72(2): 373-400.



다중회귀분석의 실제 활용

집합적 효능은 우울증상과 주관적 건강평가를 설명하는 다중회귀모형을 살펴보자.

- 우울증상에 관한 집합적 효능의 회귀계수를 해석해보자.
- 주관적 건강평가에 관한 집합적 효능의 회귀계수를 해석해보자.
- 우울증상에 관한 개인소득의 회귀계수가 집합적 효능을 추가하면서 어떻게 변화하는지 해석해보자.
- 주관적 건강평가에 관한 연령의 회귀계수가 집합적 효능을 추가하면서 어떻게 변화하는지 해석해보자.
- 참고로 〈표 2〉와 〈표 3〉에서는 서로 독립변수와 종속변수를 뒤바꾸어 모형을 추정하고 있다. 이것은 일반적이지 않은 관행이므로 주의해야 한다.

임훈민·김중백. 2014. "집합적 효능과 건강의 상호관계에 관한 연구." 『보건사회연구』 34(4): 441-446.



연습문제



연습문제

연습 1. WAGE2.DTA를 활용하여 다음에 답하시오.

- 관찰단위는 무엇인가?
- 종속변수는 lwage이고, 독립변수는 meduc, feduc, brthord, IQ, KWW, educ, exper, tenure, age인 회귀모형을 구상하시오.
- 모형에 사용되는 모든 변수를 간단히 점검하고 의미를 파악하시오. 결측치가 얼마나 많은지 살펴보고 많지 않다면 목록별 삭제(listwise deletion) 방식으로 결측치를 제거하시오.
- 변수를 추가하는 순서에 관하여 나름의 스토리텔링을 구상하면서 위계적 회귀모형을 구축하시오. 결과표를 제시하되 반드시 사례수와 (adj.) R^2를 함께 제시하시오.
- 모형을 도시거주 여부(urban)에 따라 나누어 각각 추정하고 결과표에서 대조하시오.
- 위의 두 모형에서 무엇이 각각 가장 강력한 변수인가? 그 회귀계수를 해석하시오. 왜 그것이 가장 강력한 변수인지 나름의 설명을 간략히 제시하시오.



회귀계수와 상수의 유의성 검정

연습 2. `mobility.csv`와 `mobility.pdf`를 사용하여 다음에 답하시오.

- 관찰단위는 무엇인가?
- 독립변수를 제조업종사자비율로 종속변수를 순이동률로 하여 회귀분석을 수행하시오.
- 이번에는 독립변수로 제조업종사자비율, 고차서비스비율, 지가변동율, 신규주택비율, 평균교육연수, 천명당공원면적, 만명당문화시설수을 함께 투입하여 회귀분석을 수행하시오.
- 두 분석 결과를 나란히 표로 작성하고 해석하시오. 이때 반드시 사례수와 (adj.) R^2를 함께 제시하시오.
- 위의 두 모형에서 무엇이 각각 가장 강력한 변수인가? 그 회귀계수를 해석하시오. 왜 그것이 가장 강력한 변수인지 나름의 설명을 간략히 제시하시오.
- 위 분석을 토대로 제조업종사자비율이 18%인 지역은 인구가 순유입될지 아니면 순유출될지 예측하시오.

