계량분석
Assumptions about the Error Term

김현우, PhD[1]

[1] 충북대학교 사회학과 부교수

November 9, 2026



진행 순서

1. 오차항의 가정: 조건부 영평균
2. 오차항의 가정: 등분산성
3. 오차항의 가정: 자기상관 없음
4. 오차항의 가정: 정규성
5. 회귀 가정에 대한 코멘트
6. 연습문제



오차항의 가정: 조건부 영평균



오차항의 가정: 조건부 영평균

조건부 영평균은 개념적으로 혼동스러우니 주의해야 한다.

- 먼저 조건부 영평균의 정의를 살펴보자. **조건부 기댓값(conditional expectation)** 개념을 수학적으로 꼼꼼히 살펴보지 않고, 어물 넘어가기 때문에 혼란스러울 수 있다.
- 이것은 어떤 독립변수가 데이터 안에서 "특정 값"을 가진다고 전제하고($X = x$) 모형에서 구한 오차항의 평균값이 0이라는 가정이다.

$$E(\epsilon_i|X) = 0$$

- 가령 지도배부 수(`map`)로 이용객 수(`rider`)를 예측한다고 하자. 지도배부 수가 0일 때도, 100일 때도, 200일 때도, 추정 이후 모형에서 남은 오차항은 평균적으로 0이어야 한다.



오차항의 가정: 조건부 영평균

- 이 가정은 **평균 독립성(mean independence)**이라고도 불리운다(Allison 1998).
- 이 가정은 사실 고전적 가정 가운데 비확률적 독립변수(non-stochastic Xs)의 사회과학적 수용이다. 비확률적 독립변수 또는 조건부 영평균 덕택에 다음의 식이 성립한다.

$$E(Y|X) = \beta_0 + \beta_1 X_1 + ... + \beta_k X_k$$

- 즉 회귀계수 해석에 오차항을 신경쓰지 않아도 된다.



오차항의 가정: 조건부 영평균

조건부 영평균이 성립하기 위해 완전모형 설정을 요구한다.

- 왜곡되지 않은 상수 추정을 전제로 했을 때, 조건부 영평균 가정은 주로 **모형설정 오류(model mis-specification)**나 변수의 **측정오류(measurement error)** 등으로 인해 위협받는다.
- 만약 연봉을 예측하기 위해 교육 수준을 독립변수로 투입하였다고 하자. 이때 타고난 능력(innate ability)을 도저히 측정할 수단이 없어 누락하였다고 하자.
- 타고난 능력이 교육 수준과 무관하다면 아무 걱정이 없다. 그러나 만일 타고난 능력이 교육 수준에 영향을 미친다면, 이 회귀분석은 조건부 영평균 가정을 위배하기 쉽다 (Why?).
- **완전모형 설정(perfect model specification)**은 보통 불가능하므로 이 부분은 결국 이론과 기존 문헌에 의존할 수 밖에 없다.



오차항의 가정: 조건부 영평균

조건부 영평균의 진단법은 사실 따로 없다.

- 표본을 회귀분석하고 추정한 $\hat{\epsilon}$은 이미 조건부 영평균을 가정하고 구한 것이다.
- 그러므로 표본의 잔차항을 열심히 살펴본다고 해서 가정의 성립 여부를 검증할 수 없다.
- Stata에서 비선형관계를 선형모형으로 적합시킨 다음, 잔차(residuals)를 계산하고 이를 독립변수 X에 대해 산포도와 적합선을 그려보자.
- 이러한 그림을 RVP 도표(Residuals-Versus-Predictor plot)라고 부른다.
- $E(\epsilon_i|X_i) = 0$가 성립하고 그렸으므로 상식적으로 RVP 도표는 "모든 X에 대해" $Y = 0$에 계속해서 수평선이 된다.
- 선형모형에서 그린 RVP 도표와 비선형모형에서 그린 RVP 도표를 비교해보자.



오차항의 가정: 등분산성



오차항의 가정: 등분산성

등분산성은 오차항의 분산이 X에 따라 변화하지 않는다는 가정이다.

- 이 가정의 의미를 그림으로 이해하자. 독립변수가 어떤 값이든 오차항이 일정하게 퍼져있음을 의미한다.

$$Cov(\epsilon_i, \epsilon_i|X) = Var(\epsilon|X) = \sigma_0^2$$

- 첫째, 변수에 이상점(outliers)이 있는 등 들쭉날쭉한 관측치가 끼어있거나, 둘째, 모형에 반드시 있어야 하는 변수가 빠져 불완전한 모형 설정(model mis-specification)인 경우에 이 가정이 쉽게 위배된다.
- 등분산성이 위배되는 상황을 **이분산성(heteroscedasticity)**이라고 부른다.



오차항의 가정: 등분산성

RVP 도표나 RVF 도표를 그려보는 것이 가장 기본적인 진단법이다.

- Stata에서 시뮬레이트된 자료를 활용하여 일부러 불완전한 회귀모형을 추정해보자.
- 추정된 잔차항과 독립변수와의 관계를 살펴보면, 독립변수가 변화할 때 추정된 잔차항의 분산도 변화하는 현상을 확인할 수 있다.
- 다음에는 완전한 모형을 만들어 회귀분석을 해보자.
- 이번엔 독립변수가 변화하더라도 추정된 잔차항의 분산은 일정함을 확인할 수 있다.



오차항의 가정: 등분산성

좀 더 공식화된 방법은 Breusch-Pagan 검정이 있다.

- 이 검정에서 귀무가설은 등분산성이고, 대립가설은 이분산성이다.

$$H_0 : Var(\epsilon|X) = \sigma_0^2$$
$$H_a : Var(\epsilon|X) \neq \sigma_0^2$$

- 검정통계량은 χ^2 이다(Why?). 다만 대부분의 χ^2 검정이 그러하듯, 이 검정도 표본 수에 지나치게 민감하다는 단점이 있다.



오차항의 가정: 등분산성

이분산성 상황에 대해서도 여러가지 대응책이 있다.

- 만약 이상점이 존재하는 상황이라면 이것을 제거하고 다시 회귀분석을 수행한다.
- 변수의 분산이 크다면 로그 변환을 시도해 볼 수 있다. 이런 목적의 로그 변환을 특별히 **분산안정화 변환(variance-stabilizing transformation)**이라고도 부르기도 한다.
- 일반적인 표준오차 대신 **강건표준오차(robust standard error)**를 보고할 수 있다. Stata에서 이것은 `regress` 명령어 뒤에 `robust` 옵션을 붙여서 손쉽게 얻어낼 수 있다.



오차항의 가정: 등분산성

- 위의 모든 방법으로도 이분산성 문제가 심각하게 남아있는 경우, 최후의 수단으로 **가중최소자승(Weighted Least Square; WLS)**을 사용한 회귀분석을 수행할 수 있다.
- 이는 보통최소자승(OLS) 대신 이분산을 야기하는 구조 그 자체를 모형 속에 고려하는 방법으로, 계산 논리는 흥미롭지만 현실적으로 이분산 구조를 모형 속에 제대로 구현하지 못한다면 오히려 더 큰 문제를 야기할 수도 있다.
- 등분산성 가정이 위배되더라도 추정값의 표준오차(standard errors)에 큰 차이가 없으면 너무 걱정하지 않아도 된다.
- 그러므로 다양한 방법으로 모형을 추정해 보고 나란히 보고하여 얼마나 추정이 강건한가를 주장할 수 있다(온라인 부록도 물론 활용할 수 있다).



오차항의 가정: 자기상관 없음



오차항의 가정: 자기상관 없음

자료 안에서 오차항 사이에는 조건부 상관관계가 없어야 한다.

- 같은 모집단에서 크기 n의 표본을 무수히 반복해서 뽑는다고 상상해 보자. 그러면 표본마다 i번째 사례와 j번째 사례의 오차항이 한 쌍씩 실현된다. 이렇게 반복된 표본들 전체에서, 한 표본 안의 ϵ_i가 크게 나올 때 같은 표본 안의 ϵ_j도 체계적으로 크거나 작게 나오는 경향이 없어야 한다.
- 두 오차항 e_i과 e_j 사이에 공분산(covariance)이 0이라는 가정이다.

$$Cov(\epsilon_i, \epsilon_j) = 0$$

- 이 가정은 (관측된 숫자 두 개의 관계를 말하는 것이 아니라) 확률변수 ϵ_i와 ϵ_j 사이의 관계를 말하는 것이다.



오차항의 가정: 자기상관 없음

등분산성 가정과 자기상관 없음 가정은 밀접하게 연관되어 있다.

- 오차항의 **공분산행렬(variance-covariance matrix)**은 다음과 같이 가정된다.

$$Cov(e_i, e_j) = \begin{bmatrix} \sigma^2 & 0 & 0 & \cdots & 0 \\ 0 & \sigma^2 & 0 & \cdots & 0 \\ 0 & 0 & \sigma^2 & \cdots & 0 \\ & & \vdots & & \\ 0 & 0 & 0 & \cdots & \sigma^2 \end{bmatrix}$$

- 대각행렬 부분이 바로 등분산성 가정이고 그 나머지 부분은 자기상관 없음 가정에 의해 채워진다(Why?).

$$Cov(\epsilon_i, \epsilon_i) = Var(\epsilon_i|X) = \sigma_0^2$$
$$Cov(\epsilon_i, \epsilon_j) = 0$$



오차항의 가정: 자기상관 없음

사회학이 궁금해 할 만한 주제에 관해 이 가정은 아예 성립하지 않는다.

- (분석단위가 개인인 경우) 사회학이나 사회역학(social epidemiology)의 세계관에서 이 가정은 특히 문제가 된다.
- 시공간적 **자기상관(autocorrelation)**이 존재할 때도 이 가정은 쉽게 위배된다.
- **시계열적 자기회귀(time-series autoregression)**는 현재의 오차항 e_t이 과거의 오차항 e_{t-1}과 자기상관을 갖는 현상을 지칭한다.
- "오늘의 나를 가장 잘 설명하는 변수는 과거의 나"라는 평범한 진리는 자기상관 없음 가정을 위배하고 있다.



오차항의 가정: 자기상관 없음

- **공간적 자기회귀(spatial autoregression)**는 특정 지역의 오차항이 그 근린의 오차항과 자기상관을 갖는 현상을 지칭한다.
- "가까운 것은 먼 것보다 중요하다(Near things are more related than distant things)"는 **토블러의 지리학 제1법칙(Tobler's First Law of Geography)**을 떠올릴 것.
- 이렇게 **시계열 자료(time-series data)**나 **공간자료(spatial data)**가 주어진 경우 보통최소자승(OLS) 회귀분석으로는 적절한 분석이 불가능한 까닭을 여기서 알 수 있다.



오차항의 가정: 자기상관 없음

자기상관 없음의 진단법은 지금 고민할 필요가 없다.

- 자기상관이 나타나는 상황 자체가 이미 수준 높은 고급사회통계학의 영역이다.
- 예컨대 흔히 시계열분석에서는 Durbin-Watson 통계량(statistic)부터 공부하기 시작하고, 공간회귀분석에서는 Moran's I부터 공부하기 시작하는데 이미 우리 수업의 단계를 훨씬 넘어선 것이다.
- 데이터의 수집 과정과 성격 자체를 들여다보고 자기상관이 존재할 것인지를 개념적으로 판단하자.



오차항의 가정: 자기상관 없음

자기상관이 존재하는 경우에도 대응책은 마련되어 있다.

- 가장 단순한 방법은 애시당초 순수한 임의표집(random sampling)으로 자기상관이 존재하지 않도록 하는 것이다. 이것은 여러가지 의미에서 현실적으로 어려운 경우가 많다(Why?).
- 다음으로 일반적인 표준오차 대신 **강건표준오차(robust standard error)** 혹은 **군집표준오차(clustered standard error)**를 보고한다. Stata에서는 `regress` 명령어 뒤에 `robust` 또는 `cluster(·)` 옵션을 사용한다.
- 또다른 방법은 자기상관의 구조를 직접 모델링하여 구현하는 것이다. **시계열분석(time-series analysis)**나 **공간회귀분석(spatial regression analysis)**, **소셜네트워크 회귀모형(social network regression modeling)** 등은 이런 맥락에서 발전하였다.



오차항의 가정: 정규성



오차항의 가정: 정규성

필수적인 가정은 아니지만 가설검정 절차를 편리하게 만들어준다.

- 오차항은 정규분포한다는 것이 이 가정의 전부이다.

$$\epsilon_i \sim N(0, \sigma^2)$$

- 조건부 영평균과 등분산성을 결합한다고 해도 자동적으로 이 가정이 성립하는 것은 아니다. 두 가정은 오차항의 분포에 대해서는 어떠한 형태도 전제도 하지 않기 때문이다.
- 이 정규성 가정이 워낙 포괄적(overarching)인 까닭에 논문에서는 이것 하나만 쓰고 "가정이 성립한다고 전제한다"라고 요약할 때가 많다.



오차항의 가정: 정규성

- 학부과정에서 배운대로, 소표본인 경우 오차항이 정규분포해야만 회귀계수의 t 검정을 위해 t 분포를, 모형 적합도 검정을 위해 F 분포를 믿고 사용할 수 있다.
- 만약 이 가정이 없었다면, t 통계량이나 F 통계량의 논리는 더이상 성립하지 않으므로 신뢰구간(confidence interval)과 유의성 검정 결과를 신뢰할 수 없게 된다.
- 한편 사례가 충분히 크다면(대표본) 이 가정은 불필요하다. 표본이 커지면 t 분포는 자연스럽게 Z 분포를 따라가고, F 분포의 근본이 되는 χ^2 분포 역시 대표본에서는 정규분포에 근접하기 때문이다.



오차항의 가정: 정규성

정규성 가정은 보통 그림을 통해 진단한다.

- **표준화된 정규확률도표**(standardized normal probability plot) 혹은 PP (Percent-Percent) **도표**를 그린다.
- 이 그림의 Y 축은 이론적 정규분포의 누적표준분포, 즉 **기대누적확률**(expected cumulative probability)를 의미하고, X 축은 관찰된 데이터의 누적표준분포, 즉 **관찰누적확률**(observed cumulative probability)를 의미한다.
- 두 값들이 정확히 일치하면 그림은 45도 선을 따라가기 마련이지만, 만일 그렇지 않다면 정규성 가정이 아무래도 위배되고 있다고 의심할 수 있다.
- Shapiro-Wilk **정규성 검정**(test of normality)라는 기법도 있다.
- 이들 기법은 사실 t, χ^2, F 분포 등을 사용하기 앞서 정규성 여부를 확인하기 위해서도 가끔씩 쓰이곤 한다. 하지만 대표본이라면 이 가정에 그렇게까지 집착할 필요는 없어 보인다.



회귀 가정에 대한 코멘트



회귀 가정에 대한 코멘트

가정이 위배되면 더이상 보통최소자승이 최적이라고 보장할 수 없다.

- 보통 연구자들은 다음과 같이 (모든 가정을 충족하는) 고전적인 회귀모형을 짧게 정의한다.

$$\mathbf{Y} = \mathbf{XB} + \mathbf{e}$$

$$\mathbf{e} \overset{\text{i.i.d}}{\sim} N(0, \sigma^2 \mathbf{I})$$

- 볼드(bold)로 두껍게 표시된 기호는 이것들이 행렬임을 의미한다.
- i.i.d는 **독립항등분포(independent and identically distributed)**를 뜻한다.



회귀 가정에 대한 코멘트

회귀분석의 가정은 고급통계학의 관문과도 같다.

- $1 + 1 = 2$ 를 배우는 것은 금방이지만 왜 이러한 식이 성립하는지 **공리(axioms)**나 가정을 공부하는 것은 어렵다.
- 회귀분석의 가정을 공부할 때는 일단 각 가정이 무엇을 의미하는가를 살펴보고 이를 직관적으로 파악하는데 중점을 두자. 처음 공부할 때는 증명은 일단 생략하고 결론이 무엇인가를 파악하자.
- 물론 사회통계학 자체를 전공한다면 수학 공부를 게을리해서는 안된다. 반드시 교재를 읽고 꼼꼼히 공부해야 한다.



연습문제



회귀 가정에 대한 코멘트

연습 1. `hprice1.dta`에서 `price`를 종속변수로, `bdrms`, `lotsize`, `sqrft`, `colonial`를 독립변수로 하는 회귀모형을 자료에 적합하시오. 회귀분석의 가정을 설명하고 각각의 성립 여부를 평가하시오.



회귀 가정에 대한 코멘트

연습 2. `bwght.dta`에서 `bwght`를 종속변수로, `cigtax`, `cigprice`, `fatheduc`, `motheduc`, `parity`, `male`, `white`, `cigs`, `faminc`를 독립변수로 하는 회귀모형을 자료에 적합하시오. 회귀분석의 가정을 설명하고 각각의 성립 여부를 평가하시오.

