계량분석
Examining Datasets

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

September 18, 2023

진행 순서

1. 사회조사자료
2. 패널 자료
3. 공공 데이터
4. 시사점

사회조사자료

사회조사자료

데이터 아카이브 안에서 수많은 사회조사자료를 찾을 수 있다.

- 사회조사(social survey)는 해당 지역 또는 국가의 거주민들이 정치·사회·경제·과학기술 등 여러 분야에 걸친 가치(values), 여론(opinions), 태도(attitudes), 행태(behaviors)를 조사하여 얻는다.
- 사회과학 분야에서 연구될 수 있는 여러가지 토픽을 커버한다. 시민 자유(civil liberties), 범죄/폭력, 그룹간 관용(intergroup tolerance), 도덕/윤리 판단, 국가재정, 심리적 안녕(psychological well-being), 사회적 계층 이동(social mobility), 스트레스와 트라우마 등 다양하다.
- 특정 토픽을 수 년에 한 번씩 돌리기도 한다.
- 물론 나이, 성별, 인종 등 기본적인 인구학적 변수(demographic variables)는 언제나 포함한다.

사회조사자료

- 일반적으로 하나의 사회조사자료는 특정 연구모집단 내 모든 구성원들에 대해 대표성 (representativeness을 확보하고 있다.
- (미국은 GSS, 한국은 KGSS, 중국은 CGSS, 일본은 JGSS, 독일은 GGSS 등) 국가별로 각각 대표적인 사회조사가 있다.
- 유사한 질문을 수 년에 걸쳐 반복적으로 질문하여 사회변동을 파악하기에 유용하다.
- 다만 같은 사람을 추적하지 않으므로 패널 자료는 아니다. 다만 미국의 GSS는 패널도 함께 운용하고 있다.
- 데이터 수집 및 관리를 전공한 수많은 사회학자들이 프로젝트를 운영하기 때문에 일반적으로 대단히 품질이 높다.

사회조사자료

사회조사 데이터들을 비교하여 국가간 비교를 수행할 수도 있다.

- 예전 비교사회학(comparative sociology)이 제법 흥성하던 시기가 있었다.
- 이 목적으로 설계·수집된 대표적인 자료로 Ronald Inglehart가 주도한 World Values Survey (WVS)가 특히 유명하다.
- 유럽 국가들 사이에서 설계·수집된 자료로 European Values Survey (EVS)도 나름 유명하다.

사회조사자료

- 몇몇 국가의 연구자들은 자국에서 나름의 GSS를 운영하면서 같은 모듈(module)을 같은 해에 함께 질문하여 일부러 비교가능하도록 설계하였다.
- 이 자료를 따로 뽑아 International Social Survey Programme (ISSP)을 구축했다.
- 많은 유럽 국가들은 ESS (European Social Survey)에 함께 참여한다.
- 동아시아의 국가들 간에 운영되는 East-Asian Social Survey (EASS)도 있다.
- (필요에 따라) 한국인과 미국인의 사회적 가치를 비교하기 위해 KGSS와 GSS를 함께 분석할 수 있다.

사회조사자료

- 오늘날 비교사회학은 크게 침체되었지만, 폭넓은 자료 이용가능성(data availability)에 힘입어 다양한 주제를 탐구하며 나름의 명맥을 유지하고 있다.
- 국민정체성(national identity), 민족주의(nationalism), 그리고 이주민에 대한 태도(attitudes toward migrants)
- 국가기구에 대한 신뢰(confidence), 대중 일반에 대한 신뢰(trust)
- 노동조합 가입률 및 조직관련 행동
- 결혼과 가족, 여성의 사회적 지위, 아동 양육 등에 관련한 태도 및 행태, 가치관
- 더 많은 시민적 자유(civil liberties)와 통치가능성(governability) 사이에서의 믿음
- 정치 및 사회 참여, 신사회운동(new social movements) 가치관
- 교육, 보건, 의료와 관련된 태도 및 행동

사회조사자료

세계가치관조사의 최근 자료를 간단히 살펴보자.

- 링크는 https://www.worldvaluessurvey.org
- Stata 원자료 파일(Wave 7) 뿐만 아니라 설문지도 함께 다운로드 받자.
- 특히 탈물질주의적 가치(post-materialist values)를 살펴보자.
- 다음의 중 가장 중요한 두 가지가 무엇인가를 고르게 하여 분류한다(1=물질주의적; 2=혼합적; 3=탈물질주의적).
  (1) Maintain order in the country
  (2) Give people more to say in important government decisions
  (3) Fight raising prices
  (4) Protect freedom of speech

잉글하트, 로널드. 1983. 『조용한 혁명』. 종로서적.

잉글하트, 로널드 · 크리스찬 웰젤. 2011. 『민주주의는 어떻게 오는가』. 김영사.

패널 자료

패널 자료

패널 자료분석은 많은 잠재력을 내포한다.

- 하지만 현실적으로 패널에는 응답자의 조사 거부, 이사 등 연락 두절, 사망 등의 이유로 어쩔 수 없이 마모(attrition)가 발생한다(마모는 당연히 자료의 질에 부정적인 영향을 준다).
- 패널 자료의 질 관리는 매우 어렵고 또한 엄격하게 이루어져야 한다.
- 패널 자료의 수집과 관리가 대단히 까다롭다는 점을 감안하면, 대부분 대규모 조직이나 정부기관 등에서 특수한 목적에 따라 운용해 왔다는 사실은 놀랍지 않다.

패널 자료

- 전통적인 사회과학 통계학에서는 패널 자료를 가장 이상적인 자료형태로 여겨왔다.
- 패널 자료분석은 훨씬 고난이도의 분석기법을 요구한다.
- 가령 패널 자료분석을 통해 관찰자료인 경우에도 엄격한 인과관계(causal relationship) 연구를 수행할 수도 있다.
- 몇몇 연구자들(특히 석사학위 논문을 쓰려는 학생들)은 패널 자료 전체를 분석하기 보다 특정 연도의 자료만을 잘라내 횡단면 자료로 삼아 분석하기도 한다.

패널 자료

국내만 해도 수많은 패널 데이터가 존재한다.

- 한국아동청소년 패널조사, 한국청소년 패널조사, 다문화청소년 패널조사, 학업중단청소년 패널조사(이상 한국청소년정책연구원)
- 서울교육종단연구, 서울교원종단연구(이상 서울교육정책연구소)
- 사업체패널, 노동패널(이상 노동연구원)
- 한국의료패널, 한국복지패널(이상 한국보건사회연구원)
- 인적자본기업패널, 한국교육고용패널(이상 한국직업능력개발원)
- 여성가족패널조사(한국여성정책연구원), 한국미디어패널조사(정보통신정책연구원), 청년패널조사(한국고용정보원), 한국교육종단연구(한국교육개발원), 가계금융복지조사(통계청), 장애인고용패널조사(한국장애인고용공단), 한국아동패널(육아정책연구소), 청소년건강행태조사(질병관리청) 등

패널 자료

한국교육종단연구 2005년 교육용 자료를 살펴보자.

- 자료를 받기 위해서 회원 가입에서 승인까지 다소 시간이 걸릴 수 있으므로 교육용 자료를 eCampus에서 다운로드 받자.
- 자기조절학습(self-regulated learning)의 측정문항 4개와 학업성취도(1학년 국영수) 총점 3개의 기술통계(descriptive statistics)를 살펴보자.
- 자기조절학습의 문항들을 모두 더하여 하나의 복합변수(composite variable)를 만들자. 마찬가지로 학업성취도 세 과목 총점의 복합변수를 만들자.
- 위 두 복합변수들의 히스토그램을 살펴보자.
- 두 변수 사이의 산점도를 그려보고 약간 더 예쁘게 꾸며보자.

공공 데이터

공공 데이터

사회학 연구에서 정부의 공식 통계는 다소 미묘한 입장에 있다.

- Emile Durkheim의 〈자살론〉은 공식 통계(official statistics)를 활용한 가장 뛰어난 사회학 고전 연구다(동시에 공식 통계에 의존했다는 이유로 비판받기도 했다).
- 사회학 연구에서 공식 통계의 사용에 관한 가장 근본적인 비판 가운데 하나는 민속방법론(ethnomethodology)에 의해 제기되었다
- "우리는 사회 현상을 통계적으로 분석하는가? 아니면 공무원의 통계 작성 행위를 분석하는가?"

공공 데이터

- 설령 통계 자료의 중립성을 받아들이더라도 공식 통계가 대부분 집계 자료 (aggregate data)라는 점에서 유용성이 다소 제한적이다.
- 어떤 경우에는 집계 자료로도 충분하지만 원자료(raw data)가 필요한 경우가 많다.
- 원자료는 프라이버시나 저작권 등의 이유로 인해 공공 데이터로서는 공개되지 않지만 연구 목적에 따라서는 구입 또는 정보공개 청구로 확보할 수 있는 경우가 있다.
- 공공 데이터의 원자료가 바로 행정자료인 경우가 많다(Why?).

공공 데이터

근래에는 공공 데이터의 양과 범위가 점점 넓어지고 있다.

- 이른바 4차 산업혁명의 한 인프라로서 공공 데이터의 가치가 재발견되면서 연구 기회도 늘어났다.
- 각종 경진대회가 열리기도 한다. 예컨대 (2021년 제9회 문화공공데이터 활용 경진대회).
- 비정형인 데이터가 일반화되면서 좀 더 새롭고 창의적인 접근이 요구되는 경우가 많아졌다.
- 다운로드가 아니라 Application Programming Interface (API)의 형식을 취하는 경우가 늘어났다.
- 이런 경우에는 자료에 접근하기 위해서라도 코딩(주로 R이나 Python)을 배워야 하고 전처리 숙련도도 필요하다.

공공 데이터

여기서는 World Bank에서 제공하는 공공 데이터를 살펴보자.

- https://data.worldbank.org
- World Development Indicators 메뉴를 선택하자. 모든 Country, 모든 Series, 2019년을 체크해서 국가 단위의 경제 통계를 csv 파일의 형식으로 다운로드받자.
- 다운로드받은 자료를 엑셀에서 한 번 살펴보자.
- 필터를 사용해 GDP per capita, PPP (current international $) 만 고른 뒤, 새로운 탭에 복사하여 붙여넣자. 결과물을 CSV 파일 형식으로 저장하자.
- 이 데이터를 Stata에서 불러오자.
- GDP는 문자열(string)이므로 이를 수치형 자료로 변환하고 히스토그램을 그려보자. 이 그림은 어떤 시사점을 제공하나?
- CSV 파일을 Stata 파일로 새롭게 저장하자.

공공 데이터

두 개 이상의 자료의 연결은 매우 중요한 기법이다.

- 자료 연결(data merging)는 크게 네 가지 형식 중 하나로 이루어진다:
  (1) 일대일(one-to-one)
  (2) 일대다(one-to-many) (3) 다대일(many-to-one)
  (4) 다대다(many-to-many)

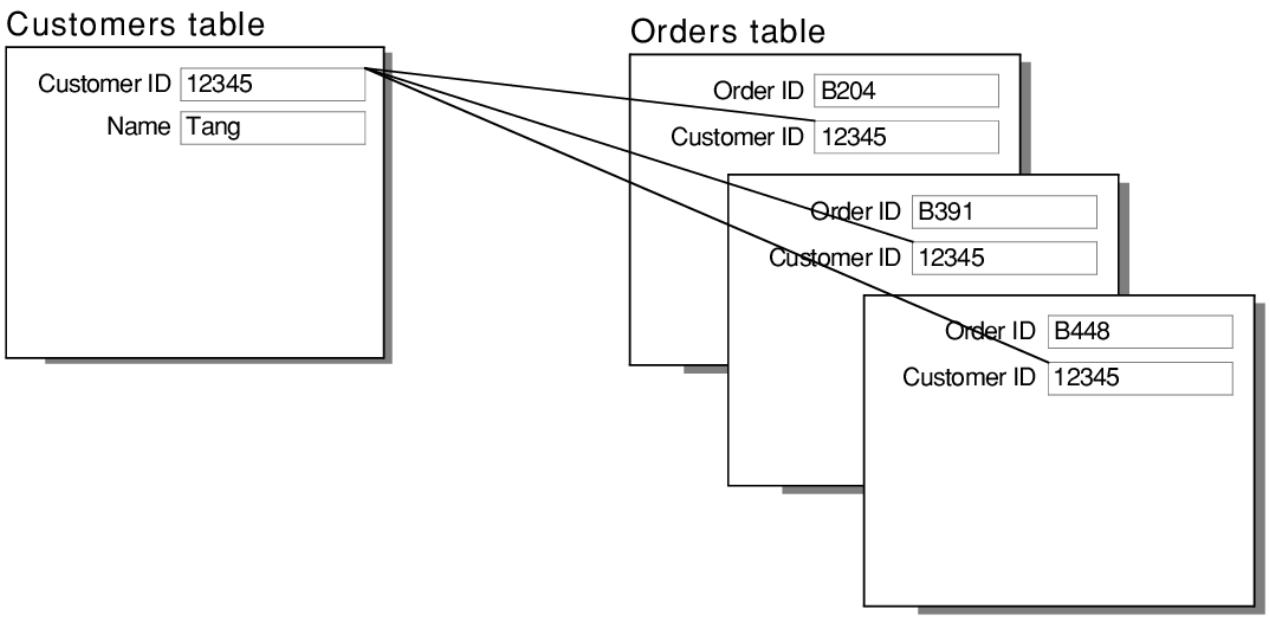

One-to-Many Merging

공공 데이터

- 각각 공통 변수(common identifier)가 “고유한 하나” 인가 아니면 “중복된 여러 개” 인가에 따라 다르다.
- 연구 목적에 따라서도 써야 하는 연결 방식이 달라진다.
- Stata에서는 결합하는 파일(master file)과 결합에 쓰일 파일(using file) 모두에서 공통 변수의 이름이 반드시 같아야 한다.
- 공통 변수가 있는 한 수많은 자료들을 연결할 수 있다. 연결된 자료는 그렇지 않았을 때와는 비교할 수 없을만큼 큰 잠재력을 갖는다.
- 특히 공공 데이터는 그 자체로는 다소 쓸모가 약하지만, 다른 사회조사 자료나 패널 자료와 결합되었을 때 나름의 가치를 보여준다(Why?).

공공 데이터

아까 준비한 세계가치관조사 자료와 세계은행 공공 데이터를 결합해 보자.

- ISO 3166-1 국가 코드는 WVS 자료와 세계은행 공공 데이터 양쪽 모두에 들어있다. 이 공통 변수를 사용해 자료를 연결할 수 있다.
- 먼저 WVS 데이터에서 가치체계를 세 개의 더미변수(dummy variable)로 바꾸어보자.
- WVS 원자료의 관찰단위는 개인이였는데 이를 국가 수준으로 집계(aggregate)하자.
- 이제 WVS 데이터와 WB 데이터 모두 측정단위는 국가가 되었다.
- 이제 서로 결합(merge)하고 편의상 결합에 실패한 국가들은 그냥 삭제하자.
- 국가별로 물질주의적 가치 평균, 혼합형 가치 평균, 탈물질주의적 가치 평균이 GDP와 어떤 관련을 갖는지 산점도를 그려보자.

시사점

시사점

책 읽기와 마찬가지로 설문지 읽기도 사회과학 연구에 큰 도움이 된다.

- 찾고자 하는 데이터가 정말 존재하는지 그리고 어떻게 구하는지를 아는 것은 그 자체로 어려운 일이다.
- 이런 것들은 노하우(know-how)라기보다 노웨어(know-where)에 가깝다.
- 자신의 전공과 무관하더라도 수많은 데이터를 살펴보아야 한다.
- 이 과정에서 새로운 분야에 대해 관심과 식견을 키우고 학제간 통찰력도 얻는다.
- 얼핏 본 사회조사 설문지의 질문 하나로부터 지적 충격을 받아 완전히 새로운 이론적 관심으로 발전하는 일은 매우 흔하다.
- 최대한 많은 설문지들을 다운로드 받고 어떤 문항들이 있는지 눈여겨 보다보면 사회학적 상상력과 분석적 통찰력을 얻는다.

시사점

자료 탐색에 시간을 충분히 많이 써야 한다.

- 시간을 많이 들여서 관심에 부합하는 데이터 아카이브를 발굴하고 자주 살펴보는 습관이 필요하다.
- 평상시에 수많은 자료에서 조사하는 변수들을 미리 머리 속에 잘 정리해두자.
- 이론 또는 가설이 생겨났을 때 “아! 이 가설이라면 세계가치관조사(WVS)가 적절하겠구나!” 하고 깨닫는 것이 보다 이상적이다.
- 많은 패널 자료 학술대회에서는 거의 매해 컨퍼런스가 열릴때마다 “패널 데이터 분석방법론” 세션을 마련하고 있다(아무 웹사이트나 가서 과거 컨퍼런스 일정표를 훑어보자).