계량분석
Comparing Variances

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 9, 2023

진행 순서

1. 단일모분산에 대한 가설검정
2. 두 모분산에 대한 가설검정
3. 일원분산분석
4. 일원분산분석의 실제 활용

단일모분산에 대한 가설검정

단일모분산에 대한 가설검정

모분산 σ^2에 관한 가설검정은 여러 상황에서 유용하다.

1. 가령 소득의 분산은 소득 불균등을 의미한다(사실 사회계층 및 불평등 연구에서는 좀 더 정교한 소득 불균등 지표가 사용되기는 한다).
2. 한 반에서 학생 성적의 분산은 교육 성과가 고르게 나타나지 않아 교육 양극화가 나타남을 시사한다.
3. 설문조사의 특정 문항에 대한 응답의 분산은 조사대상자 의견의 불일치 내지 다양성을 의미한다.
4. 금융상품의 수익률의 분산은 해당 상품의 스프레드(spread) 또는 리스크(risk)를 의미한다. 똑같은 논리가 도박에 대해서도 적용된다.
5. 제조된 공산품의 상태지표의 분산은 들쭉날쭉한 품질(quality) 상태를 의미한다.

단일모분산에 대한 가설검정

일단 하나의 표본분산 s^2에 대해 이론적으로 상상해보자.

- 우리는 모집단에서 표본을 무한히 계속 뽑고 그것들의 분산 s^2를 구해 분산의 표집분포를 상상해 볼 수야 있다
- 이때 표본 크기 n이 작다면 분산의 표집분포는 오른쪽 꼬리가 길어질 것이다(long tail). 그 이유는 생각보다 단순한데, 분산의 계산 과정에서 제곱을 하다보면 큰 값이 우연히 많이 나오기 때문이다.
- 하지만 아쉽게도 표본분산 s^2에 관한 직접적인 이론 분포는 없다!

단일모분산에 대한 가설검정

- 평균 $\bar{x}$의 경우 소표본일 때 t 분포, 대표본일 때 Z 분포라는 이론적 확률분포를 가졌다.
- 반면 분산 s^2의 경우 직접적인 이론적 확률분포가 없고, "표본분산 s^2와 모분산 σ^2 간의 비율"에 관한 이론적 확률분포인 χ^2 분포(chi-square distribution)를 대신 사용한다.

$$\chi^2_{n-1} = \frac{(n-1)s^2}{\sigma^2}$$

- 말하자면 단일표본의 분산 s^2의 표집분포가 아니라, $(n-1)s^2/\sigma^2$ 비율의 표집분포를 상상해야 한다!

단일모분산에 대한 가설검정

χ^2 분포는 오로지 자유도 $n-1$에 의해 모양이 결정된다.

- χ^2 분포는 소표본일 때 비대칭적이고 오른쪽으로 꼬리가 길다.
- Z 값에 제곱을 하다보면 우연히 큰 값이 나타나기 쉽고 표본이 작다보면 그 값이 튀어보이기 때문이다(Why?).

$$\chi_k^2 = Z_1^2 + Z_2^2 + \ldots + Z_k^2 = \sum \left(\frac{x-\mu}{\sigma}\right)^2$$

- 그러나 대표본이 될수록 정규분포의 모습에 점점 근사한다(Why?).
- χ^2 값은 결국 분산들의 비율이므로 항상 양수값을 갖는다.

$$\frac{(n-1)s^2}{\sigma^2} \geq 0$$

단일모분산에 대한 가설검정

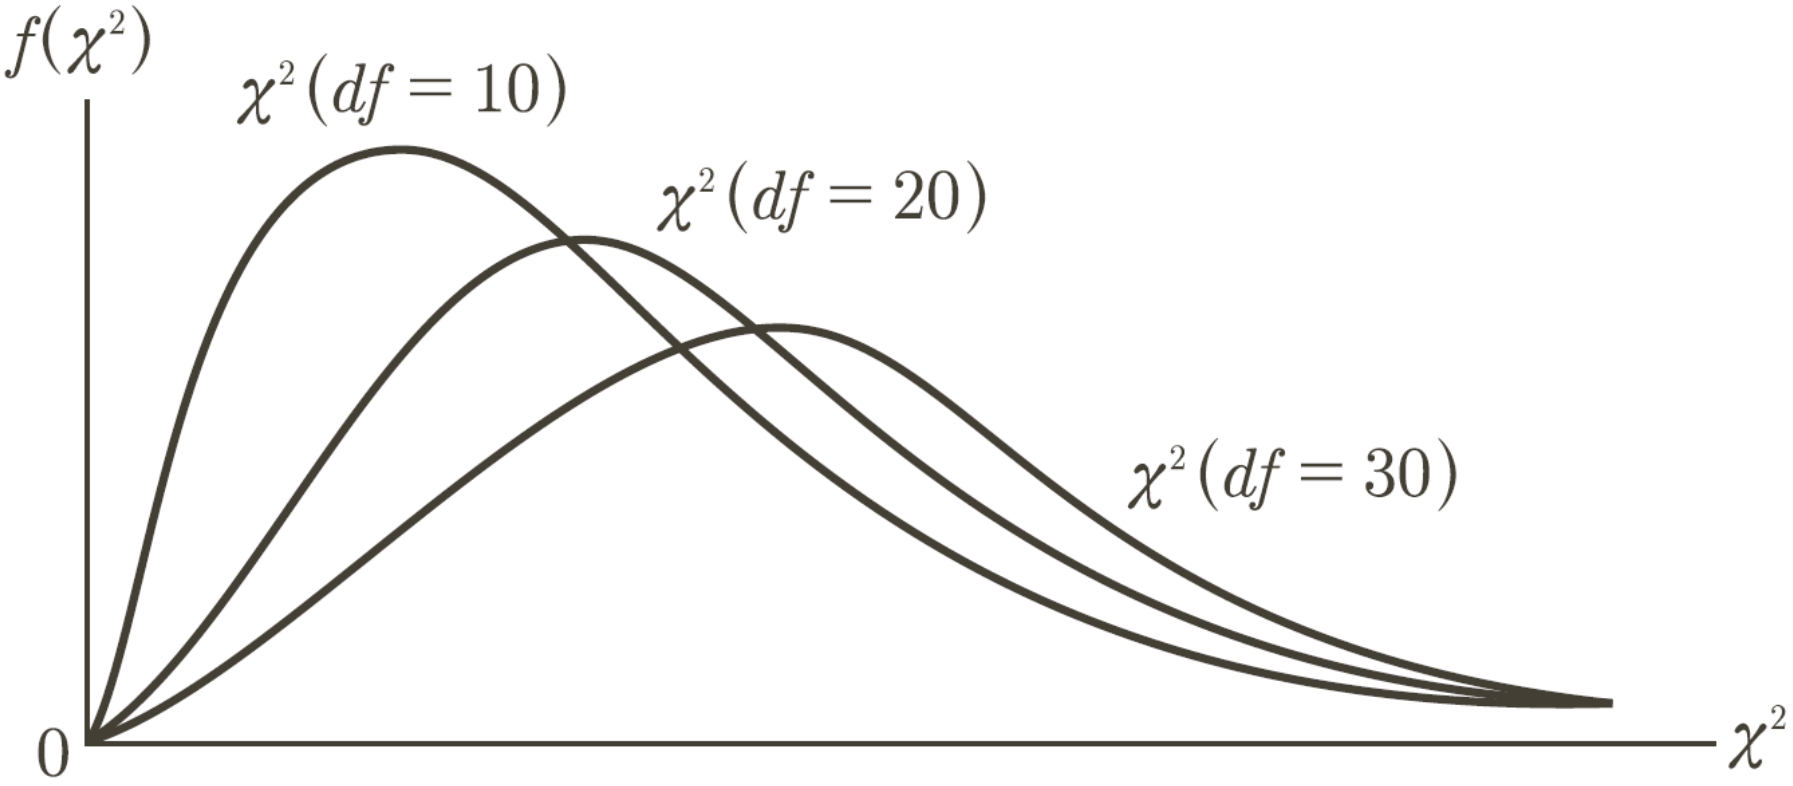

단일모분산에 대한 가설검정

앞서 배운 바와 마찬가지로 유의성 검정을 수행할 수 있다.

- 먼저 social.dta 안에서 socialself 변수의 요약통계량을 살펴보자.
- 전국의 모든 학생들에 대해 일괄적으로 시험을 실시하였고, 그 중 6,301명의 학생을 임의표본(random sample)으로 추출하였다고 하자.
- "모집단 점수의 표준편차는 5.1점보다 작다($\sigma \leq 5.1$)"라는 귀무가설을 세우기로 한다.
- 이에 따라 6,301개의 표본에서 계산된 표준편차 s와 모집단 점수로 가설 설정된 표준편차 σ_0의 비율에 6300의 자유도를 곱한 χ^2_{6300} 분포를 그릴 수 있다.

단일모분산에 대한 가설검정

- 표본에서 계산된 표준편차가 5.177점이라고 하자. 이 경우 χ^2 값은 약 6493이다.

$$\chi^2 = \frac{(n-1)s^2}{\sigma^2} = \frac{(6301-1)\cdot 5.177^2}{5.1^2} = 6493.1538$$

- Stata에서는 이론적 확률분포의 누적분포함수(cdf)를 직접 계산하여 χ^2 값과 유의확률(p-value)을 구할 수 있다.
- $p < 0.05$이므로 95% 유의수준에서 귀무가설을 통계적으로 유의하게 기각할 수 있다.
- Stata에서는 sdtest 명령어를 사용한다. 다만 이것은 분산을 비교하는게 아니라 표준편차를 비교한다는 점에 주의하자.

두 모분산에 대한 가설검정

두 모분산에 대한 가설검정

분산비교는 보통 F 분포에 기반하여 수행된다.

- 단일모분산에 관한 가설검정이 χ^2 분포를 이용하는 반면, 두 모분산의 비율에 관한 가설검정은 F 분포를 이용한다.
- F 분포의 확률밀도함수(PDF)는 다음과 같이 정의된다:

$$F_{(n_1-1,n_2-1)} = \frac{\chi_1^2/(n_1-1)}{\chi_2^2/(n_2-1)}$$

- 조금만 생각해보면 F 분포는 각각의 단일모분산을 설명하는 χ^2 의 비율임을 쉽게 파악할 수 있다. 다만 자유도를 사용하여 약간의 보정이 이루어졌을 뿐이다. 심지어 $n_1 = n_2$ 라면 그마저도 필요없다.
- F 분포는 두 개의 자유도 $(n_1 - 1)$ 와 $(n_2 - 1)$ 에 따라 그 형태가 결정된다(이것도 χ^2 와 흡사하다).

두 모분산에 대한 가설검정

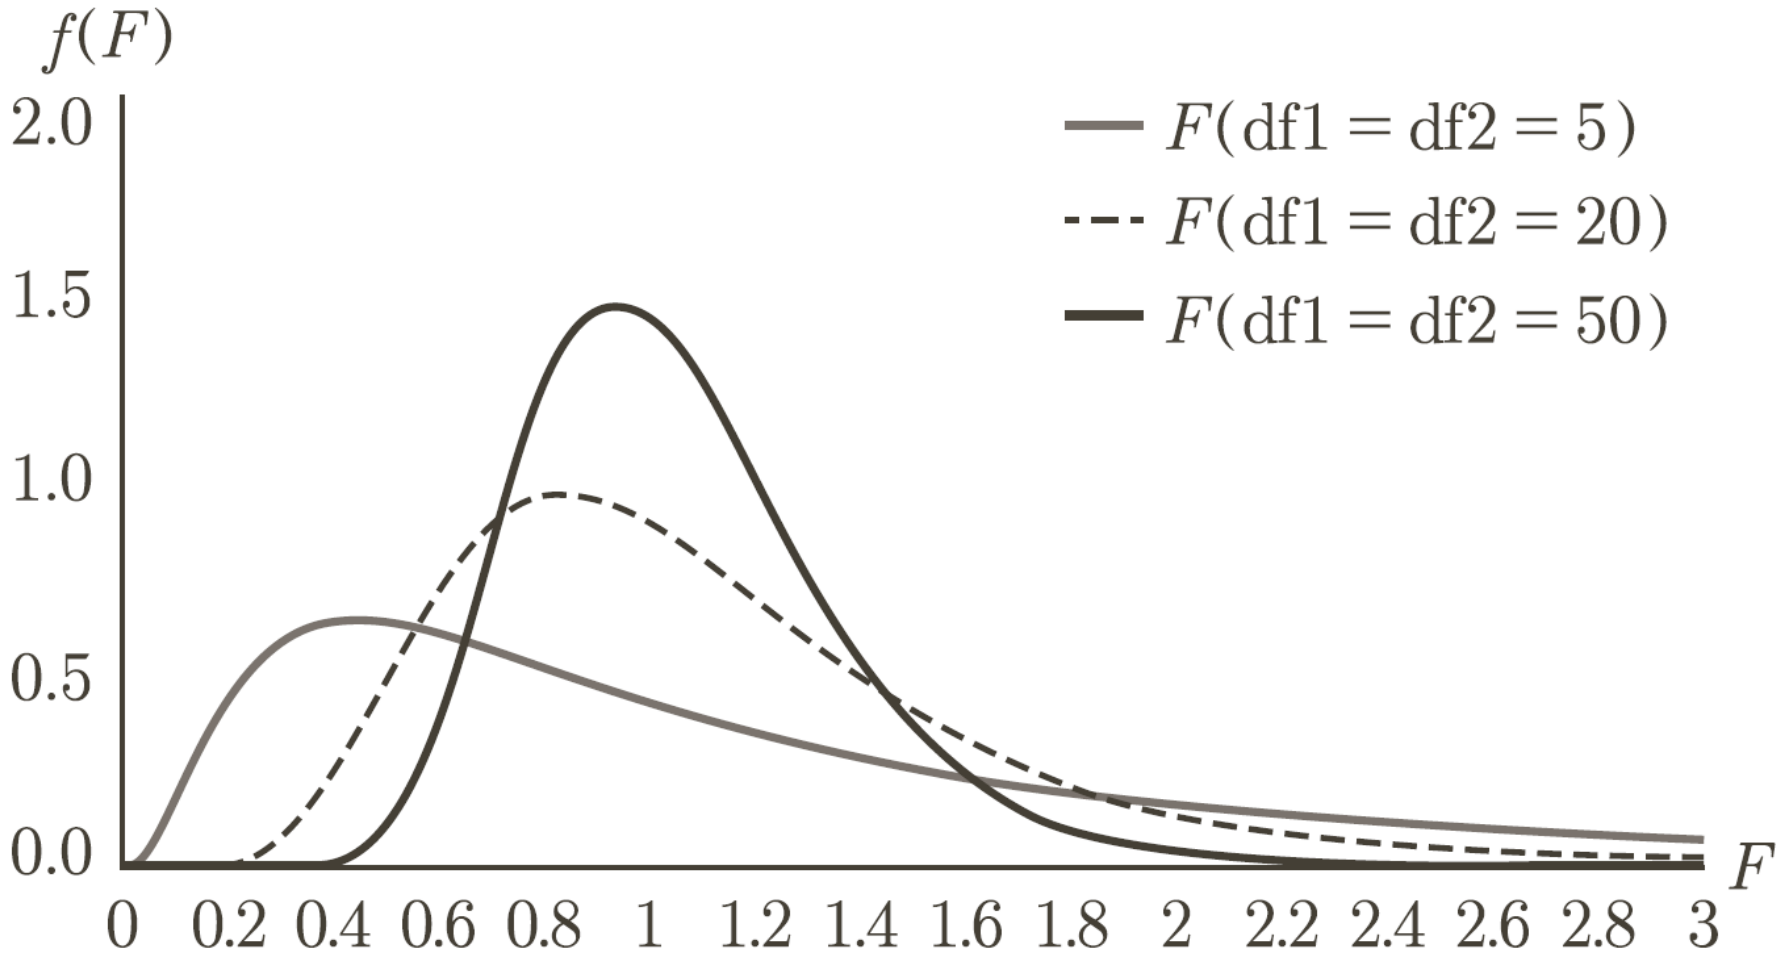

두 모분산에 대한 가설검정

일단 χ^2 분포 자체에 익숙해져야 F 분포에 대해서도 쉽게 이해할 수 있다.

- 우리는 두 표본의 분산의 차(difference)를 구하려는 것이 아니라 비(ratio)을 구하려는 것이므로 두 χ^2 값이 서로 비슷할수록 F 값은 0이 아니라 1에 접근하리라 예상할 수 있다.
- F 분포는 두 개의 χ^2 분포의 비(ratio)로 구성되므로 0보다 작을 수 없다.

두 모분산에 대한 가설검정

Stata에서 두 개의 독립표본에 대한 분산비교를 연습하자.

- fuel2 자료에서 treat에 따라 mpg의 표준편차 비율에 관한 귀무가설들을 검정해보자.
- (1) “treat 상태에 따른 mpg의 표준편차 비율은 1이다.”
- (2) “treat 상태에 따른 mpg의 표준편차 비율은 1보다 작다.”
- (3) “treat 상태에 따른 mpg의 표준편차 비율은 1보다 크다.”
- 쌍체표본(paired sample)도 있긴 하지만 여기서는 더이상 다루지 않고 넘어간다.

일원분산분석

일원분산분석

일원분산분석은 여러 모분산에 대한 가설검정 기법이다.

- 사실 지금까지 설명한 분산의 추정과 비교는 일원분산분석(one-way analysis of variance)을 위한 준비에 불과하다.
- 실용적 맥락에서 보면 일원분산분석은 여러 개의 표본들이 주어졌을 때 이것들이 하나의 모집단에서 추출되었는가를 확인하는데 쓰인다.
- 한편 분산분석(Analysis of Variance 또는 ANOVA)은 특히 실험적 연구의 맥락에서 분석을 위해 자주 사용되는 고도로 발달한 여러 분석기법들의 한 집합이다.
- 일원분산분석에서 일원(one-way)는 독립변수가 하나인 것을 의미한다.
- 그 밖에도 다변량분산분석(multivariate ANOVA 또는 MANOVA), 공분산분석(analysis of covariance 또는 ANCOVA)이나 다변량공분산분석(multivariate analysis of covariance 또는 MANCOVA) 등 다양하게 있으나 이것들은 이 수업의 수준을 벗어난 것이므로 다루지 않는다.

일원분산분석

일원분산분석의 검정통계량은 F 값이다.

- 일원분산분석은 F 분포를 사용하며 그 원리는 앞서 설명한 두 모집단 분산에 대한 가설검정과 같다.

$$F_{(n-1,n-k)} = \frac{MS_{between}}{MS_{within}} = \frac{SS_{between}/(k-1)}{SS_{within}/(n-k)}$$

- 이때, 두 제곱합(sum of squares; SS)은 각각 다음과 같다.

$$SS_{between} = \sum(\mu_j - \mu)^2$$
$$SS_{within} = \sum(Y_{ij} - \mu_j)^2$$

- 분자인 $MS_{between}$는 실험처리에 의한 효과(treatment effect)로 볼 수 있고, 분모인 MS_{within}는 임의오차(random error)에 지나지 않는다.

일원분산분석

집단 간 분산이 클수록 그리고 집단 내 분산이 작을수록 F 값은 커진다.

- 수리적으로 따지고 들어갈 필요조차 없다. 사실 F 값이 갖는 의미는 상식적으로 너무나 명확하다!
- 두 표본이 주어졌을 때, 표본 간에는 차이가 크고 표본 내에는 차이가 작다면, 두 모집단은 서로 다른 것이다.
- 두 표본이 주어졌을 때, 표본 간에는 차이가 작고 표본 내에는 차이가 크다면, 두 모집단은 서로 다르다고 할 수 없다.
- 따라서 F 값이 크다는 것은 두 모집단은 서로 다름을 시사한다.

일원분산분석

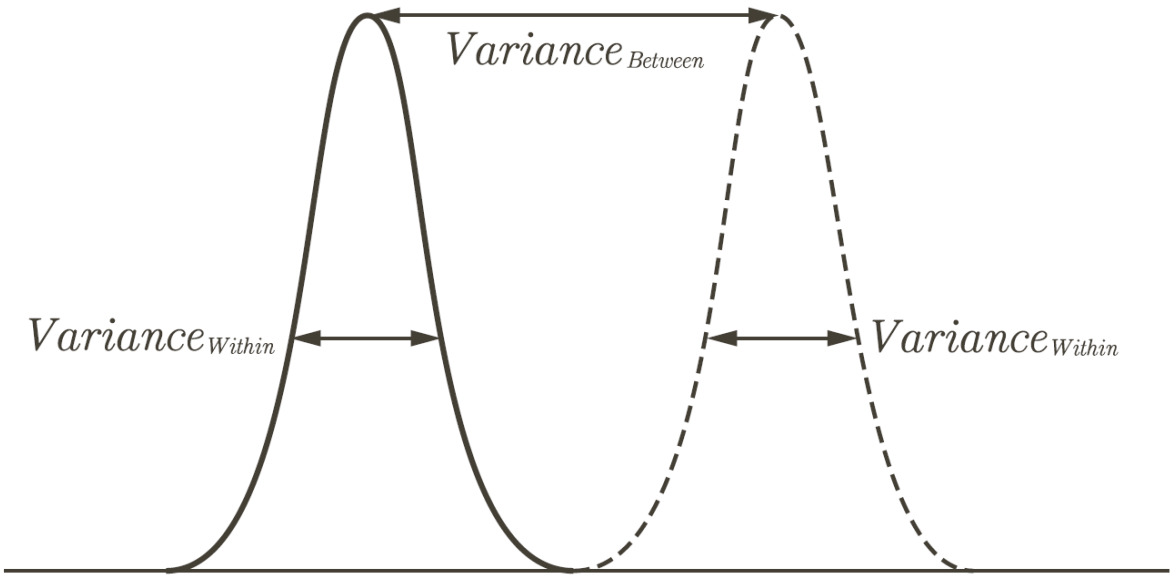
$Variance_{Between}$
$Variance_{Within}$
$Variance_{Within}$

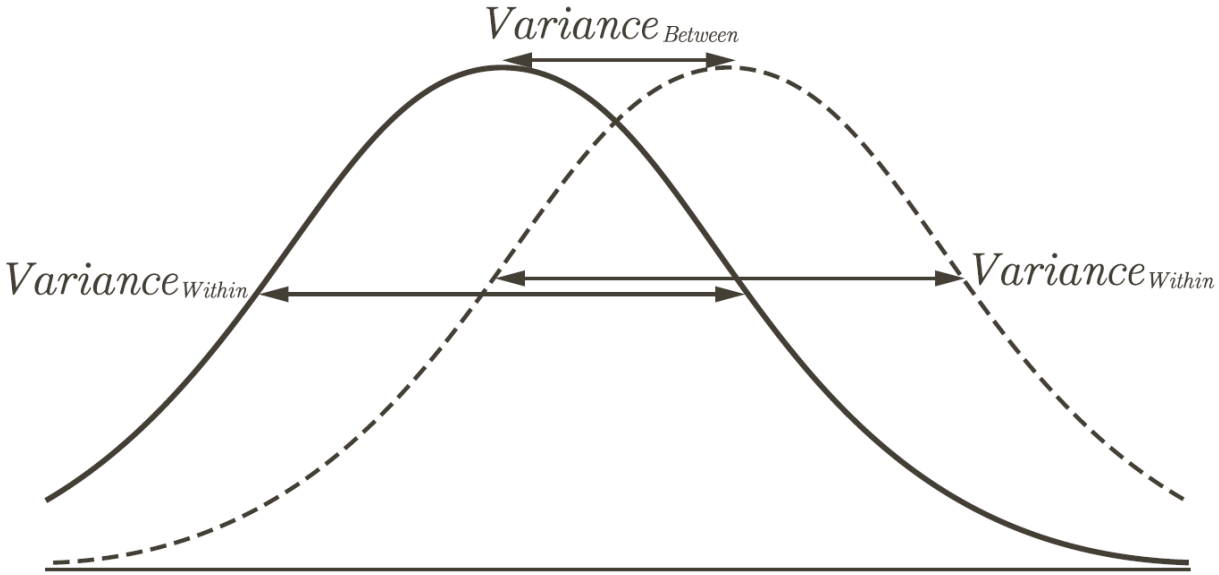
$Variance_{Between}$
$Variance_{Within}$
$Variance_{Within}$

일원분산분석

일원분산분석의 가설설정은 다소 주의를 요한다.

- 일원분산분석의 귀무가설은 "모든 집단에 걸쳐 평균값이 동일하다"이다. 구체적인 예를 들면, "기후위험의 인식 점수의 평균에 최종학력별 차이는 없다"가 될 수 있다.
- 그 대립가설은 "모든 집단에 있어 평균값이 다르다"가 아니다. "적어도 하나의 집단에서 평균값이 다르다"임에 주의할 것!
- 이 귀무가설을 넘어 보다 구체적으로 둘 중 어느 집단에서 평균값이 더 높은가를 짝지어 비교하는 기법들도 있다. 예컨대 본페로니(Bonferroni), 셰페(Scheffe), 시닥(Sidak) 다중비교검정(multiple comparison test)이 있다. 우리는 다루지 않는다.
- 분석상 분산의 비율을 비교하고 있음에도 불구하고 가설설정이 평균에 대해 이루어진다는 점도 기억할 것.

일원분산분석

계산된 F 값과 두 개의 자유도에 따라 유의성 검정을 수행한다.

- census3 자료에서 지역(region)에 따라 출산율(brate)이 다른지 일원분산분석을 수행해보자.
- (모든 집단에 있어 평균이 같다는) 귀무가설이 정말로 옳다면 F 값은 1에 가까울 것이다(Why?).
- Stata에서는 oneway 명령어를 사용할 수 있고, 좀 더 일반화된 분산분석 명령어인 anova를 사용할 수도 있다.

일원분산분석의 실제 활용

일원분산분석의 실제 활용

경험적 연구논문에서 일원분산분석은 크게 두 부분에서 주로 활용된다.

- 첫째로 표본에 관한 기술통계를 제시할 때 사용될 수 있고, 두번째로 회귀분석에서 모형적합도 지표 중 하나로 사용될 수 있다.
- 기술통계로 제시한다면, 표본 안의 핵심이 되는 범주형 관심변수 내지 종속변수에 따라 다른 여러 변수들이 어떻게 다른지 일원분산분석을 통해 보여줄 수 있다.
- 이때 범주형 변수는 명목형 내지 순서형 척도로 측정된 것이며 예컨대 최종학력, 출신지역, 지지하는 정당 등을 생각해 볼 수 있다.

일원분산분석의 실제 활용

〈Table 7〉 Analysis of variance on perception toward justice

		Average of effort reward fairness	F	Prob.>F
All		2.981		
Sex	Male	2.975	0.10	0.7469
	Female	2.987		
Co-residency with parents	Not living together	3.008	1.02	0.3136
	Living together	2.969		
Economic Independence	Independent	3.031	7.47	0.0063
	Dependent	2.935		
Marital status	Married	3.120	24.65	0.0000
	Single	2.927		
Employment	Regular worker	3.067	9.36	0.0001
	Self-employed	2.866		
	Unemployed	2.938		

이희정. 2018. “청년층 계층인식 변화가 공정성 인식에 미치는 영향 분석.” 한국사회학 52(3): 119–164.

일원분산분석의 실제 활용

일원분산분석은 두번째 맥락인 회귀분석 전체 계수의 유의성 검정에서도 사용된다.

- 이 경우 귀무가설은 "모든 회귀계수들이 0이다"로 만일 이 귀무가설을 기각하지 못한다면 모델에 포함된 어떠한 독립변수(X)로도 종속변수(y)를 의미있게 설명하지 못함을 의미한다.
- 당연히 이 경우에는 모델을 처음부터 다시 만들어야 한다.
- 회귀분석의 맥락에서 대립가설은 "적어도 하나 이상의 회귀계수는 0이 아니다" 임에 주의할 것.
- census3 자료에서 출산율(brate)을 종속변수로, 지역(region) 가변수를 독립변수로 회귀분석을 수행해보자.

일원분산분석의 실제 활용

t 검정과 일원분산분석에는 잘 알려진 연관성이 있다.

- t 검정은 두 모집단의 평균을 비교하고, 일원분산분석은 여러 모집단에 걸친 분산의 비율을 비교한다.
- 만일 집단이 두 개만 주어졌을 때 일원분산분석을 수행하면 어떤 결과를 가져올까?
- 이 경우 일원분산분석의 귀무가설은 "모든 집단에 걸쳐 평균값이 동일하다"였으므로 이는 다시 "두 집단에 걸쳐 평균값이 동일하다"로 축소된다.
- 즉 t 검정과 같은 것이 된다. 실제로 F 값과 t 값에는 다음과 같은 관계가 있다.

$$\sqrt{F} = |t| \quad (\text{또는 } F = t^2)$$

- auto 자료를 사용하여 이 사실을 Stata에서 간단히 확인해보자.

일원분산분석의 실제 활용

- 그렇다면 반대로 생각해서, 집단이 여러 개 있을 때 구태여 일원분산분석 대신 t 검정을 여러 번 하면 안될까?
- 결론만 말하자면 (1) 굉장히 불편하고 혼란스러울 뿐 아니라, (2) 추정상의 오류를 저지르게 될 위험이 극단적으로 커지므로 권할 수 없다.
- 먼저 t 검정을 아주 여러 번 수행하고 비교해야 하는 부담이 있다.
- 예컨대 겨우 5개의 모집단을 비교하기 위해서 t 검정을 10번이나 수행해야 한다 (Why?).
- 이것은 기하급수적으로 증가하여 6개의 모집단을 비교하기 위해서는 t 검정을 15 번이나 수행해야 한다(Why?).

일원분산분석의 실제 활용

- 게다가 이 10번의 t 검정을 수행하는 과정에서 최소 1번 이상 오류가 나타날 가능성 또한 급격히 증가한다.
- 예컨대 5% 유의확률이라면 1회 이상의 오류 확률은 40%이나 된다(Why?).
- 이항분포(binomial distribution)를 통해 이 확률분포를 계산할 수 있다. 즉 발생확률 p가 0.05인데 10번의 시행 중 사건이 전혀 발생하지 않을 확률분포는 다음과 같다.

$$1 - \binom{n}{k} p^k (1-p)^{n-k} = 1 - \binom{10}{0} \cdot 0.05^0 \cdot (1-0.05)^{10-0}$$

- 이 사실을 간단히 Stata에서 확인해보자.