계량분석
Correlation Analysis

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 16, 2023

진행 순서

1. 상관분석
2. 상관계수의 유의성 검정
3. 산점도

상관분석

상관분석

둘 이상의 양적변수 간 연관성은 상관분석으로 살펴볼 수 있다.

- 상관분석(correlation analysis)은 상관계수(correlation coefficient)를 구하는 기법이다.
- 상관계수의 밑바탕에는 분산(variance)과 공분산(covariance)이 있으므로, 먼저 다시 분산의 식을 돌이켜보자.

$$
\begin{aligned}
Var(X) &= \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu)(X_i - \mu)
\end{aligned}
$$

- 변수가 하나만 주어져 있을 때 편차(deviation)를 구해 제곱하여 분산을 구했는데, 아래처럼 살짝 바꾸면 곧바로 공분산이 된다.

$$
Cov(X, y) = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu_X)(Y_i - \mu_Y)
$$

상관분석

- 두 변수의 편차끼리 곱할 때, 모두 양수(+)이거나 음수(-)이면 공분산은 양수(+)가 되고, 어느 한쪽이 양수(+)이고 다른 쪽이 음수(-)이면 공분산은 음수(-)가 된다.
- 공분산에는 명확한 단점이 있었다. Cov(X, Y)는 X 내부(within X)의 분산과 Y 내부(within Y)의 분산이 다를 수 있다는 점을 고려하지 않는다.
- 그러나 피어슨의 적률상관계수(Pearson's product-moment correlation coefficient)는 두 변수 X와 Y 각각의 표준편차(분산이 아니고!)를 분모로 각각 나누어주므로 이 문제를 해결한다.

$$\rho = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

- (표준편차로 나누어주었기 때문에) ρ는 -1과 1사이에서 두 변수가 얼마나 강한 상관관계를 가지고 있는지 보여준다.

상관분석

상관계수의 해석은 매우 간단하지만 혼동하지 않도록 주의해야 한다.

- 상관계수가 0보다 크면 두 변수는 서로 같은 방향(정방향)으로 움직인다. 즉 "X가 증가할 때 Y는 증가한다."
- 상관계수가 0보다 작으면 두 변수는 서로 다른 방향(역방향)으로 움직인다. 즉 "X가 증가할 때 Y는 감소한다."
- 왜 이렇게 해석되는지 공분산의 분자 부분인 $\sum(X-\bar{X})(Y-\bar{Y})$ 를 들여다보자.
- 상관계수가 1에 가까울수록 (그리고 -1에 가까울수록) 두 변수는 더욱 밀접한 상관관계를 갖게 된다.
- 물론 상관성이 인과성을 보장하는 것은 아니다!

상관분석

공분산과 상관계수를 Stata에서 계산해보자.

- 상관계수를 구하기 위해 correlate 명령어를 사용할 수 있다.
- 공분산을 구하기 위해서는 같은 명령어 뒤에 cov라는 옵션을 붙이면 된다.
- 변수에 적당한 상수를 곱하거나 나눈 뒤, 공분산과 상관계수를 다시 계산하여 비교해보자.
- 위의 상관계수 공식을 사용하여 correlate 명령어에 의존하지 말고 직접 상관계수를 계산해보자.

상관분석

상당히 많은 논문들이 기술통계의 일환으로 상관계수행렬을 제시한다.

- 상관계수행렬은 단순히 한 변수와 다른 변수 사이의 상관관계를 보여주는 것을 넘어 이른바 다중공선성(multicollinearity)이 존재하는가를 살펴볼 때도 (잠재적으로) 유용하다. 이에 관해서는 나중에 다루기로 한다.
- 상관계수행렬은 논문 한 페이지를 통째로 잡아먹기 때문에 근래에는 보고하지 않는 경우도 많다.
- 그러나 이 행렬은 이른바 메타분석(meta analysis)에서 종종 유용한 정보를 제공하는 경우가 있으므로 사정이 허용된다면 온라인 부록(online appendix)으로라도 보고하는 편이 바람직하다.

상관분석

〈표 2〉 주요 변인들 간 피어슨 단순 상관계수

	1	2	3	4	5
1. 혼전성수용도	-				
2. 혼외성수용도	.34***	-			
3. 법회 · 예배참석	-.22***	-.09***	-		
4. 기도빈도	-.18***	-.10***	.63***	-	
5. 기타활동 참석	-.15***	-.07**	.68***	.53***	-
6. 자기평가종교성	-.17***	-.06**	.58***	.52***	.44***
7. 본질적종교성	-.20***	-.09***	.58***	.53***	.44***
8. 비본질적종교성	-.02	-.04	.35***	.33***	.30***
9. 연령	-.41***	-.09***	.14***	.15***	.07**
10. 교육수준	.29***	.09***	-.01	-.02	.04

※ 유의수준: ***p 〈0.001 **p 〈0.01 *p 〈0.05

〈표 2: 계속〉 주요 변인들 간 피어슨 단순 상관계수

	6	7	8	9
6. 자기평가종교성	-			
7. 본질적종교성	.56***	-		
8. 비본질적종교성	.40***	.34***	-	
9. 연령	.14***	.16***	.00	-
10. 교육수준	-.05*	-.08**	.09***	-.62***

※ 유의수준: ***p 〈0.001 **p 〈0.01 *p 〈0.05

한내창. 2010. “종교와 성태도 간 관계.” 한국사회학 44(5): 114-138.

상관분석

- 그런데 이렇게 여러 변수들의 상관계수를 보여줄 때, 결측치(missing value)가 포함되어 있을 때 그 처리 방식이 조금 복잡해진다.
- (1) 한 변수에라도 결측치가 있다면 그대로 버리는 방식과 (2) 그 변수와 다른 변수와의 상관계수를 계산할 때만 버리는 방식으로 나뉜다.
- 후자는 쌍별(pairwise) 상관분석이라고 부른다(그리고 좀 더 많이 쓰이는 것 같다).
- Stata에서 pwcorr로 수행할 수 있다.

상관계수의 유의성 검정

상관계수의 유의성 검정

상관계수에 대해서도 다음과 같이 유의성 검정을 할 수 있다.

- 상관계수에 대해서는 무조건 양측검정을 수행한다.

$$H_0 : \rho = 0$$
$$H_a : \rho \neq 0$$

- t 검정을 통해 유의확률(p-value)을 구한다. 단, t 분포의 꼴은 $(n-2)$의 자유도로 결정된다(Why?).

$$t = \frac{\hat{\rho} - \rho}{se_\rho} = \frac{\hat{\rho}}{\sqrt{\frac{1-\hat{\rho}^2}{n-2}}} = \hat{\rho}\sqrt{\frac{n-2}{1-\hat{\rho}^2}}$$

- 즉 (1) 추정된 상관계수 $\hat{\rho}$가 커지고 (2) 사례수 n가 많아질수록 검정통계량 t 값이 커져 귀무가설을 기각하기 쉬워진다.

상관계수의 유의성 검정

소표본만 벗어나도 상관계수의 유의성 검정에 사실 큰 의미가 없다.

- 위 식을 곰곰히 들여다보면 눈치챌 수 있는 부분인데, 예컨대 $n = 50$ 정도로 작은 표본에서 $\hat{\rho} = 0.3$ 정도의 값만 나와주어도 이미 95% 신뢰수준에서 통계적으로 유의하다(Why?).
- 오늘날 경험적 사회과학 연구에서 $n = 50$ 짜리 연구는 없다. 게다가 $\hat{\rho} = 0.3$는 거의 없는 수준의 상관관계에 불과하다.
- Stata에서는 pwcorr의 경우 sig 옵션을 통해 유의확률을 알 수 있다. 이때 star(0.05)와 같은 옵션을 통해 5% 수준에서 유의한가를 알려주는 별을 붙일 수도 있다.

산점도

산점도

산점도와 상관계수는 늘 함께 생각하자!

- 산점도(scatterplot)는 두 양적변수 사이의 연관성을 시각화하는 중요한 기법이다.
- 이때 기울기(slope)는 상관계수의 본질이 아니다! 오히려 관찰값 사이의 흩어짐(산포경향)이 상관계수의 본질이다(Why?).
- 참고로 기울기는 회귀계수의 본질을 전달한다. 이에 관해서는 나중에 배우기로 한다.

산점도

- 왼쪽과 오른쪽 산점도 둘 다 상관계수 ρ는 1이다.

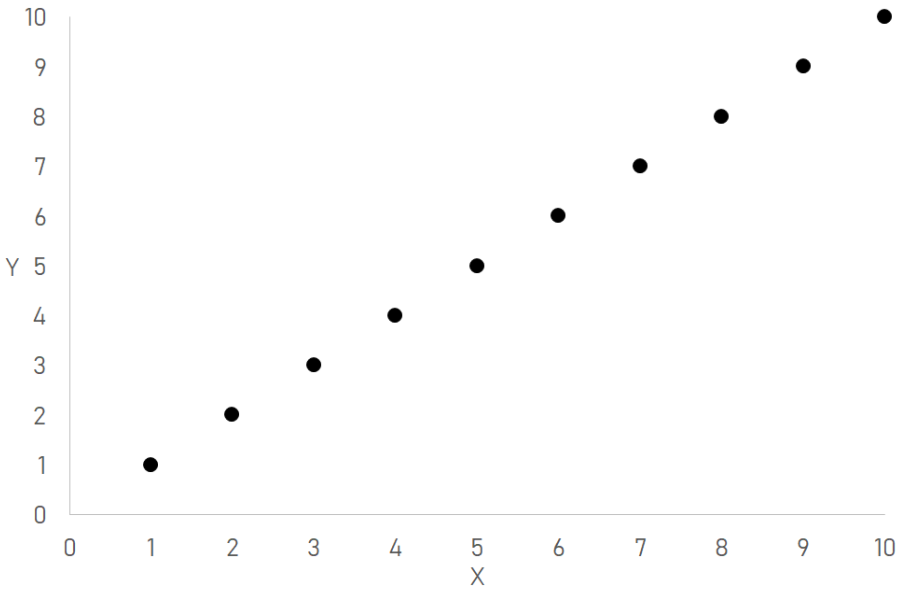

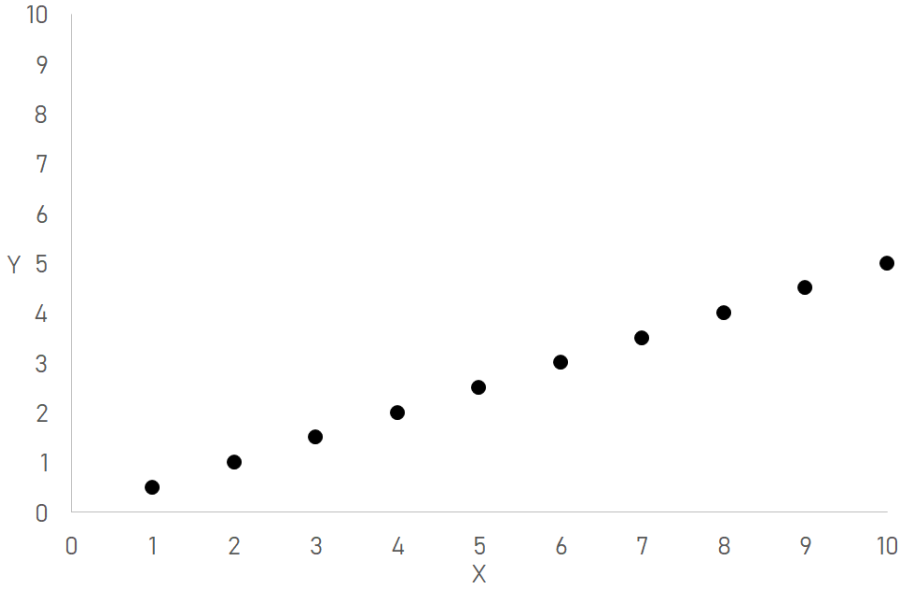

X(공통)	Y(왼쪽)	Y(오른쪽)	X(공통)	Y(왼쪽)	Y(오른쪽)
1	1	0.5	6	6	3
2	2	1	7	7	3.5
3	3	1.5	8	8	4
4	4	2	9	9	4.5
5	5	2.5	10	10	5

산점도

- 왼쪽 산점도에서 Y는 X로부터 ± 0.5씩 더해 계산되었고, 오른쪽 산점도에서 Y는 X로부터 ± 1씩 더해 계산되었다.
- 왼쪽 상관계수($\rho = .98$)가 오른쪽 상관계수($\rho = .94$)보다 크다.

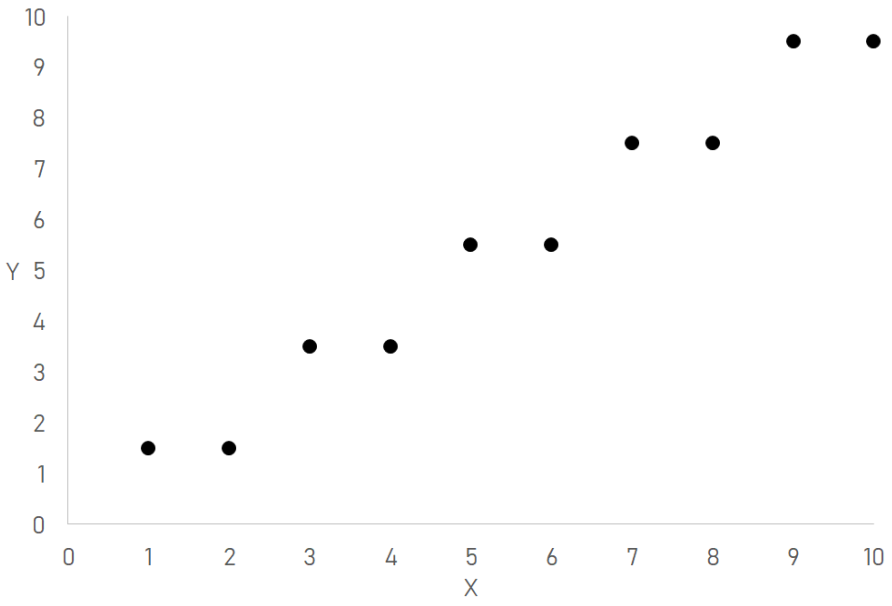

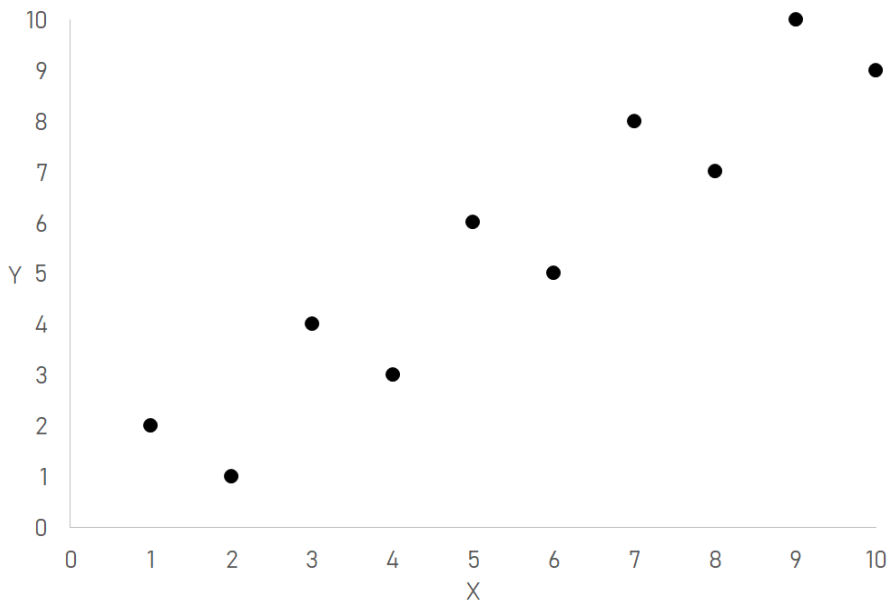

X(공통)	Y(왼쪽)	Y(오른쪽)	X(공통)	Y(왼쪽)	Y(오른쪽)
1	1.5	2	6	5.5	5
2	1.5	1	7	7.5	8
3	3.5	4	8	7.5	7
4	3.5	3	9	9.5	10
5	5.5	6	10	9.5	9

산점도

- 왼쪽 산점도에서 Y는 .0001씩이라도 커져서 $\rho = 1$이지만, 오른쪽 산점도는 전혀 변동하지 않아 수평선이고 ρ는 아예 계산할 수 없다(Why?).

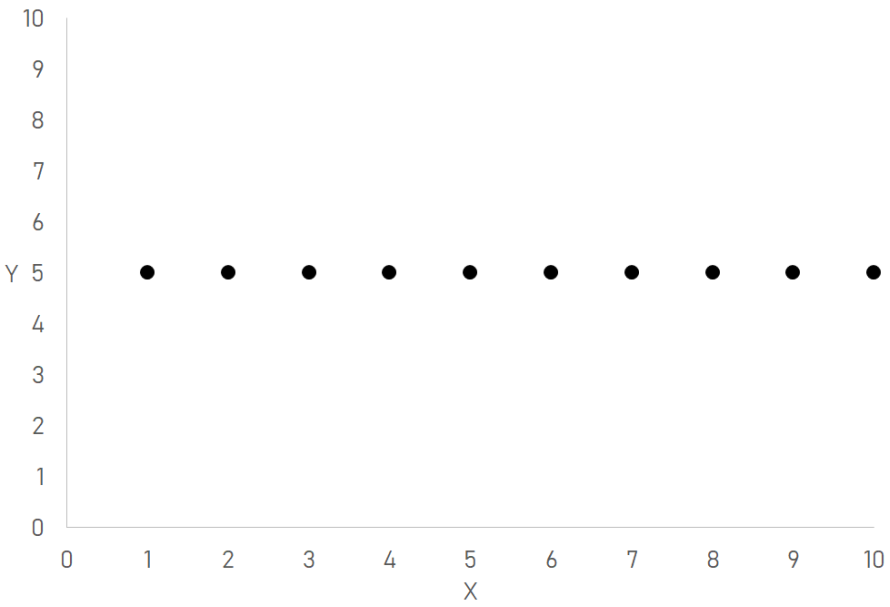

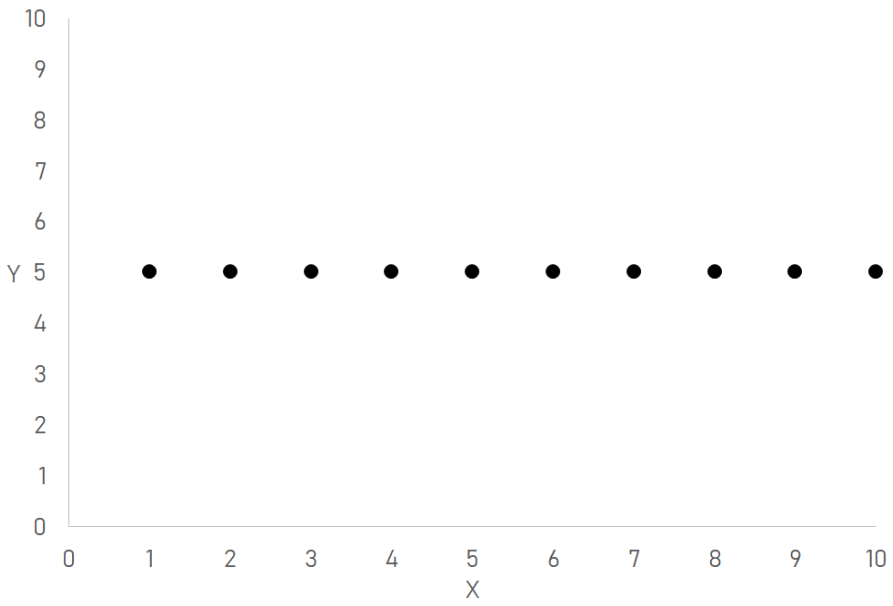

X(공통)	Y(왼쪽)	Y(오른쪽)	X(공통)	Y(왼쪽)	Y(오른쪽)
1	5	5	6	5.0005	5
2	5.0001	5	7	5.0006	5
3	5.0002	5	8	5.0007	5
4	5.0003	5	9	5.0008	5
5	5.0004	5	10	5.0009	5

산점도

상관분석을 수행할 때는 반드시 함께 산점도를 그려야 한다.

- 상관계수는 두 양적변수 간 선형적 관계의 강도(strength of the linear relationship)를 보여준다.
- 그러나 현실자료에서는 두 변수가 (U자형, 역U자형, W자형 등) 비선형적(non-linear)일 수도 있다. 그 중 곡선형(curvilinear)인 경우도 흔하다.
- 산점도는 극단치(outliers)를 발견할 때도 매우 유용하다.
- 산점도에는 늘 적합선(fitting line)을 함께 그려넣자.
- Stata에서는 graph twoway scatter 명령어로 수행할 수 있다. 예쁘게 꾸미기 위한 옵션을 공부하자.