계량분석
이변량 보통최소자승

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 16, 2023

진행 순서

1. 선형회귀모형 입문
2. 회귀식에서 유의성 검정
3. 모형의 적합도
4. 고품질 통계표

선형회귀모형 입문

선형회귀모형 입문

독립변수 X와 종속변수 Y 사이의 관계를 선형적으로 묘사해보자.

- 이른바 선형모형(linear model)으로 그 관계를 아래와 같이 설정하자.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

- X_i와 Y_i, ϵ_i는 확률변수(random variable)이며 하첨자로 i가 붙어있으므로 관측치(observations)에 따라 다른 값을 가질 수 있다.
- 이때 β_0를 상수(constant) 또는 절편(intercept)이라고 부르고, β_1를 기울기(slope)라고 부른다.
- 만일 β_1이 크다면 X가 한 단위 증가할 때, Y는 더 크게 증가할 것이다(Why?).
- $X = 0$일 때, $Y = \beta_0$이다(Why?).

선형회귀모형 입문

- 기초적인 단순회귀모형은 일차방정식(linear equation)이므로 이를 쉽게 그림으로 나타낼 수 있다.
- 기억이 나지 않는다면 desmos라는 웹사이트에서 연습하자.
- β_1를 이리저리 바꾸어서 이것이 기울기임을 확인하고, β_0를 이리저리 바꾸어서 이것이 절편임을 확인하자.

선형회귀모형 입문

회귀분석은 결국 자료를 관통하는 최적합선을 찾으려는 시도이다.

- 가장 잘 맞는 직선(best-fitting straight line)을 그어 자료를 요약하는 것으로 상상해보자.
- 회귀분석(regression analysis)은 바로 그 직선에 관한 방정식을 찾으려는 시도이다.
- 점은 주어진 자료이고, 적합선은 이를 설명하는 모형인 셈이다.
- 그러나 β_0와 β_1를 어떻게 설정하더라도 결국 자료를 완벽하게 설명할 수는 없다.
- 따라서 우리는 추가적인 항(term)으로 오차항(ϵ_i)을 고려해야 한다.

선형회귀모형 입문

오차제곱합을 최소화하는 적합선이야말로 가장 잘 맞는 직선이다.

- 일단 적합선을 그린 다음에는 X가 주어질 때, Y를 예측(predict)할 수 있다.
- 실제(actual) Y_i와 예측된(predicted) $\widehat{y}$ 간의 차이는 곧 오차(error)라고 볼 수 있다.

$$\epsilon_i = Y - \widehat{Y}_i = Y_i - (\widehat{\beta_0} + \widehat{\beta_1} X)$$

- 이 오차를 줄인다는 것은 이론적 예측과 현실 데이터 사이의 괴리를 줄인다는 의미와 일맥상통한다.

선형회귀모형 입문

- 단, 오차의 합을 그냥 최소화하지 않고 오차 제곱의 합(sum of squares)을 최소화한다(Why?).
- 오차의 제곱의 합을 최소화할 수 있는 β_0와 β_1을 찾음으로서 주어진 데이터를 가장 잘 설명할 수 있는 모형을 개발할 수 있게 된다.

$$\underset{\beta_0,\beta_1}{\operatorname{argmin}} \sum_{i}^{n} e_i^2$$

- 이것이 보통최소자승(ordinary least squares; OLS)이라고 불리우는 회귀모형의 계산 원리이다.

선형회귀모형 입문

- OLS의 해(solutions) 찾기는 수학적으로 2차함수 최적화 문제(quadratic optimization problem)이다.
- 이 최적화 문제의 목적함수(objective function)는 오차의 제곱합(sum of squared error)이므로 2차항이다.
- 이 오차의 제곱을 β_0와 β_1에 대해 편미분(partial derivation)하되, 그 식을 0으로 놓고 풀면 "오차의 제곱을 최소화하는" β_0과 β_1의 값을 알아낼 수 있다.

$$\frac{\partial \sum^2}{\partial \beta_0} = 0$$
$$\frac{\partial \sum \epsilon^2}{\partial \beta_1} = 0$$

- 이 식들을 풀어 정규방정식(normal equations)을 도출해 낼 수 있다.

선형회귀모형 입문

- 위와 같이 닫힌 형태의 해(closed-form solutions)를 분석적으로 구할 수 있는데, 만약 양적 방법론을 전공하려면 이 과정을 반드시 꼼꼼하게 이해해야 한다.
- 가우스-마코프 정리(Gauss-Markov Theorem)은 이와 같이 구한 해가 최선의 선형, 편향없는 추청치(best linear unbiased estimator; BLUE)임을 증명하고 있다.
- 처음에는 스케일러(scalar)로, 다음에는 행렬(matrix)로 이 풀이를 이해해야 한다.
- 이 과정에서 미적분(calculus)과 선형대수학(linear algebra)에 대해 어느 정도의 지식이 요구된다.
- 수학의 기초를 꼼꼼히 다져두지 않으면 앞으로 배울 수 있는 내용의 수준에서 (공부한 사람과) 압도적인 격차가 벌어진다.
- 적절한 경영경제 통계학 교과서나 계량경제학(econometrics) 교과서를 참고하자. 인터넷 등에서 미분에 관한 기초자료를 활용할 수도 있다.

선형회귀모형 입문

회귀분석은 인과분석이 아니다.

- "상관분석은 상관관계를 살펴보고, 회귀분석은 인과관계를 살펴본다"는 식의 헛소문은 전혀 사실이 아니다.
- 회귀분석을 통해 계산된 회귀계수는 사실 수학적으로 꼼꼼히 따져보면 표준화된 상관계수에 불과하다.
- 비실험적 자료(non-experimental data) 혹은 관찰자료(observational data)라고 불리우는 일반적인 사회과학 데이터를 가지고 평범하게 회귀분석하였다면 단지 상관관계만을 파악한 것이다.
- 물론 인과관계가 아니라고 연구로서 무가치해지는 것은 아니다. 다만 회귀분석의 결과를 해석할 때 인과관계로 거짓보고만 하지 않으면 된다.

선형회귀모형 입문

일단 Stata에서 실습부터 해보자.

- mroz 자료를 사용하여 여성의 소득 lwage을 본인 학력수준 educ으로 설명해보자.
- Stata에서 회귀분석 명령어는 regress이다. 명령어 뒤에는 종속변수가 먼저 옴에 주의할 것.
- 결과표는 크게 (1) 분산분석(ANOVA), (2) 요약정보, (3) 추정된 회귀모형의 세 부분으로 나뉜다.
- 이 결과표에 근거하여 추정된 회귀식을 작성해보자.
- predict 명령어를 사용해 $\hat{Y}$과 $\hat{\epsilon}$을 각각 추정해보자.

회귀식에서 유의성 검정

회귀식에서 유의성 검정

회귀분석에서도 표본을 넘어 모집단의 성격을 추리해야 한다.

- 설령 우리가 오차제곱항을 최소화하는 b_0과 b_1를 구했다고 하더라도 이것은 어디까지나 표본의 성격, 즉 통계량(statistic)일 뿐이다.
- 우리는 (다른 추리통계학에서와 마찬가지로) 다음과 같은 가설 구조에 따라 모집단의 성격, 즉 모수(parameter)에 대해서도 추리해야 한다.

$$\text{상수: } H_0 : \beta_0 = 0, \quad H_a : \beta_0 \neq 0$$
$$\text{회귀계수: } H_0 : \beta_1 = 0, \quad H_a : \beta_1 \neq 0$$

- 모집단에서 수많은 표본을 뽑아 그로부터 b_0와 b_1를 구한 뒤, 이것들의 표집분포를 그린다고 상상해보자.
- 그 가상적인 표집분포의 표준편차를 (상수 및 회귀계수의) 표준오차(standard error)라고 부를 수 있다.

회귀식에서 유의성 검정

- 보통 우리는 표본을 분석하므로 모회귀모형(population regression model)과 표본회귀모형(sample regression model)은 개념상 구별된다.

$$\text{모집단: } Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$
$$\text{표본: } Y_i = b_0 + b_1 X_i + e_i$$

- 여기서 우리는 β 대신 b를, ϵ_i 대신 e_i를 사용하고 있다.
- ϵ_i가 오차항이라고 불리웠던 반면, e_i는 잔차항(residual term)이라고 불리운다.

회귀식에서 유의성 검정

t 분포를 사용하여 회귀계수와 상수에 대한 유의성 검정을 수행한다.

- 주어진 표본에서 회귀분석으로 추정된 회귀계수 $\widehat{b}_1$ 의 t 값은 아래와 같다.

$$t = \frac{\widehat{b}_1 - \beta_1}{SE_{b_1}} = \frac{\widehat{b}_1}{SE_{b_1}}$$

- 이때 t 분포의 자유도는 $n-1$이다.
- 귀무가설이 옳다는 전제 아래 그린 표집분포는 t 분포한다. 표본에서 추정된 검정통계량 t 값의 위치를 확인해보고 그보다 극단적인 t 값을 얻게 될 확률, 즉 유의확률(p-value)을 계산할 수 있다.
- 만일 유의확률이 0.05보다 작다면 우리는 95% 신뢰수준에서 귀무가설($H_0 : \beta_1 = 0$)을 기각하고 대립가설($H_a : \beta_1 \neq 0$)을 채택할 수 있다.

회귀식에서 유의성 검정

Stata에서 유의성 검정 결과를 확인해보자.

-
- mroz 자료를 사용하여 여성의 소득 lwage을 아버지 학력수준 fatheduc으로 설명해보자.
- 유의성 검정을 수행해보고 의미를 해석해보자.
- 추정 결과(ereturn)는 행렬과 스케일러로 재사용할 수 있다.
- 검정통계량 t 값과 유의확률(p-value)를 직접 계산해보자.
- 유용한 기능 가운데 하나는 e(sample)인데 회귀모형에 사용된 표본을 알려준다.

단순회귀모형의 유의성 검정

통계적 유의성이 말해주는 의미를 명확히 이해하자.

- 통계적 유의성을 해석할 때 가장 흔한 실수 중 하나는 유의확률(p-value)이 작은 것을 가지고 선형적 관계의 강도(strength of linear relationship)로 해석하는 일이다.
- 유의확률은 단지 $H_0 : \beta = 0$라는 옳은 귀무가설을 기각하는 가능성을 보여줄 뿐이다.
- 실질적 유의성(substantial significance)은 통계적으로 유의한가 여부와 상관없이 실제로 얼마나 그 강도가 센가의 문제를 다룬다.
- 예컨대 한 시간 게임을 더하게 되면 독서시간이 2분 줄어든다는 발견(Cummings and Vandewater 2007)은 설령 통계적으로 유의하더라도 실질적으로는 그다지 유의하지 않다.
- 그러므로 (통계적으로 유의한 결과를 얻었더라도) 그 관계의 그래프를 그려보고 실제로 해석해보아 실질적 유의성이 얼마나 높은지 판단할 필요가 있다.

Cummings, Hope M. and Elizabeth A. Vandewater. 2007. "Relation of Adolescent Video Game Play to Time Spent in Other Activities." Archives of Pediatrics Adolescent Medicine 161(7): 684-689.

모형의 적합도

모형의 적합도

이제 자신의 회귀모형을 평가해보자.

- 우리가 모형(model)을 세워 그것을 현실 데이터에 맞추어(fit) 본 이상, 이것이 얼마나 잘 맞는가를 말할 수 있어야 한다. 이것이 모형의 자료 적합도(goodness-of-fit)이다.
- 오늘은 일단 두 가지 적합도 지표(goodness-of-fit indices)를 공부한다:

  (1) 결정계수(R^2) 또는 조정된(adjusted) 결정계수(R^2)
  (2) 제곱근평균제곱오차(root mean square error; RMSE).
- 어느 한 가지 지표에만 맹목적으로 의존하지 않고 모든 지표들을 균형있게 살펴보면서 자신이 세운 모형이 얼마나 자료에 잘 맞는가를 확인해야 한다.
- 물론 적합도 지표에 근거해 여러 가지 모형들을 비교 평가할 수도 있다.

모형의 적합도

가장 널리 알려진 적합도 지수는 결정계수이다.

- 결정계수(coefficient of determination)는 R^2 라고 불린다.
- 결정계수는 제법 흥미로운 수리적 아이디어를 통해 계산된다.
- 우리에게 데이터가 주어지고 여기에 총변량(total variation)이 있다면, 이것은 모형에 의해 설명되는 변량(explained variation)과 그렇지 못하고 남은 변량(residual variation)의 합이라고 할 수 있다.

$$\sigma^2_{total} = \sigma^2_{explained} + \sigma^2_{residual}$$

모형의 적합도

- 그렇다면 설명되는 변량의 비율(ratio)은 모형의 높은 설명력 내지 데이터 적합도를 의미한다고 볼 수 있다.

$$R^2 = \frac{\sigma^2_{explained}}{\sigma^2_{total}} = 1 - \frac{\sigma^2_{residual}}{\sigma^2_{total}}$$

- 이것이 바로 결정계수 R^2의 직관적 의미이다.
- 변량의 비율이므로 0과 1사이에 놓인다. 1에 가까울수록 모델은 높은 적합도를 보인다고 할 수 있고, 0에 가까울수록 모델은 형편없는 적합도를 보인다고 할 수 있다.
- 이제 남은 문제는 세 변량들이 어떤 식으로 정의되는가를 파악하는 것이다.

모형의 적합도

독립변수 X가 없을 때 종속변수 Y를 가장 잘 예측하는 요소는 무엇일까?

- 이 질문은 생각보다 매우 중요하다! 그것은 바로 종속변수의 평균($\bar{Y}$)이다(Why?). 우리는 사실 학부 시절 이른바 중심성향(central tendency)에 관해 공부하면서 이것을 은근슬쩍 배웠다.
- 이 원리는 우리에게 중요한 원칙 하나를 제공한다: "어떤 모형을 세우던지 최소한 종속변수의 평균($\bar{Y}$)보다는 나은 설명력을 보여야 한다."
- 종속변수의 평균 $\bar{Y}$은 일종의 기준점이자 최소한의 바닥이다. 이것보다도 못한 모형은 아무런 가치도 없다.
- 한편 종속변수의 실제 값(Y_i)은 일종의 이상점이자 최고의 천장이다. 이것은 모형이 추구할 수 있는 최고의 이상이다.
- (직관적으로 설명한다면) 당연히 모형의 예측값($\widehat{Y}_i$)은 Y_i와 $\bar{Y}$ 사이 어딘가 놓이리라 생각할 수 있다(물론 실제로는 꼭 그렇지 않을수도 있다).

모형의 적합도

- (아주 엄밀하지는 않지만) 그림을 통해서 우리는 총변량이 "설명된 변량"과 "잔여 변량"의 합임을 직관적으로 이해할 수 있다.

$$(Y_i - \bar{Y}) = (Y_i - \widehat{Y}_i) + (\widehat{Y}_i - \bar{Y})$$

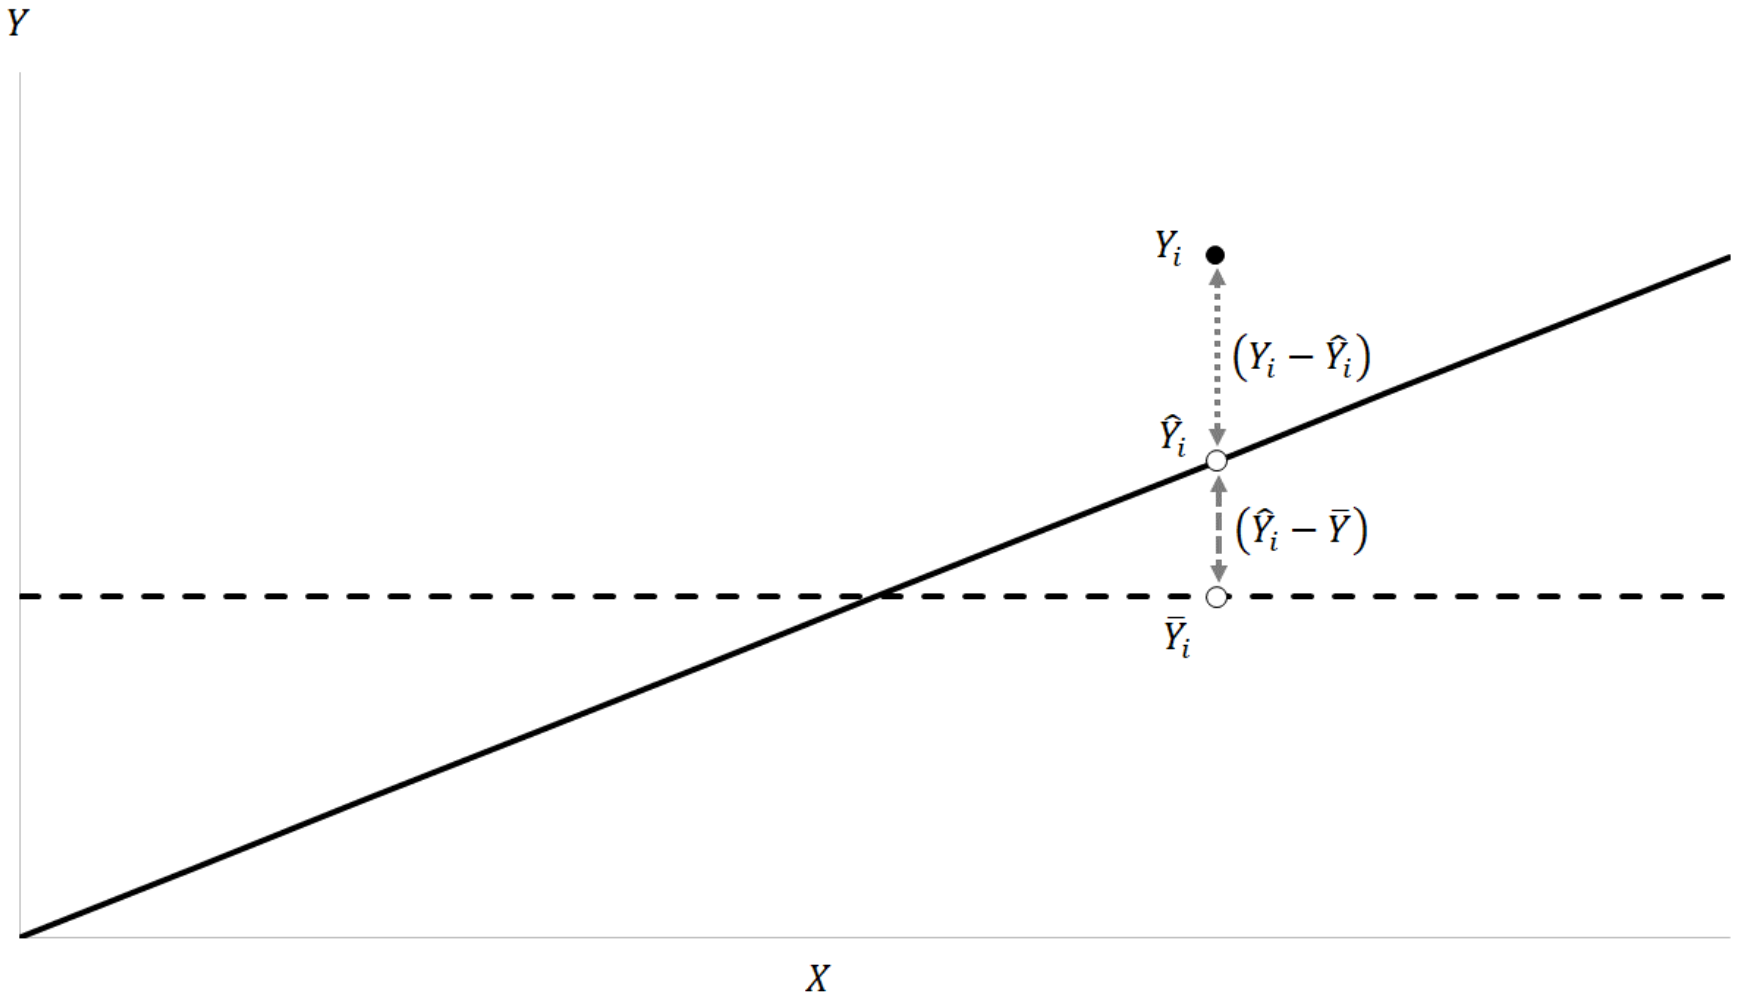

모형의 적합도

- 우리는 이제 제곱합(Sum of Squares; SS) 개념을 가지고 다음의 공식에 도달할 수 있다.

$$SS_{Total} = SS_{Explained} + SS_{Residual}$$
$$\sum (Y_i - \bar{y})^2 = \sum (Y_i - \widehat{Y}_i)^2 + \sum (\widehat{Y}_i - \bar{y})^2$$

- 당연히 R^2에 관해서도 정의할 수 있다.

$$R^2 = \frac{SS_{Explained}}{SS_{Total}} = \frac{\sum (Y_i - \widehat{Y}_i)^2}{\sum (y - \bar{y})^2} = 1 - \frac{SS_{Residual}}{SS_{Total}} = 1 - \frac{\sum (\widehat{Y}_i - \bar{y})^2}{\sum (Y_i - \bar{y})^2}$$

- 아까 그림을 통해 되새겨보면, Y_i에 더 가까운 위치에 $\widehat{Y}_i$가 놓일수록 R^2 역시 높으리라고 추측할 수 있다.

모형의 적합도

결정계수에 대해 알아둘 만한 것들이 있다.

- 결정계수가 작다는 것이 무엇을 뜻하는지 생각해보자. 그것을 크게 만드는 것이 사회과학연구의 목적이 아닐 수도 있다(Why?).
- 결정계수가 R^2 인 것은 우연이 아니다. 모상관계수 ρ의 추정량인 표본상관계수 r은 결정계수 R^2 의 제곱근이기 때문이다.
- 증명은 상당히 어려우므로 Stata에서 간단히 확인해보자.
- 만약 회귀모형에서 아래와 같이 상수 b_0가 포함되어 있지 않다면, 일반적인 결정계수 공식은 더이상 사용할 수 없다(증명 생략).

$$Y_i = b_1 X_i + e_i$$

모형의 적합도

다행히 제곱근평균제곱오차는 보다 직관적이다.

- 사회과학자들이 제곱근평균제곱오차(RMSE)를 무시하는데 비해, 데이터 사이언티스트들은 반대로 R^2 보다 RMSE를 우선시하는 점이 흥미롭다(Why?).
- 수리적인 관점에서 보면 RMSE는 R^2 만큼 흥미롭지는 않다. 다만 너무나 명쾌하다!
- RMSE는 MSE (Mean Squared Error)의 제곱근(square root)이다. MSE는 다음과 같이 정의된다.

$$MSE = \frac{1}{n}\sum(Y_i - \widehat{Y}_i)^2 = \frac{1}{n}\sum e_i^2$$

- 즉 오차의 제곱의 합이다. 제곱을 했으니 제곱근을 통해 팽창한 부분을 제거해야 좋다.

모형의 적합도

- RMSE은 모형을 통해 예측한 값들과 실제 데이터의 값들 사이에서 나타나는 평균적인 오차의 합으로 볼 수 있다.
- 만약 종속변수가 (0점에서 100점 사이의) 수학시험 점수이고 RMSE가 7이라면 모형을 통한 예측과 실제 값 사이에는 평균적으로 7점의 오차가 있다고 해석할 수 있다.
- Stata에서 모형적합도 지수들을 해석하고 재현해보자.

고품질 통계표

고품질 통계표

Stata에서는 esttab 또는 estout 등으로 통계표를 꾸밀 수 있다.

- 이것들은 사용자들이 만들어 배포한 명령어(user-written commands)이지만 굉장히 폭넓게 쓰인다.
- 두 명령어 모두 같은 사람이 만들었는데 접근 방식이 살짝 다르다. 상황에 따라 편리한 쪽을 사용하면 된다.
- 일단 한 번 만들어두면 앞으로 계속해서 쓸 수 있으므로 억지로 외우거나 하지 않아도 된다.
- outreg2 명령어도 있고 이쪽도 제법 유명하다. 다만 사용법이 esttab 또는 estout 과는 다르다.