계량분석
Introduction to Multiple Regression

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 23, 2023

진행 순서

1. 다중회귀모형
2. 위계적 회귀분석
3. 표준화 회귀계수
4. 모형의 적합도

다중회귀모형

다중회귀모형

다른 변수들을 통제하고 특정 변수의 영향력만을 살펴볼 수도 있다.

- 여러 개의 독립변수를 회귀모형에 투입했다면 자료에서의 나타내는 변량(variation)은 각각 대응하는 변수 안으로 분산되어 흡수된다(Why?).

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik} + \epsilon_i$$

- 그러므로 단순회귀모형(simple regression model)과는 달리 다중회귀모형(multiple regression model)은 다른 변수의 영향력으로부터 독립된 특정 변수의 순효과(net effect) 또는 부분효과(partial effect)를 살펴보는데 유용하다.

다중회귀모형

- 예컨대, 임금(ln_wage)을 종속변수로, 나이(age) 및 직무경험(ttl_exp)을 독립변수로 하는 회귀모형을 통해 "나이(age)의 효과를 통제했을 때(즉 같은 나이일 때)" 직무경력(ttl_exp)이 한 단위 변화하면 임금(ln_wage)이 얼마만큼 바뀌지 파악할 수 있다.

$$ln_wage = b_0 + b_1 age + b_2 ttl_exp + e$$

- 이렇게 "다른 요소들이 같다고 할 때(all other things being equal)"라는 표현에 대하여 경제학에서는 ceteris paribus 라는 라틴어를 사용하기도 한다."

다중회귀모형

다중회귀모형의 분석 전에 변수 체크에 주의를 기울여야 한다.

- 여러 개의 독립변수를 모델에 투입하다보면 하나하나를 꼼꼼하게 살펴보지 않고 그냥 대충 집어넣는 경우가 많다.
- 개별 변수의 척도가 어떻게 구성되어 있는지, 분포는 어떠한지, 결측치(missing values)가 있는지 등을 반드시 꼼꼼하게 살펴보아야 한다.
- Stata에서 summarize, tabulate, codebook, inspect, histogram, graph 등의 명령어를 활용해 변수를 살펴본다. 또 edit로 여러 변수들이 각각 어떤 구조 속에 있는지도 충분히 감을 얻어야 한다.
- 특정한 변수 별로 정렬(sort)하여 데이터를 살펴보는 것도 유용하다. Stata에서 sort는 그런 기능을 제공한다.

다중회귀모형

다중회귀모형의 해석에 친숙해져야 한다.

- 다른 변수들의 영향력을 통제하였을 때, 특정 독립변수 X의 값이 한 단위 변화(a unit change)하면 회귀계수 b만큼 종속변수 Y가 변화한다.
- 가령 age와 ttl_exp이 ln_wage에 영향을 미친다는 회귀모형을 세우고 보통최소자승법(OLS)에 따라 b_0, b_1, 와 b_2"를 다음과 같이 추정하였다고 하자.

$$ln_wage_i = 1.55 - 0.0065age_i + 0.050ttl_exp_i$$

- "직무경험의 효과를 통제하였을 때, 연령이 한 살 증가하면 로그 평준화임금은 0.0065만큼 감소한다."
- "연령의 효과를 통제하였을 때, 직무경험이 한 단위 증가하면 로그 평준화임금은 0.050만큼 증가한다."
- "연령과 직무경험이 모두 0일 때의 로그 평준화임금은 1.55이다."

위계적 회귀분석

위계적 회귀분석

단순한 회귀모형에서 복잡한 회귀모형으로 점진적으로 발전시켜야 한다.

- 위계적 회귀분석(hierarchical regression analysis)을 통해 회귀계수 및 유의성 여부의 변화를 관찰할 수 있다.
- 단계적으로 독립변수를 모델에 투입하여 점차 회귀계수와 유의성이 변화하는 모습을 관찰할 수 있다. 이때 어떤 변수를 어떤 순서대로 넣는가는 전적으로 연구자의 몫이다.
- 단번에 수많은 독립변수를 넣어 근사한 회귀모형을 만들고 싶은 유혹에 빠지기 쉽지만, 하나하나 변수를 넣어가면서 차분히 회귀모형을 설계하는 것이 바람직하다.

위계적 회귀분석

- 특히 독자는 다른 모형 설정(model specification)의 가능성에 대해 아는 바가 없기 때문에 연구자는 이에 관한 정보를 충실히 보여주어야 한다(Why?).
- 논문에서 꼭 보고하지 않더라도 수많은 대안모형들을 만들어 살펴보고, 변수 투입에 따른 변화를 꼼꼼히 살펴보아야 한다.
- 특히 기존 문헌에서 중요하게 보고되었던 독립변수가 빠지면 심사자에게 지적을 받기 쉽다. 그러므로 "(이를 고려해보았지만) 연구의 발견에는 큰 변화가 없었다" 하는 식으로 보고해야 할 수도 있다.

위계적 회귀분석

Stata에서 연습해보자.

- 임금(ln_wage)을 설명하기 위해 (1) 나이(age)을 독립변수로 한 회귀분석을 수행해보자.
- 뒤이어 (2) 나이와 직무경험(ttl_exp)을 넣은 회귀분석을 수행해보자.
- 마지막으로 (3) 나이, 직무경험(ttl_exp), 노조원 여부(union)을 넣은 회귀분석을 수행해보자.
- 표로 만들어 이 모형들을 비교해보자. 계수와 유의성은 어떻게 변화하는가? 왜 그런가?

위계적 회귀분석

- 하나의 변수에라도 결측치가 있다면 그 행(row)을 아예 모두 삭제할 수 있다. 이것을 목록별 삭제(listwise deletion)이라고 부른다.
- 결측치가 전반적으로 적다면 목록별 삭제가 큰 문제를 일으키지 않는다.
- 특히 다중회귀모형에서 새로운 변수를 넣기 때문에 그보다 단순한 모형(가령 단순회귀모형이나 투입된 변수가 적은 다중회귀모형)과 관찰값의 수가 달라질 수 있다. 이렇게 되는 경우를 일단 피하도록 하자.
- 보다 복잡한 모형 안에 내포될 수 있을 때 이를 내포모형(nested model)이라고 부른다.

위계적 회귀분석

- 두 모형 사이에 사용된 표본이 일치할 때만 내포관계를 따질 수 있다.
- 아래 모형 (1b)에서 $b_2 = 0$이라는 제약(constraint)이 붙는다면 모형 (1a)과 똑같게 된다.

$$Y = b_0 + b_1 X_1 + e \tag{1a}$$

$$Y = b_0 + b_1 X_1 + b_2 X_2 + e \tag{1b}$$

- 내포관계 없이는 이런 당연한 관계가 성립하지 않는다(Why?).

위계적 회귀분석

통제변수의 의미를 과잉해석해서는 안된다.

- 우리는 종종 관심변수(variables of interest)와 통제변수(control variables)를 구별한다.
- 우리의 연구문제에 따라 "교육수준이 임금에 미치는 영향"에 관심이 있다면 교육수준이 우리의 관심변수가 되고, 나머지 (잠재적으로 임금에 영향을 미칠 수 있는) 다른 모든 독립변수들은 이른바 통제변수로 취급된다.
- 하지만 이것은 철저하게 주관적으로 붙이는 의미이자 이름일 뿐이고 모델 안에서 변수들의 지위는 완벽히 평등하다.
- 실무나 논문에서는 통제변수가 갖는 실질적 함의에 대해서 대체로 논의하지 않는다.

위계적 회귀분석

"다른 변수를 통제한다는 것"의 의미를 명확하게 이해해야 한다.

- Stata에서 predict로 구한 $\widehat{Y}$는 관심변수 뿐 아니라 다른 변수들에 의해서도 함께 영향을 받기 때문에, 관심변수와 종속변수 간의 연관성을 살펴보기에는 부적합하다 (Why?).
- 그러므로 모든 통제변수의 영향력을 일단 고정(fix)시켜 놓고 관심변수와 종속변수의 연관성을 살펴보면 편리하다.
- 어떤 변수를 대표하는 값으로는 보통 평균(mean)이 거론되기 때문에 "통제변수의 영향력을 통제하기 위해" 관심변수를 제외한 나머지 통제변수들은 평균에 그 값을 고정시켜 놓고 해석할 수 있다.

위계적 회귀분석

- 만일 ttl_exp이 관심변수라면 다음과 같이 age을 표본평균에 고정시킨다.

$$\text{age}_i = \overline{\text{age}}$$

- 이제 ttl_exp의 변화에 따른 ln_wage의 차이를 예측할 수 있다.

$$\begin{aligned} E(ln_wage) &= 1.236 - 0.005\overline{age} + 0.050ttl_exp \\ &= 1.236 - 0.005 \cdot 29.05 + 0.050ttl_exp \\ &= 1.091 + 0.050ttl_exp \end{aligned}$$

- 일단 방정식을 단지 두 변수 사이의 관계로 축약했다면 그래프도 그릴 수 있다.
- Stata에서는 margins와 marginsplot을 사용한다. 이 명령어들의 옵션과 그래프를 꾸미는 법을 철저하게 연습해야 한다.

위계적 회귀분석

- 참고로 위계적 회귀분석(hierarchical regression analysis)과 위계적 선형모형(hierarchical linear model)은 상이한 것이다.
- 위계적 선형모형은 이른바 다층모형(multilevel model)을 의미하며 지역/조직/시간 속에 내포된 개체(individuals)를 분석할 때 유용하다.

표준화 회귀계수

표준화 회귀계수

회귀계수를 표준화하여 변수의 상대적 영향력을 판단할 수 있다.

- 어떤 독립변수가 종속변수를 가장 잘 설명하나? 회귀계수의 크기만 보고 이것을 판단할 수 없다.
- 이는 각 독립변수의 표준편차가 다르기 때문이다. 어떤 변수는 겨우 [1,10] 사이에 놓인 반면, 어떤 변수는 [-9999,9999] 사이에서 변화할 수 있다.
- 그러므로 비교를 위해서는 회귀계수 b를 표준화(standardization)해야 한다.
- 표준화된 회귀계수를 β로 표현하는데 이를 모회귀계수와 혼동하지 않도록 주의한다.

표준화 회귀계수

- 몇 가지 표준화 방식이 있는데, 가장 널리 사용되는 것은 다음의 전체 표준화 베타계수 (fully standardized beta coefficients)이다.

$$\beta = b\frac{s_X}{s_y}$$

- 원회귀계수(raw coefficient)에 독립변수/종속변수의 표준편차 비율 s_X/s_y를 곱하여 구하는데 공식의 의미를 꼼꼼히 살펴보자.
- 추정된 베타계수의 크기를 보고 곧바로 여러 독립변수들 사이에서 상대적 영향력을 비교할 수 있다(Why?).

표준화 회귀계수

- 베타계수 β의 해석은 조금 특별하다: "X가 1 표준편차만큼 변화할 때, Y는 β 표준편차만큼 변화한다."
- 원회귀계수 b의 경우 "X가 한 단위 변화할 때, y는 b 만큼 변화한다"로 해석했었다.
- 원회귀계수는 자료 본래의 단위를 사용하지만, 베타계수에서는 표준편차를 단위로 사용하여 해석한다(Why?).
- Stata에서는 beta 옵션으로 이를 구할 수 있다.

표준화 회귀계수

- 사회학 분야의 권위있는 저널에서 살펴보면 표준화된 베타계수는 예전에 비해 그다지 인기가 없는 듯 하다.
- 실용적 목적과는 별개로 베타계수는 회귀계수가 사실 “표준화된 상관계수”에 불과하다는 점을 수학적 증명없이도 보여준다는 점에서 유용하다.
- 관찰 자료(observational data)를 가지고 평범하게 회귀분석을 수행해서 얻은 회귀계수는 결코 인과관계를 드러내 보이지 못한다.

모형의 적합도

모형의 적합도

분산분석표 역시 회귀모형의 적합도와 관련된다.

- 다중회분석에서 수행하는 ANOVA의 가설구조는 다음과 같다.

$$H_0 : \beta_1 = \beta_2 = ... = \beta_k = 0$$
$$H_a : (\beta_1 \neq 0) \text{ or } (\beta_2 \neq 0) \text{ or } ... \text{ or } (\beta_k \neq 0)$$

- 이 귀무가설을 기각하지 못한다면 설정한 모형은 완전히 무의미한 것이다. “이 모델은 완전히 쓸모없다” 라는 귀무가설을 기각할 수 없는 것이나 마찬가지이기 때문이다.

모형의 적합도

- 단순회귀분석에서 사용된 일원분산분석의 귀무가설은 $H_0 : \beta_1 = 0$이므로 회귀계수의 t 값의 제곱과 같다(Why?).
- 일원분산분석의 검정통계량 F 값은 다음과 같다. 단 k는 독립변수의 수를 의미한다.

$$F_{(k,n-k-1)} = \frac{MS_{model}}{MS_{residual}} = \frac{SS_{between}/k}{SS_{within}/(n-k-1)}$$

- 검정통계량 F 값이 클수록 유의확률이 작아져(Why?) 귀무가설을 기각하기 쉬워진다.

모형의 적합도

다중회귀분석에서는 조정결정계수를 사용하기도 한다.

- 우리는 지난 주에 R^2가 모형의 높은 설명력 내지 데이터 적합도를 의미함을 배웠다.

$$R^2 = \frac{SS_{explained}}{SS_{total}}$$

- 다중회귀분석에서는 보정된 결정계수(adjusted R^2)를 쓸 수도 있다.

$$\text{adjusted } R^2 = R^2 - \frac{k(1-R^2)}{n-k-1}$$

(k는 독립변수의 수)

- 공식의 차이를 꼼꼼히 살펴보아 이해하자.

모형의 적합도

- 변수를 더 많이 사용할수록 두 결정계수 사이의 차이는 점점 벌어진다는 점이 알려져 있다. 그러므로 다중회귀모형 안에 변수를 많이 사용한다면 보정된 결정계수의 사용이 더 바람직할 수도 있다.
- 실험삼아 이론적으로 쓸데없는 변수(예컨대 난수)도 독립변수로 넣어보자. R-squared는 조금 더 증가하지만 Adj R-squared는 호락호락하게 증가하지 않는다 (심지어 감소하기도 한다).