계량분석
Multiple Regression in Practice

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

October 23, 2023

진행 순서

1. 부분효과의 의미
2. 누락변수 편의
3. 다중회귀분석의 실제 활용
4. 다중회귀분석 연습

부분효과의 의미

부분효과의 의미

회귀분석의 중요한 가정 가운데 하나는 완전모형설정이다.

- 종속변수에 영향을 미치는 모든 독립변수가 온전하게 측정되어 회귀모형 안에 투입되어 있다는 가정일 완전모형설정(perfect model specification)이라고 부른다.
- 이 경우 종속변수에 영향을 미치는 어떤 요인이 변화하면 이를 측정하고 있는 변수가 이를 반영한다. 회귀모형이 완전하게 설정되었다면 그 요인의 종속변수에 대한 효과는 편회귀계수(partial regression coefficient) 안으로 고립시킬 수 있다(isolate).
- 완전모형설정일 때, 고립은 완벽하고 특정 요인의 변화는 다른 독립변수의 편회귀계수에 아무런 영향을 주지 않는다(Why?).

부분효과의 의미

- 단순회귀모형에서 보통최소자승(OLS)에 따라 회귀계수를 구하면 다음과 같다.

$$b = \frac{Cov(X, Y)}{Var(X)}$$

- 한편 다중회귀모형에서는 회귀계수가 다음과 같다.

$$b = \frac{Cov(\tilde{X}, Y)}{Var(\tilde{X})}$$

- 이때 $\tilde{X}$는 다른 변수와 겹치지 않는 X만의 부분효과를 뜻한다.
- 벤 다이어그램으로 상상해보자. 가령 연령과 직무경력의 임금에 대한 효과는 일정 부분 겹치지만 각자 나름의 순효과 내지 부분효과가 있기 마련이다!

부분효과의 의미

수학적으로 검토하는 대신 Stata에서 이 원리를 간단히 실습해보자.

- lifeexp 자료에서 인구증가율(popgrowth)과 1인당 GNP(gnppc)의 두 독립변수로 기대수명(lexp)을 설명하고자 한다.
- 이때 gnppc의 편회귀계수를 직접 계산해보자.
- 분자는 popgrowth와 겹치지 않는 gnppc의 일부분 $\tilde{X}$와 종속변수 lexp 사이의 공분산이다(Why?).
- 분모는 popgrowth와 겹치지 않는 gnppc의 일부분 $\tilde{X}$의 분산이다(Why?).
- 이때 popgrowth와 겹치지 않는 gnppc의 일부분 $\tilde{X}$는 부속회귀모형(auxiliary regression model)을 추정하고 그 잔차(residual)를 통해 얻는다(Why?).
- 이렇게 계산된 값은 다중회귀계수에서 계산된 gnppc의 실제 편회귀계수와 일치한다.

누락변수 편의

누락변수 편의

앞서 설명과는 달리 완전모형설정이 위배된다면 어떻게 될까?

- 만일 (가정과는 달리) 그 변화를 측정하는 변수가 회귀모형 안에 적절히 고려되지 않았다면, 그 특정 요인의 변화는 (1) 다른 변수를 통해서 혹은 (2) 잔차 e을 통해서 종속변수에 영향을 미치게 된다.
- 결국 빠진 변수로 인해 종속변수에 대한 특정 독립변수의 순효과는 어느 정도 오염되었다고 할 수 있다.
- 그 오염된 정도를 누락변수 편의(omitted variable bias; OVB)라고 부른다.

누락변수 편의

Stata에서 누락변수 편의의 크기를 실제로 추정해보자.

nlswork 자료에서 가상의 자료를 만들어 완전모형을 갖춘 회귀분석을 수행해보자. 이때 얻은 회귀계수는 말하자면 "정답"이다!이제 그 중 하나 이상의 변수를 제외하고 회귀분석을 수행해보자. 회귀계수와 유의확률은 어떻게 달라졌나?

누락변수 편의

완전모형설정은 물론 현실적으로 거의 불가능하다.

- 누락변수 편의(OVB)는 그럴듯한 통제변수 몇 개를 집어넣으면 자동적으로 해소되는 그런 간단한 문제가 아니다.
- 사회 현상의 복잡성을 고려한다면 실증연구에서 완전모형설정은 사실상 불가능하다.
- 게다가 때로는 명백히 종속변수에 영향을 미치리라고 예상되는 요인이 있지만, 그것을 측정할 수 없는(unobservables) 경우도 있다(Why?).
- 그러므로 누락변수 편의는 언제나 사회과학 연구의 타당성을 위협한다. 우리는 기존문헌을 꼼꼼하게 살피고 이론적 통찰력에 힘입어 변수를 구성해야 한다.

다중회귀분석의 실제 활용

다중회귀분석의 실제 활용

일-생활 균형 인식은 임금노동자의 행복에 어떤 영향을 미치는가?

- 윤수인·이홍직(2020)의 모든 통계표를 순서대로 살펴보자. 어떤 식으로 진행되고 있는가?
- 주요 종속변수 및 독립변수는 어떤 항목들로 측정되고 있는가? 기술통계표는 어떻게 제시되고 있는가?
- 상관관계분석의 결과는 어떻게 요약되었는가?
- t 검정 또는 ANOVA 결과는 어떻게 제시되었는가?
- 마지막으로 〈표 8〉의 다중회귀분석 결과표에서 일-생활 균형 인식의 회귀계수를 해석해보자.

윤수인 · 이홍직. 2020. "임금노동자의 행복에 영향을 미치는 요인에 관한 연구: 인구 사회학적 요인, 좋은 일자리 요인, 일-생활 균형 요인을 중심으로." 한국사회복지학 72(2): 373–400.

다중회귀분석의 실제 활용

집합적 효능은 우울증상과 주관적 건강평가를 설명하는 다중회귀모형을 살펴보자.

- 우울증상에 관한 집합적 효능의 회귀계수를 해석해보자.
- 주관적 건강평가에 관한 집합적 효능의 회귀계수를 해석해보자.
- 우울증상에 관한 개인소득의 회귀계수가 집합적 효능을 추가하면서 어떻게 변화하는지 해석해보자.
- 주관적 건강평가에 관한 연령의 회귀계수가 집합적 효능을 추가하면서 어떻게 변화하는지 해석해보자.
- 참고로 〈표 2〉와 〈표 3〉에서는 서로 독립변수와 종속변수를 뒤바꾸어 모형을 추정하고 있다. 이것은 일반적이지 않은 관행이므로 주의해야 한다.

임훈민 · 김중백. 2014. "집합적 효능과 건강의 상호관계에 관한 연구." 보건사회연구 34(4): 441-446.

다중회귀분석 연습

다중회귀분석 연습

WAGE2.DTA를 활용하여 다음에 답하시오.

- 관찰단위는 무엇인가?
- 종속변수는 lwage이고, 독립변수는 meduc, feduc, brthord, IQ, KWW, educ, exper, tenure, age인 회귀모형을 구상하시오.
- 모형에 사용되는 모든 변수를 간단히 점검하고 의미를 파악하시오. 결측치가 얼마나 많은지 살펴보고 많지 않다면 목록별 삭제(listwise deletion) 방식으로 결측치를 제거하시오.
- 변수를 추가하는 순서에 관하여 나름의 스토리텔링을 구상하면서 위계적 회귀모형을 구축하시오. 결과표를 제시하되 반드시 사례수와 (adj.) R^2를 함께 제시하시오.
- 모형을 도시거주 여부(urban)에 따라 나누어 각각 추정하고 결과표에서 대조하시오.
- 위의 두 모형에서 무엇이 각각 가장 강력한 변수인가? 그 회귀계수를 해석하시오. 왜 그것이 가장 강력한 변수인지 사회학적인 설명을 간략히 제시하시오.

다중회귀분석 연습

다중회귀분석은 석사 초년생 레벨에서 사회통계학의 허리에 해당한다.

- 앞으로 무거운 짐을 더 높게 쌓아올릴 수 있기 위해 허리를 튼튼히 단련해야 한다.
- 응용통계학의 일종인 사회통계학 측면에서 보면 기초적인 이해를 마친 다음 가장 먼저 필요한 것은 반복 숙련이다. 많은 데이터를 가지고 계속해서 다중회귀분석을 연습하고 감을 얻어야 한다.
- 조금씩 더 숙달되면 그 안에 숨겨져 있는 수학적 원리를 공부하여 더 체계적으로 이해하고 향후 수준높은 공부를 준비한다.