계량분석
Dummy Variables

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

November 6, 2023

진행 순서

1. 이분변수
2. 다분변수
3. 범주형 독립변수 연습

이분변수

이분변수

사회학 연구에서는 범주형 변수를 사용해야 할 상황이 제법 많다.

- 우리는 지금까지 양적변수로 측정된 종속변수와 독립변수만을 사용했다. 하지만 생각해보면 양적변수로 표현하기 어려운 사회학적 연구대상도 존재한다.
- 먼저 질적변수인 종속변수는 어떨까?
- 예를 들어, 성역할 태도(gender role attitude) 중 하나로 "엄마는 직장보다 자녀를 우선시해야 한다" 라는 진술에 대해 동의/부동의를 묻고, 어떤 요인에 의해 그러한 태도를 갖게 되는지 살펴보는 문제가 있을 수 있다.
- 혹은 1–5점 사이 리커트 척도로 측정된 원자력 발전에 대해 인지된 위험도를 여러 독립변수들로 설명하려는 경우도 있을 수 있다.
- 그것은 이른바 범주형 자료분석(categorical data analysis)의 영역이며 이 수업을 모두 이수하고 난 뒤에야 공부할 수 있다.

이분변수

그러면 질적변수인 독립변수는 어떨까?

- 예를 들어 성별, 인종, 종교, 최종학력은 독립변수로서 사회학적으로 중요한 의미를 갖는다.
- 성별은 {남, 녀}, 인종은 {백인, 흑인, 아시아인, 기타}, 종교는 {개신교, 가톨릭, 불교, 기타, 종교없음}, 최종학력은 {고졸 이하, 고졸, 대졸, 대학원졸 이상} 등 다양한 범주를 상상해 볼 수 있다.
- 물론 최종학력에서 범주형 변수(categorical variable) 대신 양적변수인 교육연수를 사용할 수도 있다. 에스트로겐 분비량으로 성별을 측정한다면 어떨까? 피부의 명도(brightness)로 인종을 측정한다면 어떨까?
- 그러한 척도도 상상해 볼 수 있지만, 대체로 이런 경우 의미가 미묘하게 달라진다는 점에 주의해야 한다(여기에 관해서는 곧 다룬다).

이분변수

우리는 이미 t 검정이나 ANOVA로 범주형 독립변수를 분석할 수 있었다.

- 그건 그렇다. 하지만 통제변수(control variables)를 여러 개 투입할 수 있는 회귀분석과는 달리, (적어도 우리 배운 수준에서) t 검정과 ANOVA만으로는 다른 변수의 영향력을 통제하기 어려웠다(Why?).
- 다행히 회귀분석에서도 범주형 변수를 사용할 수 있다!
- 이를 위해 우리는 이분변수(dichotomous variable)와 다분변수(polytomous variable)를 먼저 학습한다.

이분변수

이분변수 또는 가변수(dummy variable)란 무엇인가?

- 처방, 조건, 또는 상황 등이 존재하면(present) 1로, 그것이 부재하면(absent) 0으로 가부호화(dummy coding)된 변수이다.
- 예를 들어, 처리(treatment)에 관한 가변수라면 받았다(1) 또는 안받았다(0) 중 하나의 값을 갖는다.
- "성별이 여성이다"에 관한 가변수라면 그렇다(1) 또는 아니다(0) 중 하나가 된다.
- 이분변수는 이른바 명목변수(nominal variable)의 가장 단순한 형태임에 주의하자.

이분변수

이분변수의 원리와 해석은 사실 매우 간단하다.

- 성별을 예로 들자. 이때 남자는 0, 여자는 1로 가부호화(dummy coding)하였다고 하자.
- 아래와 같이 양적변수 X가 독립변수인 이변량 회귀모형을 추정하였다면, 회귀계수 $\widehat{b}_1$와 상수 $\widehat{b}_0$를 어떻게 해석할까?

$$\widehat{Y} = \widehat{b}_0 + \widehat{b}_1 X$$

- 위 모형에서 만약 X가 가변수라도 해석은 크게 다르지 않다.

$$\begin{aligned} \widehat{Y}_{\text{남}} &= \widehat{b}_0 && (\text{if } X = 0) \\ \widehat{Y}_{\text{여}} &= \widehat{b}_0 + \widehat{b}_1 && (\text{if } X = 1) \end{aligned}$$

- 이때 남녀 간 $\widehat{Y}$의 격차는 $\widehat{Y}y_{\text{여}} - \widehat{Y}_{\text{남}} = \widehat{b}_1$이다. 이것은 그냥 가변수의 회귀계수이다!

이분변수

write 점수를 female로 예측하는 회귀분석을 연습해보자.

- b_0는 어떻게 해석할까? "남자의 write 점수는 평균적으로 50.12점이다."
- b_1는 어떻게 해석할까? "여자의 write 점수는 남자의 write 점수보다 평균적으로 4.87점(b_1=54.99-50.12) 높다."
- 여자의 write 점수는 어떻게 알 수 있을까?
- Stata에서 margins 명령어를 연습해보자.

이분변수

우리는 남자 변수와 여자 변수를 동시에 집어넣지 않았다.

- 자료에서 여자가 아니면 곧바로 남자이기 때문에 두 변수를 동시에 집어넣는 것은 아무런 의미도 없다.
- 이때 집어넣지 않은 쪽을 기준집단(reference group) 또는 근거범주(base category)라고 부른다. 우리의 예제에서는 남자가 기준집단이다.
- 우리는 기준집단이 되는 성별 범주를 0으로 가부호화하였다. 남자를 0으로, 여자를 1로 했으므로 상수는 곧바로 기준집단인 남자의 write 점수를 보여준다.
- (표현 그대로) 기준집단을 기준으로 해석하게 된다. 따라서 여러가지 의미에서 기준이 될 만한 집단을 기준집단으로 삼는 편이 좋다(Why?).

다분변수

다분변수

그런데 범주형 변수는 가변수만 있는게 아니라 다분변수도 있다.

- 예를 들어 5명의 사회경제적 지위(socioeconomic status; SES)를 를 세 범주 (1=low; 2=middle; 3=high)로 입력하였다고 하자.

id	ses
1	low
2	middle
3	high
4	high
5	middle

- 이 변수를 쪼개 다음과 같이 가부호화(dummy coding)할 수 있다:

  (1) "ses가 low이다"에 관한 첫번째 가변수(ses1)로 그렇다(1)/아니다(0).
  (2) "ses가 middle이다"에 관한 두번째 가변수(ses2)로 그렇다(1)/아니다(0).
  (3) "ses가 high이다"에 관한 세번째 가변수(ses3)로 그렇다(1)/아니다(0).

다분변수

- 사회경제적 지위 변수(ses) 하나를 다음과 같이 3개의 가변수로 재코딩(recoding)한 셈이다.

id	ses	ses1	ses2	ses3
1	low	1	0	0
2	middle	0	1	0
3	high	0	0	1
4	high	0	0	1
5	middle	0	1	0

- 잘 보면 (어디든지) 한 줄은 결국 필요가 없다. 나머지 두 줄에서 얼마든지 추측이 가능하기 때문이다.
- 아까 이분변수에서와 마찬가지로 바로 그 삭제된 범주가 기준집단이 된다. 나머지 모든 가변수가 0이면 자동적으로 이 범주를 의미하게 된다.

다분변수

다분변수에서 무엇을 기준집단으로 삼아야 할까?

- 기본적으로 상관없으므로 마음대로 정해도 된다. 하지만 이론적으로는 몇 가지 추천할 수 있는 기준이 있다:

  (1) 가장 사례 수(n)가 큰 (주류) 범주. 뒤집어 말하면 아주 작은 사례 수만 있는 범주는 피하는 것이 좋다(Why?).
  (2) 가장 동질성이 높은 범주. 뒤집어 말하면 "기타" 같은 범주는 피하는 것이 좋다(Why?).

- 기준집단을 무엇으로 삼는가에 따라 통계적 유의성 구도는 당연히 다르게 나온다(Why?). 실질적인 해석에서 손해를 보지 않으려면 여러 가지로 기준집단을 바꿔볼 필요가 있을 수 있다.
- 하지만 가장 중요한 것은 연구자의 관심이다. 관심이 가는 집단을 기준집단으로 삼아야 다른 집단과 자꾸 비교할 수 있다는 점을 기억하자(Why?).

다분변수

다분변수의 원리와 해석도 결국 이분변수와 같다.

- 사회경제적 지위(ses)의 범주는 3개가 있었으므로 여기서 하나를 뺀 2개의 가변수만 모델에 투입하게 된다.

$$Y = b_0 + b_1 \text{ses1} + b_2 \text{ses3} + e$$

- 위 회귀모형에서 ses2는 기준집단으로 빠져있는 점에 주목하자.
- 이제 가변수가 여러 개 있는 다중회귀모형을 해석하는 것과 마찬가지이다.

$$\widehat{Y}_{\text{low}} = \widehat{b}_0 + \widehat{b}_1 \qquad \text{(if ses=1)}$$

$$\widehat{Y}_{\text{mid}} = \widehat{b}_0 \qquad \text{(if ses=2)}$$

$$\widehat{Y}_{\text{high}} = \widehat{b}_0 + \widehat{b}_2 \qquad \text{(if ses=3)}$$

다분변수

write 점수를 ses로 예측하는 회귀분석을 연습해보자.

- 가장 먼저 다분변수인 ses의 범주를 빈도분포표를 통해 살펴보자. 레이블(label)과 함께 입력값에 대해서도 살펴보자.
- 다음으로는 기준집단이 될 범주를 정하자. 어느 쪽이 가장 많은 집단/범주인가? 또 어느 집단/범주가 가장 높은/낮은 종속변수의 평균값을 가지고 있나?
- Stata에서는 tabulate 명령어에 generate 옵션을 붙여 쉽게 다분변수를 직접 가부호화할 수 있다.
- 회귀분석을 할 때, 변수 이름 앞에 i.를 붙여 단항 연산자(unary operator)라고 선언하여 다분변수를 인식시킬 수 있다. 만약 b1.를 붙인다면 1번 범주가 기준집단이 된다.

다분변수

- Stata에서 margins 명령어로 조건부 평균값을 예측할 수 있다.

  (1) "ses가 low인 집단(ses1==1)의 작문 성적은 평균적으로 50.62점이다."
  (2) "ses가 middle인 집단(ses2==1)의 작문 성적은 평균적으로 51.93점이다."
  (3) "ses가 high인 집단(ses3==1)의 작문 성적은 평균적으로 55.91점이다."

- 회귀계수와 상수의 해석을 통해 집단 간 차이를 해석할 수 있다.

  (4) "ses가 high인 집단은 middle인 집단보다 작문 성적이 평균적으로 3.99점 높다."
  (5) "ses가 low인 집단은 middle인 집단보다 작문 성적이 평균적으로 1.31점 낮다."

다분변수

- 기준집단의 평균은 회귀모형의 상수가 되므로 그림에서는 Y 축 절편(interecept)에 그대로 반영된다.
- 기준집단이 되는 범주를 하나를 빼고 나머지 가변수를 "반드시" 모두 투입해야 한다.
- 예를 들어 low/middle/high로 사회경제적 지위를 분류했을 때, (middle은 기준집단이라서 뺐지만) low 마저도 빼고 high만 모델에 투입한다면, low와 middle 두 집단이 사실상 함께 기준집단이 된다(Why?).
- 이렇게 회귀모형을 만들었다면, high 집단의 작문 점수를 해석할 때 non-high 집단(즉 low 집단 + middle 집단)과 대조하는 방식으로 이루어져야만 한다. 가변수와 같은 셈이다!
- 다시 말해, 마음대로 하나를 빼거나 하면 그 뺀 범주가 기준집단과 통합되는 효과가 있음을 염두에 두어야 한다.

범주형 독립변수 연습

범주형 독립변수 연습

가변수 이외의 여러 변수들을 통제한 상태에서 가변수의 해석을 연습해보자.

- nlswork.dta에서 ln_wage를 종속변수로, union, race, grade, ttl_exp 독립변수로 하는 회귀모형을 만들자.
- 다중회귀분석에서는 언제나 모든 변수들을 하나하나 꼼꼼하게 살펴보고 모형에 투입해야 한다. 종속변수와 독립변수를 살펴보자. 결측치는 목록별 삭제(listwise deletion)로 대응하자.
- 추정된 회귀모형에서 이분변수인 노조 가입여부 union의 회귀계수를 해석해보자. 그 다음에는 다분변수인 인종 race을 해석해보자.
- 위계적 회귀모형(hierarchical regression models)을 구축하고 어떻게 변화하는지 살펴보자. 이때 적합도 지표로 R^2를 반드시 보고하자.

범주형 독립변수 연습

가변수는 꼭 0과 1로만 가부호화해야 할까?

- 만약 노조가입 여부 union에서 {0, 1}이 아니라 {1, 2}, 또는 {-1, 1}로 가부호화하면 어떨까?
- 사실 그래도 된다. 회귀계수와 상수는 변하지만 적합도 지표(R^2 나 F 등)은 변하지 않는다(Why?).
- 그러면 왜 관습처럼 {0, 1}로 주로 가부호화할까? 단지 그렇게 할 때 계수 해석이 편리하고 절편 해석도 편리하기 때문이다. item 보다 구체적으로, (1) 0을 사용하면 기준집단의 평균값이 다른 모든 집단/범주들이 0일 때 자연스럽게 상수와 일치하기 때문이고, (2) 1을 사용하면 회귀계수가 정확히 해당 집단/범주의 평균값을 보여주기 때문이다.

범주형 독립변수 연습

범주형 변수는 때로 문턱효과를 살펴볼 때 꼭 필요할 수 있다.

- 교육연수(양적변수) 변수와는 달리 최종학력(범주형 변수)은 문턱효과(threshold effects)를 살펴보기에 유리하다.
- 교육연수 grade는 양적변수이므로 해석상 단위 변화(unit change)에 따라 회귀계수의 영향력이 일정하게 작동한다.
- 즉, "고2 → 고3 변화"는 "고3 → 대1 변화"와 동등한(homogeneous) 것으로 가정된다.
- 이 가정은 타당한가? 사회적으로 구성된 최종학력의 의미는 다르다. 고등학교 중퇴와 고졸 사이에는 질적인 차이, 즉 문턱효과가 있다.

범주형 독립변수 연습

- 따라서 (고졸 미만과 고졸을 질적으로 구분하는) 다분변수인 최종학력을 회귀모형에 투입하는 것이 나을수도 있다(이것은 연구자가 판단할 문제이다).
- 이 자료에서도 대졸 여부 collgrad가 있으므로 이를 회귀모형에 넣고 비교해보자.
- (가령 출산자녀 수처럼 응답 범주의 숫자가 너무 적다면) 일부러 양적변수를 범주형 변수처럼 취급하여 회귀계수를 살펴보아야 한다.
- 사후검정(post-estimation)의 일종인 Wald 검정(Wald test)를 통해 쟁점이 되는 회귀계수가 정말 같은가 여부도 테스트해 볼 수 있다.

범주형 독립변수 연습

가변수는 예외처리에도 유용하게 쓰인다.

- 이론적인 목적에 따라, 도시에 살지 않는(c_city==0), 남부의(south==1), 흑인(race==2)을 특별한 소수자 집단으로 부각시키거나 그 영향력을 통제하고 싶다고 하자(두 표현은 회귀분석에서는 같은 의미이다).
- 그러면 이들 집단을 지시하는 가변수를 따로 만들어 하나의 변수처럼 회귀모형에 투입할 수 있다.
- 무엇이 예외인가에 대해서는 물론 이론적으로 결정되는 측면이 강하지만, 자료를 꼼꼼하게 살펴보아야만 비로소 알 수 있는 부분도 크다.

범주형 독립변수 연습

- 2000년에서 2010년 사이의 자살률을 검토하는 시계열 분석(time-series analysis)을 수행한다면 어떤 시기가 예외적일까? 아마도 2008년 금융위기는 예외적인 사건이므로 통제하는 것이 바람직할 것이다.
- 서울시의 420여개 행정동을 분석단위(unit of analysis)로 삼아 행정만족도를 조사한다고 할 때, 어떤 지역이 예외적일까? 아마도 강남4구(강남구, 서초구, 송파구, 강동구)에 속하는 행정동은 특히 부유한 지역들이므로 이들을 통제하는 것이 바람직할 것이다.

범주형 독립변수 연습

한승용(2008)을 보고 가변수가 활용되는 방식을 살펴보자.

- 연구가설은 무엇인가(172)? 사용한 원자료는 무엇인가(173)?
- 분석단위는 무엇인가(182)? 데이터가 어떻게 구성되어 있을지 상상해 보라.
- 가설을 테스트하기 위해 〈표 6〉 에서 〈표 9〉 까지 제시된 회귀분석 결과표를 보라. 각각 어떻게 가변수를 구성했는지 추론해 보라(183). 표를 보고 가변수의 회귀계수를 하나 해석해 보라(183).

한승용. 2008. "사회적 통합과 자살: 연휴가 자살자수 감소에 미치는 영향." 한국인구학 31(1): 169–198.