계량분석
OLS Assumptions (II)

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

November 13, 2023

진행 순서

1. 오차항의 가정: 조건부 영평균
2. 오차항의 가정: 등분산성
3. 오차항의 가정: 자기상관 없음
4. 오차항의 가정: 정규성
5. 회귀 가정에 대한 코멘트

오차항의 가정: 조건부 영평균

오차항의 가정: 조건부 영평균

조건부 영평균은 개념적으로 혼동스러우니 주의해야 한다.

- 먼저 조건부 영평균의 정의를 살펴보자. 조건부 기댓값(conditional expectation) 개념을 수학적으로 꼼꼼히 살펴보지 않고 넘어가기 때문에 혼란스러울 수 있다.
- 이것은 어떤 독립변수가 데이터 안에서 "특정 값"을 가진다고 전제하고($X = x$) 모형에서 구한 오차항의 평균값이 0이라는 가정이다.

$$E(\epsilon_i|X) = 0$$

- 가령 지도배부 수(map)로 이용객 수(rider)를 예측한다고 하자. 지도배부 수가 0일 때도, 100일 때도, 200일 때도, 추정 이후 모형에서 남은 오차항은 평균적으로 0이어야 한다.

오차항의 가정: 조건부 영평균

- 이 가정은 평균 독립성(mean independence)이라고도 불리운다(Allison 1998).
- 비확률적 독립변수(non-stochastic Xs) 또는 조건부 영평균 덕택에 다음의 식이 성립한다(Why?).

$$E(Y|X) = \beta_0 + \beta_1 X_1 + ... + \beta_k X_k$$

오차항의 가정: 조건부 영평균

- 의외로 기본인데 혼동하는 부분은 조건부 영평균과 영평균(zero mean)이 다르다.
- 영평균은 (가정이고 뭐고 상관없이) 정규방정식(normal equation)으로부터 당연히 도출된다(Why?).

$$E(\epsilon_i) = 0$$

- 게다가 그 실질적인 의미도 사뭇 다르다. 영평균은 무조건 평균(unconditional mean)에 관한 것이다.
- 교과서에 따라서는 영평균을 조건부 영평균 대신 써놓는 경우가 있다. 이는 비확률적 독립변수를 전제했기 때문이다. 이때는 자동적으로 $Cov(\epsilon, X) = 0$ 가정이 성립하므로 조건을 붙일 필요조차 없다(Why?).

오차항의 가정: 조건부 영평균

조건부 영평균은 상수를 회귀식 안에 넣으면 자동적으로 성립한다.

- 회귀식의 상수는 괜히 있는 것이 아니다. 설령 $E(\epsilon_i|X) = 0$가 성립하지 않더라도 그것을 성립시키기 위해 적절히 오차항에 더하기 빼기를 추가하는 상수항을 넣어주면 이 가정을 무조건 성립시킬 수 있다!
- 즉 $E(\epsilon_i|X) \neq 0$ 이더라도 $E(\epsilon_i'|X) = 0$ 이 되도록 γ를 더하고 빼주면 된다.

$$\begin{aligned} Y &= (\beta_0 + \gamma) + \beta_1 X_1 + \ldots + \beta_k X_k + (\epsilon - \gamma) \\ &= \beta_0' + \beta_1 X_1 + \ldots + \beta_k X_k + \epsilon' \end{aligned}$$

- 물론 이 경우 β_0 대신 β_0'를 얻었으므로 추정된 상수는 왜곡된다(biased).

오차항의 가정: 조건부 영평균

조건부 영평균은 특히 모형 설정에 민감하다.

- '왜곡되지 않은 상수 추정을 전제로 했을 때," 조건부 영평균 가정은 주로 모형설정 오류(model mis-specification)나 변수의 측정오류(measurement error) 등으로 인해 위협받는다.
- 만약 진정한 Y와 X의 관계를 잘 반영하지 않는 회귀모형을 데이터에 적합시켰다면 조건부 영평균이 성립하리라고 기대하기 어렵다.
- 그러나 완전모형 설정(perfect model specification)은 보통 불가능하므로 이 부분은 결국 이론과 기존문헌에 의존할 수 밖에 없다.

오차항의 가정: 조건부 영평균

조건부 영평등의 진단법은 사실 따로 없다.

- 표본을 회귀분석하고 추정한 $\hat{\epsilon}$은 이미 조건부 영평등을 가정하고 구한 것이다. 그러므로 표본의 잔차항을 열심히 살펴본다고 해서 가정의 성립 여부를 검증할 수 없다.
- Stata에서 비선형관계를 선형모형으로 적합시킨 다음, 잔차(residuals)를 계산하고 이를 독립변수 X에 대해 산포도와 적합선을 그려보자.
- 이러한 그림을 RVP 도표(Residuals-Versus-Predictor plot)라고 부른다.
- $E(\epsilon_i|X_i) = 0$가 성립하고 그렸으므로 상식적으로 RVP 도표는 "모든 X에 대해" $Y = 0$에 계속해서 수평선이 된다.
- 선형모형에서 그린 RVP 도표와 비선형모형에서 그린 RVP 도표를 비교해보자.

오차항의 가정: 등분산성

오차항의 가정: 등분산성

등분산성은 오차항의 분산이 X에 따라 변화하지 않는다는 가정이다.

- 이 가정의 의미를 그림으로 이해하자. 독립변수가 어떤 값이든 오차항이 일정하게 퍼져있음을 의미한다.

$$Cov(\epsilon_i, \epsilon_i) = Var(\epsilon_i|X) = \sigma^2$$

- 이 가정이 위배되는 가장 흔한 원인으로 두 가지가 지목된다:

  (1) 변수에 이상점(outliers)이 있거나 분산이 커서 들쭉날쭉한 값이 끼어있는 경우,
  (2) 모형에 반드시 있어야 하는 변수가 빠져 불완전한 모형 설정(model mis-specification)이 이루어진 경우.
- 등분산성이 위배되는 상황을 이분산성(heteroscedasticity)이라고 부른다.

오차항의 가정: 등분산성

RVP 도표나 RVF 도표를 그려보는 것이 가장 기본적인 진단법이다.

- Stata에서 시뮬레이트된 자료를 활용하여 일부러 불완전한 회귀모형을 추정해보자.
- 추정된 잔차항과 독립변수와의 관계를 살펴보면 독립변수가 변화할 때 추정된 잔차항의 분산도 변화하는 현상을 확인할 수 있다.
- 다음에는 완전한 모형을 만들어 회귀분석을 해보자.
- 이번엔 독립변수가 변화하더라도 추정된 잔차항의 분산은 일정함을 확인할 수 있다.

오차항의 가정: 등분산성

- 좀 더 복잡한 방법은 Breusch-Pagan 검정이 있다.
- 귀무가설은 등분산성이고 대립가설은 이분산성이다.

$$H_0 : Var(\epsilon) = \sigma^2$$
$$H_a : Var(\epsilon) \neq \sigma^2$$

- 검정통계량은 χ^2 이다(Why?).
- 대부분의 χ^2 검정이 그러하듯 이 검정도 표본 수에 지나치게 민감하다는 단점이 있다.

오차항의 가정: 자기상관 없음

오차항의 가정: 자기상관 없음

자료 안에서 오차항 사이에는 상관관계가 없어야 한다.

- 데이터에 대해 회귀모형을 적합시킨 뒤, 임의의 i번째 사례에 대해 추정된 오차항 e_i와 (그와는 다른) j번째 사례에 대해 추정된 오차항 e_j 사이에 공분산(covariance)이 0이라는 가정이다.

$$Cov(\epsilon_i, \epsilon_j) = 0$$

- 개별 사례들의 성격은 오로지 모형 속에 추가된 독립변수로 공통점을 완전히 설명할 수 있었고, (설명하지 못하고 남은) 오차항 사이에는 평균적으로 아무런 공통점도 남아있지 않아야 한다.

오차항의 가정: 자기상관 없음

- 시공간적 자기상관(autocorrelation)이 존재할 때 특히 이 가정이 위배된다.
- (분석단위가 개인인 경우) 사회학이나 사회역학(social epidemiology)의 세계관에서 이 가정은 특히 문제가 된다.
- 시계열적 자기회귀(time-series autoregression)는 현재의 오차항 e_t이 과거의 오차항 e_{t-1}과 자기상관을 갖는 현상을 지칭한다.
- "오늘의 나를 가장 잘 설명하는 변수는 과거의 나"라는 평범한 진리는 자기상관 없음 가정을 위배하고 있다.

오차항의 가정: 자기상관 없음

- 공간적 자기회귀(spatial autoregression)는 특정 지역의 오차항이 그 근린의 오차항과 자기상관을 갖는 현상을 지칭한다.
- "가까운 것은 먼 것보다 중요하다(Near things are more related than distant things)"는 토블러의 지리학 제1법칙(Tobler's First Law of Geography)을 떠올릴 것.
- 뒤집어 말하자면, 이렇게 시계열 자료(time-series data)나 공간자료(spatial data)가 주어진 경우 보통최소자승(OLS) 회귀분석으로는 적절한 분석이 불가능한 까닭을 여기서 알 수 있다.

오차항의 가정: 자기상관 없음

자기상관 없음의 진단법은 지금 고민할 필요가 없다.

- 자기상관이 나타나는 상황 자체가 이미 수준 높은 고급사회통계학의 영역이다.
- 예컨대 흔히 시계열분석에서는 Durbin-Watson 통계량(statistic)부터 공부하기 시작하고, 공간회귀분석에서는 Moran's I부터 공부하기 시작하는데 이미 우리 수업의 단계를 훨씬 넘어선 것이다.
- 데이터의 수집 과정과 성격 자체를 들여다보고 자기상관이 존재할 것인지를 개념적으로 판단하자.

오차항의 가정: 자기상관 없음

등분산성 가정과 자기상관 없음 가정은 사실 밀접하게 연관되어 있다.

- 오차항의 공분산행렬(variance-covariance matrix)은 다음과 같이 가정된다.

$$Cov(e_i, e_j) = \begin{bmatrix} \sigma^2 & 0 & 0 & \cdots & 0 \\ 0 & \sigma^2 & 0 & \cdots & 0 \\ 0 & 0 & \sigma^2 & \cdots & 0 \\ & & \vdots & & \\ 0 & 0 & 0 & \cdots & \sigma^2 \end{bmatrix}$$

- 대각행렬 부분이 바로 등분산성 가정이고 그 나머지 부분은 자기상관 없음 가정에 의해 채워진다(Why?).

$$Cov(\epsilon_i, \epsilon_i) = Var(\epsilon_i|X) = \sigma^2$$
$$Cov(\epsilon_i, \epsilon_j) = 0$$

오차항의 가정: 정규성

오차항의 가정: 정규성

필수적인 가정은 아니지만 가설검정 절차를 편리하게 만들어준다.

- 오차항은 정규분포한다는 것이 이 가정의 전부이다.

$$\epsilon_i \sim N(0, \sigma^2)$$

- 조건부 영평균과 등분산성을 결합한다고 해도 자동적으로 이 가정이 성립하는 것은 아니다(Why?). 두 가정은 정규분포에 대해 어떠한 전제도 하지 않는다!
- 이 정규성 가정이 워낙 포괄적(overarching)인 까닭에 논문에서는 이것 하나만 쓰고 "가정이 성립한다고 전제한다"라고 요약할 때가 많다.

오차항의 가정: 정규성

- 학부과정에서 배운대로 소표본인 경우 오차항이 정규분포해야만 회귀계수의 t 검정을 위해 t 분포를, 모형 적합도 검정을 위해 F 분포를 믿고 사용할 수 있다.
- 만약 이 가정이 없었다면, t 통계량이나 F 통계량의 논리는 더이상 성립하지 않으므로 신뢰구간(confidence interval)과 유의성 검정 결과를 신뢰할 수 없게 된다.
- 한편 사례가 충분히 크다면(대표본) 이 가정은 불필요하다. 표본이 커지면 t 분포는 자연스럽게 Z 분포를 따라가고, F 분포의 근본이 되는 χ^2 분포 역시 대표본에서는 정규분포에 근접하기 때문이다.

오차항의 가정: 정규성

정규성 가정은 보통 그림을 통해 진단한다.

- 표준화된 정규확률도표(standardized normal probability plot) 혹은 PP (Percent-Percent) 도표를 그린다.
- 이 그림의 Y 축은 이론적 정규분포의 누적표준분포, 즉 기대누적확률(expected cumulative probability)를 의미하고, X 축은 관찰된 데이터의 누적표준분포, 즉 관찰누적확률(observed cumulative probability)를 의미한다.
- 두 값들이 정확히 일치하면 그림은 45도 선을 따라가기 마련이지만, 만일 그렇지 않다면 정규성 가정이 아무래도 위배되고 있다고 의심할 수 있다.
- Shapiro-Wilk 정규성 검정(test of normality)라는 기법도 있다.
- 이들 기법은 사실 t, χ^2, F 분포 등을 사용하기 앞서 정규성 여부를 확인하기 위해서도 가끔씩 쓰이곤 한다. 하지만 대표본이라면 이 가정에 그렇게까지 집착할 필요는 없어 보인다.

회귀 가정에 대한 코멘트

회귀 가정에 대한 코멘트

가정이 위배되면 더이상 보통최소자승이 최적이라고 보장할 수 없다.

- 보통 연구자들은 다음과 같이 (모든 가정을 충족하는) 고전적인 회귀모형을 짧게 정의한다.

$$\mathbf{Y} = \mathbf{XB} + \mathbf{e}$$

$$\mathbf{e} \sim N(0, \sigma^2 \mathbf{I})$$

- 볼드(bold)로 두껍게 표시된 기호는 이것들이 행렬임을 의미한다.

회귀 가정에 대한 코멘트

회귀분석의 가정은 고급통계학의 관문과도 같다.

- $1 + 1 = 2$ 를 배우는 것은 금방이지만 왜 이러한 식이 성립하는지 공리(axioms)나 가정을 공부하는 것은 어렵다.
- 회귀분석의 가정을 공부할 때는 일단 각 가정이 무엇을 의미하는가를 살펴보고 이를 직관적으로 파악하는데 중점을 두자. 처음 공부할 때는 증명은 일단 생략하고 결론이 무엇인가를 파악하자.
- 물론 사회통계학 자체를 전공한다면 수학 공부를 게을리해서는 안된다. 반드시 교재를 읽고 꼼꼼히 공부해야 한다.

회귀 가정에 대한 코멘트

- 가정을 이해하는데 성공했다면 더 나아가 그 가정이 위배되었는가 여부를 살펴보는 방법, 즉 진단(diagnosis)과 처방(remedy)을 공부해야 한다. 이제 우리 수업의 나머지 부분들은 여기에 집중한다.
- 보통최소자승 선에서 해결할 수 없는 수준으로 가정이 위배된다면 이에 대응하는 별도의 기법을 사용해야 한다.
- 이 고급통계 기법들은 각각의 가정 위배에 대응하여 다루어진다. 그런 의미에서 OLS 의 가정에 관해 심도있게 학습하는 것은 고급통계학으로의 관문(gateway)으로 이어진다고 할 수 있다.