계량분석
Multinomial and Ordered Logistic Regression

김현우, PhD[1]

[1] 충북대학교 사회학과 조교수

December 11, 2023

진행 순서

1. 로지스틱 회귀분석의 주의점
2. 다항 로지스틱 회귀분석
3. 서열 로지스틱 회귀분석

로지스틱 회귀분석의 주의점

로지스틱 회귀분석의 주의점

종속변수가 {0, 1}이라고 무조건 로지스틱 회귀분석을 사용할까?

- 사실 이게 그렇게 간단한 문제가 아니다.
- 로지스틱 회귀분석은 완전설정된 모형(fully specified model)에서 설명되고 남은 오차 ϵ이 로지스틱 분포를 따른다는 가정을 전제하고 있다.

$$\epsilon \sim Logistic(0, 1)$$

- 이 가정은 경험적으로 검증될 수 없으며 이로 인해 상당히 복잡한 방법론적 이슈가 발생한다.
- 그러나 이해하지 못해도 괜찮다! 대부분의 리뷰어도 수학을 잘 모르기 때문이다.

로지스틱 회귀분석의 주의점

때로는 통계분석 패키지가 로지스틱 회귀식 추정에 실패하기도 한다.

- 최대우도법(MLE)은 β_0와 β_1을 수치해석으로 얻어내기 위해 반복법(iteration method)을 사용하는데, 아무리 반복해도 해를 얻지 못한 경우를 수렴 실패(convergence failure)라고 한다.
- 수렴 실패를 바로잡기 위해서는 일단 모형을 단순화시키고 다시 복잡화의 과정을 밟는 편이 좋다. 이 과정에서 추가 투입하는 변수를 신중하게 선택한다.
- 특히 완전예측(perfect prediction) 또는 분리(separation)가 종종 문제를 일으키므로 독립변수(특히 가변수)를 신중히 살펴보아야 한다(Why?).

로지스틱 회귀분석의 주의점

- 표본 크기가 너무 작으면 분명히 문제가 된다. 다만 그 대책에 관해서는 약간 논쟁이 있다.
- 표본의 크기 n 자체도 문제지만 그보다 자료 안에 성공(1) 사례수가 너무 적으면 이른바 희소사건 편의(rare event bias) 문제를 일으킨다는 지적이 있다.
- 또한 생각보다 중요한 이슈 중 하나는 극단값(outliers)의 유무이므로 매우 주의해서 살펴야 한다.

로지스틱 회귀분석의 주의점

- 종속변수가 가변수일 때, 로지스틱 회귀분석이 유일한 대안인 것은 아니고, 프로빗(probit) 회귀분석과 보 로그로그(complementary log-log; cloglog) 회귀분석같은 대안도 있다.
- 로지스틱 회귀분석과는 종속변수가 살짝 다르다.

$$ln\frac{P(Y=1|X)}{1-P(Y=1|X)} = \beta_0 + \beta_1 X \qquad \text{(logit)}$$

$$\Phi[P(Y=1|X)] = \beta_0 + \beta_1 X \qquad \text{(probit)}$$

$$ln(-ln([1-P(Y=1|X)]) = \beta_0 + \beta_1 X \qquad \text{(cloglog)}$$

로지스틱 회귀분석의 주의점

- 그런데 무엇을 사용하건 상당히 비슷한 결과를 얻기 때문에 너무 고민하지 않고 로지스틱을 사용해도 괜찮다.
- 가령 로짓, 프로빗, 보 로그-로그의 누적분포함수(cumulative distribution function; CDF)들을 비교해보면 매우 유사하다.

다항 로지스틱 회귀분석

다항 로지스틱 회귀분석

종속변수가 범주형이라면 다항 로지스틱 회귀모형 등을 활용한다.

- 앞서 우리는 종속변수가 가변수일 때, 이른바 (이항) 로지스틱 회귀모형을 사용하였다.
- 종속변수가 명목 척도(nominal scale)를 가진 범주형이라면 다항(multinomial) 로지스틱 회귀모형을 사용할 수 있다.
- 이항 로지스틱을 먼저 철저하게 이해하면 다른 로지스틱 회귀모형을 쉽게 이해할 수 있다.
- 시간을 들여 흥미로운 범주형 종속변수(e.g., 지지하는 정당, 가입한 보험의 종류, 플로리다 악어가 선호하는 먹이 등)에 관해 상상해보자!

다항 로지스틱 회귀분석

다항 로지스틱 회귀모형은 다항함수를 이용하는 로지스틱 회귀분석이다.

- 플로리다 악어는 크기에 따라 어떤 먹이를 선호하는지 살펴보기 위해, 다음과 같이 상호배타적이고 전체포괄적인 먹이의 범주를 설정하였다.

$$\{\text{어류(fish; } F\text{), 연체류(invertebrates; } I\text{), 기타(other; } O\text{)}\}$$

- 개별 먹이 범주에 대응하는 선택 확률을 다음과 같이 정의할 수 있다.

$$\{P(Y = F), P(Y = I), P(Y = O)\}$$

- 범주형 변수를 독립변수로 사용할 때와 마찬가지로 어느 하나를 기준집단으로 삼아 (그건 모형에서 빼고) 해석한다.

다항 로지스틱 회귀분석

- 기준집단으로 기타(O) 먹이를 선택했다면 다항 로지스틱 회귀식은 다음과 같이 구성된다.

$$\ln \frac{P(Y=F)}{P(Y=O)} = \beta_{0,F} + \beta_{1,F}X$$
$$\ln \frac{P(Y=I)}{P(Y=O)} = \beta_{1,I} + \beta_{1,I}X$$

- 이항 로지스틱과 비교해보면 사실상 똑같은 아이디어임을 확인할 수 있다.

$$ln\frac{P(Y=1|X)}{1-P(Y=1|X)} = \beta_0 + \beta_1 X$$

- 범주가 J개라면 회귀식은 $J-1$개 추정되어야 한다. 가령 범주가 3개(F, I, O) 였다면 추정할 회귀식은 2개가 된다.

다항 로지스틱 회귀분석

다항 로지스틱 회귀계수의 해석 또한 이항 로지스틱과 본질적으로 똑같다.

- 다만 오즈비 대신 상대위험비(relative risk ratio; RRR)라는 표현이 사용된다.
- "길이 X가 1m 증가할수록 기타(O) 먹이보다 어류(F)를 선택할 로그상대위험비는 $\beta_{1,F}$ 만큼 증가한다."
- "길이 X가 1m 증가할수록 기타(O) 먹이보다 어류(F)를 선택할 상대위험은 $100 \times (e^{\beta_{1,F}} - 1)$ 퍼센트 증가한다."

다항 로지스틱 회귀분석

- j번째 범주 먹이가 선택할 예측확률은 다음과 같다.

$$P(Y=j)=\frac{e^{\beta_0+\beta_1 X_j}}{1+\sum_{k=2}^{m} e^{\beta_0+\beta_1 X_k}}$$

- 기준집단 범주 먹이를 선택할 예측확률은 다음과 같다(Why?).

$$P(Y=j)=\frac{1}{1+\sum_{k=2}^{m} e^{\beta_0+\beta_1 X_k}}$$

다항 로지스틱 회귀분석

- 만일 기준집단을 연체류(I)로 바꾼다면 어떨까?
- 물론 기타(O) 말고 연체류(I)로 기준집단으로 바꾸어 다시 한 번 다항 로지스틱 회귀식을 추정하는 것이 편하다.
- 하지만 수학적으로 다음의 관계가 성립함을 알 수 있다(증명 생략).

$$
\begin{aligned}
ln\frac{P(Y=F)}{P(Y=O)} &= \beta_{0,F} + \beta_{1,F}X \\
ln\frac{P(Y=I)}{P(Y=O)} &= \beta_{1,I} + \beta_{1,I}X \\
ln\frac{P(Y=F)}{P(Y=I)} &= ln\frac{P(Y=F)}{P(Y=O)} - ln\frac{P(Y=I)}{P(Y=O)} \\
&= (\beta_{0,F} - \beta_{0,I}) + (\beta_{1,F} - \beta_{1,I})X
\end{aligned}
$$

다항 로지스틱 회귀분석

유의성 검정과 모형적합도 역시 이항 로지스틱 회귀분석과 똑같다.

- (이항 로지스틱 회귀분석와 마찬가지로) 다항 로지스틱 회귀분석에서도 회귀계수의 유의성 검정을 위해 t 검정이 아니라 왈드 검정을 사용한다.

$$\chi_1^2 = \left(\frac{b-\beta}{SE_b}\right)^2 = \left(\frac{b}{SE_b}\right)^2$$

- χ_1^2 값이 충분히 크면 통계적으로 유의하게 귀무가설($H_0 : b = 0$)을 기각할 수 있다.
- 모형적합도를 살펴보기 위해 (1) 우도비 검정, (2) 유사결정계수, (3) 정보기준을 확인한다.

다항 로지스틱 회귀분석

예제 3. Florida Game and Fresh Water Fish Commission는 Lake George에서 59마리의 악어를 잡아 세 종류 중 하나의 먹이를 선택하게 하였다. alligator.csv를 사용하여 악어의 길이(length)가 먹이 선택(food)과 어떤 연관성을 갖는지 해석하시오.

다항 로지스틱 회귀분석

- 먹이 선택(food)을 잘 살펴보면 범주형 자료이므로 일반적인 선형회귀모형은 부적절하고, 범주형 자료분석의 일종인 다항 로지스틱 회귀모형이 적합할 것으로 판단된다.
- 다항 회귀분석을 수행하기 전에 어떤 범주를 기준집단으로 삼을지 생각해야 한다.
- "악어의 길이가 1m 커질수록 기타(O) 먹이보다 연체류(I) 먹이를 선택할 로그상대위험비는 2.465만큼 감소한다."
- "악어의 길이가 1m 커질수록 기타(O) 먹이보다 연체류(I) 먹이를 선택할 상대위험은 91.5% (=$100 \times e^{2.465} - 1$) 감소한다."

다항 로지스틱 회귀분석

- 예측확률 해석은 다항 로지스틱에서 특히 빛을 발한다!

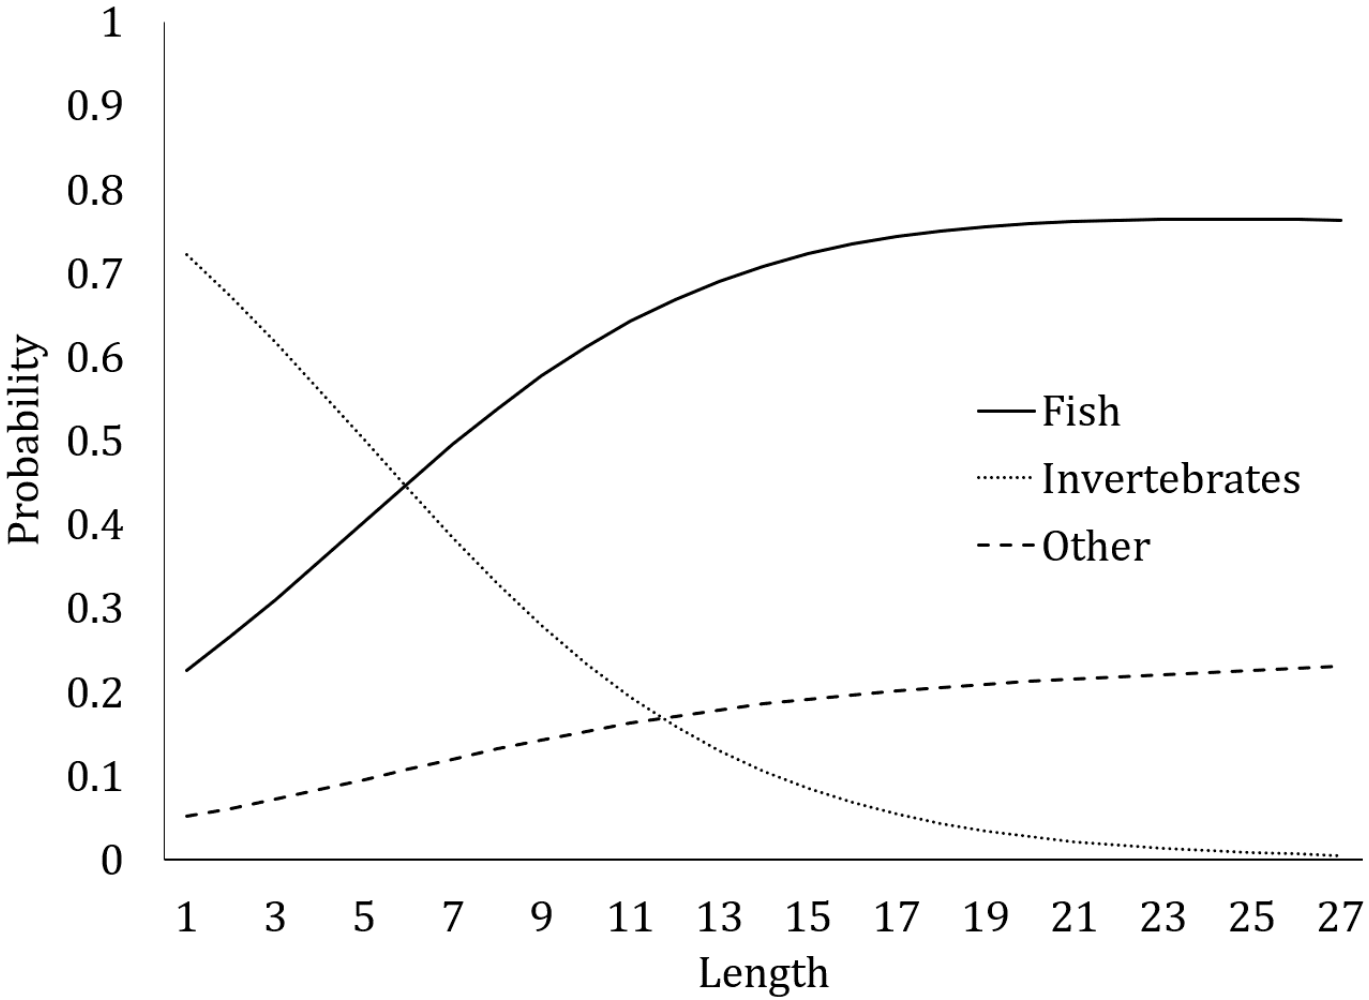

다항 로지스틱 회귀분석

- 악어의 길이와 먹이 선택은 일부만 통계적으로 유의했다. 즉 어류(F) 먹이는 기타(O) 먹이와 비교할 때 길이에 따른 선택 차이가 없었다.
- 한편, '전반적으로' 먹이 선택이 악어의 길이와 독립이라는 귀무가설은 다음과 같다.

$$H_0 : \beta_{1,F} = \beta_{1,I} = 0$$

- 이는 우도비 검정으로 테스트될 수 있으며(Why?) 검정통계량 G는 χ^2 분포를 따른다.

$$G = -2ln\frac{L_{null}}{L_{model}} = -2ln(L_{null} - L_{model}) \sim \chi^2_k$$

- $\chi^2 = 16.8$이므로 99.9% 신뢰수준에서 통계적으로 유의하게 귀무가설을 기각한다 ($p < 0.0002$).
- 그러므로 '전반적으로' 악어의 길이와 먹이 선택에는 통계적 연관성이 존재한다!

서열 로지스틱 회귀분석

서열 로지스틱 회귀분석

종속변수가 서열 척도라면 서열 로지스틱 회귀모형 등을 활용한다.

- 종속변수가 범주형이되 순서가 있다면, 서열(ordinal) 로지스틱 회귀모형을 사용할 수 있다.
- 서열 척도는 어쩌면 사회조사(social survey)에서 가장 흔하게 사용되는 척도일 것이다!

○○님은 현재 남한에 들어와 있는 탈북민을

대한민국 시민이라 생각하십니까?

1. 매우 그렇게 생각한다
2. 어느 정도 그렇게 생각한다
3. 별로 그렇게 생각하지 않는다
4. 전혀 그렇게 생각하지 않는다

- 시간을 들여 흥미로운 서열형 종속변수(e.g., 주관적 사회계층, 행복도)에 대해 상상해보자.

서열 로지스틱 회귀분석

사실 로지스틱 회귀모형들은 모두 잠재변수 개념을 사용하고 있다.

- 잠재변수(latent variable)란 보이지 않는 (말 그대로) 보이지 않는 변수이다. 반면 관측변수(observed variable)는 자료를 통해 볼 수 있는 변수이다.
- 만일 종속변수로 $\{1 = \text{불만족}; 2 = \text{중립}; 3 = \text{만족}\}$ 범주가 주어졌다면, 이 서열 로지스틱 회귀모형은 아래와 같은 모형구조를 가지고 있다.

$$Y_i^* = \tau_k - \beta_1 X_i$$

$$Y_i = \begin{cases} 1 & (\text{if } -\infty < Y^* \leq \tau_1) \\ 2 & (\text{if } \tau_1 < Y^* \leq \tau_2) \\ 3 & (\text{if } \tau_2 < Y^* \leq \infty) \end{cases}$$

- 다시 말해, 모든 로지스틱 회귀모형은 양적 변수인 잠재변수를 종속변수로 삼았던 것이고, 그것이 어떤 절단지점(cutpoint) τ를 넘었는가에 따라 관측변수인 {1, 2, 3}에 대응시킨 셈이다!

서열 로지스틱 회귀분석

- 서열 로지스틱 회귀모형에는 상수(constant)가 따로 없고, 대신 절단지점(cutpoint) τ들이 존재한다.
- 또한 이렇게 설정된 서열 로지스틱에서는 β_1 뿐 아니라, τ_1와 τ_2도 추정해야 함을 짐작할 수 있다.
- 공부하다보면 사실 τ가 상수와 비슷한 역할을 수행하고 있음을 눈치챌 수 있다.
- 모든 로지스틱 회귀모형 계열들은 이런 식으로 잠재변수와 관측변수를 동시에 사용한다.

서열 로지스틱 회귀분석

- Y_i^*는 이항 로지스틱 회귀모형과 잠재변수의 설정이 살짝 다르다.

$$Y^* = ln\frac{P(Y \leq k)}{P(Y > k)} = \tau_k - \beta_1 X$$

- 가령 위 세 범주를 예로 들면 절단지점 τ_1과 τ_2를 다음과 같이 추정해야 한다.

$$ln\frac{P(Y=1)}{P(Y=2)+P(Y=3)} = \tau_1 - \beta_1 X \qquad (\text{if } k=1)$$

$$ln\frac{P(Y=1)+P(Y=2)}{P(Y=3)} = \tau_2 - \beta_1 X \qquad (\text{if } k=2)$$

서열 로지스틱 회귀분석

- 오즈비 $e^{-\beta_1}$ 를 이항 로지스틱처럼 해석할 수 있다.

$$OR = \frac{odds_{X+1}}{odds_X} = \frac{\left(\dfrac{P(Y=1|X+1)}{P(Y=2|X+1)+P(Y=3|X+1)}\right)}{\left(\dfrac{P(Y=1|X)}{P(Y=2|X)+P(Y=3|X)}\right)}$$
$$= \frac{e^{\tau_1-\beta_1(X+1)}}{e^{\tau_1-\beta_1 X}} = e^{-\beta_1}$$

- 회귀계수가 $(-)$ 인 것이 오히려 자연스럽다(Why?").
- 서열 로지스틱 회귀모형에는 (잠재변수의 모형 설정에 따라) 인접범주모형(adjacent categories model), 연속비 모형(continuation ratio model), 스테레오타입 모형(stereotype model) 등 여러 종류가 있다.

서열 로지스틱 회귀분석

서열 로지스틱 회귀분석은 (성립을 장담하기 어려운) 가정을 요구한다.

- 이것을 비례오즈 가정(proportional odds assumption)라고 부르는데, 좀 더 일반화된 표현으로 평행회귀 가정(parallel regression assumption)도 사용된다.
- 그 핵심은 독립변수가 변화함에 따라 어떤 범주 값에서든 확률에 미치는 영향이 동일하다는 것이다(아쉽지만 수학적 토대없이는 이해하기 어렵다).

$$\frac{\delta P(Y \leq 1|X)}{\delta X} = \frac{\delta P(Y \leq 2|X)}{\delta X} = \cdots = \frac{\delta P(Y \leq |X)}{\delta X}$$

- 이 가정에 대해서는 브랜트-왈드 검정(Brant-Wald test)으로 확인해 볼 수 있다.
- 응용통계학의 관점에서 본다면 서열 로지스틱 회귀분석의 결과는 일반화된 서열 로지스틱(generalized ordinal logistic) 및 다항 로지스틱 회귀모형 결과와 조심스럽게 비교해야 한다.

서열 로지스틱 회귀분석

예제 4. nhanes2f.dta를 사용하여 주관적 건강상태(health)를 종속변수로, 성별(female), 인종(black), 연령(age)을 독립변수로 하는 서열 로지스틱 회귀모형을 추정하고, 연령의 효과를 해석하시오.

서열 로지스틱 회귀분석

- 주관적 건강상태(health)를 살펴보면 “poor (1)”에서 “excellent (5)”까지 전형적인 리커트 5점 척도로 측정되어 있으므로 일단 서열 로지스틱 회귀모형을 사용할 수 있다.
- “(다른 변수의 영향력을 통제할 때) 나이를 한 살 더 먹을수록 주관적 건강상태 악화의 로그오즈가 0.041 만큼 증가한다”(Why?).
- “(다른 변수의 영향력을 통제할 때) 나이를 한 살 더 먹을수록 주관적 건강상태 악화의 오즈가 4% 증가한다”(Why?).
- 물론 서열 로지스틱 회귀모형의 경우에도 예측 확률로 그림을 그릴수 있지만 그다지 사용되지는 않는 것 같다.

서열 로지스틱 회귀분석

- 사실 비례오즈 가정은 이 자료에서 제대로 충족되지 않는다. 그러므로 다항 로지스틱 회귀분석을 수행하고 서열 로지스틱 회귀분석 결과와 비교해보자(Why?).
- 주어진 모형적합도를 판단해보고, 당뇨병(diabetes)을 추가하였을 때 전반적인 개선 여부를 함께 판단해보자.
- 서열 로지스틱 회귀분석에서 회귀계수 해석은 특히 혼동하기 쉬우므로 주의를 기울여야 한다!